

# Análisis visual de series temporales combinando técnicas de minería de datos (DM) y aprendizaje profundo (DL)

María Inmaculada Santamaría Valenzuela



Directores

David Camacho Fernández  
Víctor Rodríguez Fernández

# QR Presentación



<https://github.com/misantamaria/thesis/raw/refs/heads/main/TarjetaPresentación.pdf>

# **Contenido**

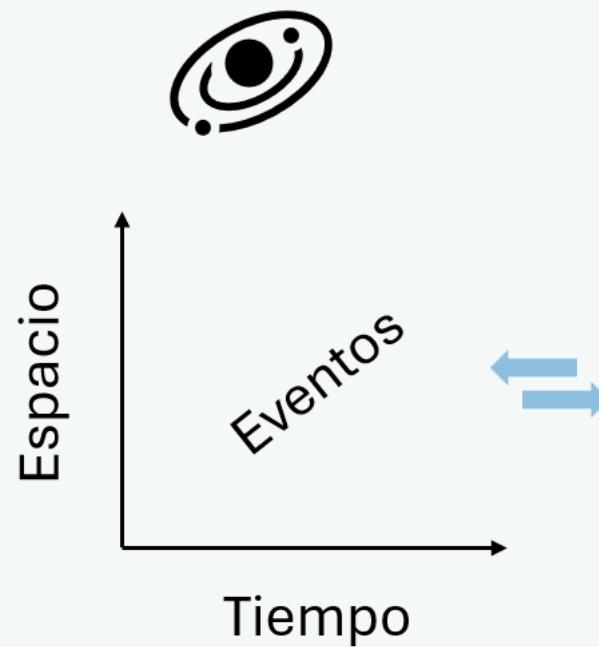
1. Introducción
2. Herramientas y metodología
3. Resultados experimentales
4. Discusión
5. Conclusiones y trabajo futuro

1 /5

# Introducción

# Series temporales

# Series temporales



Observa  
Registra  
Analiza



Tiempo	Variable 1	...	Variable N >= 1
7:00 AM	100		0
11:00 AM	0		50
03:00 PM	0		50
06:30 PM	100		0
07:00 PM	0		50
10:00 PM	0		50

# Series temporales | Análisis



Evitar problemas  
(máquinas, apagón)



Monitorizar  
(evolución a tratamiento)

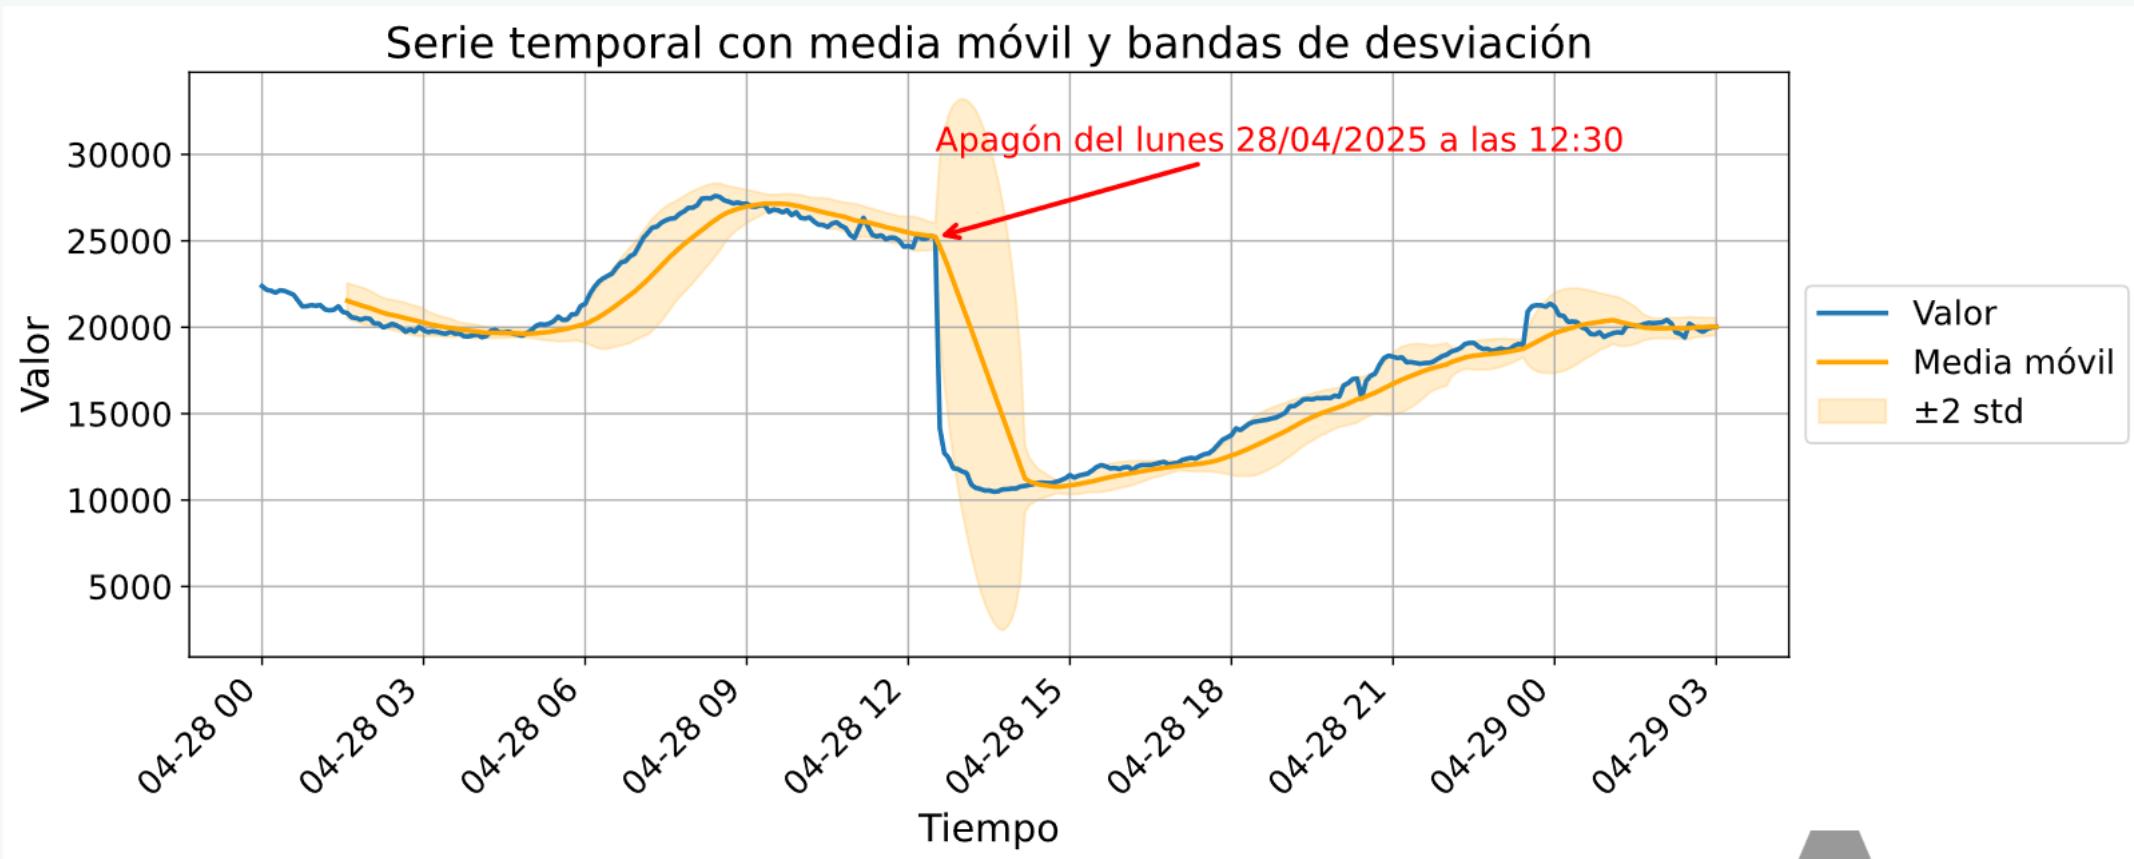


Predecir valores  
(finanzas)



Gestionar  
(transporte, stock)

# Análisis visual básico | Caso práctico | apagón 28/04/2025 1/3

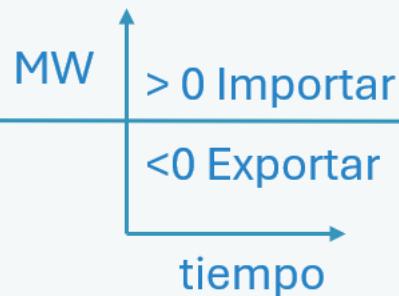


Demand real de energía eléctrica  
el día 28 de abril de 2025 en la Península Ibérica (MW)



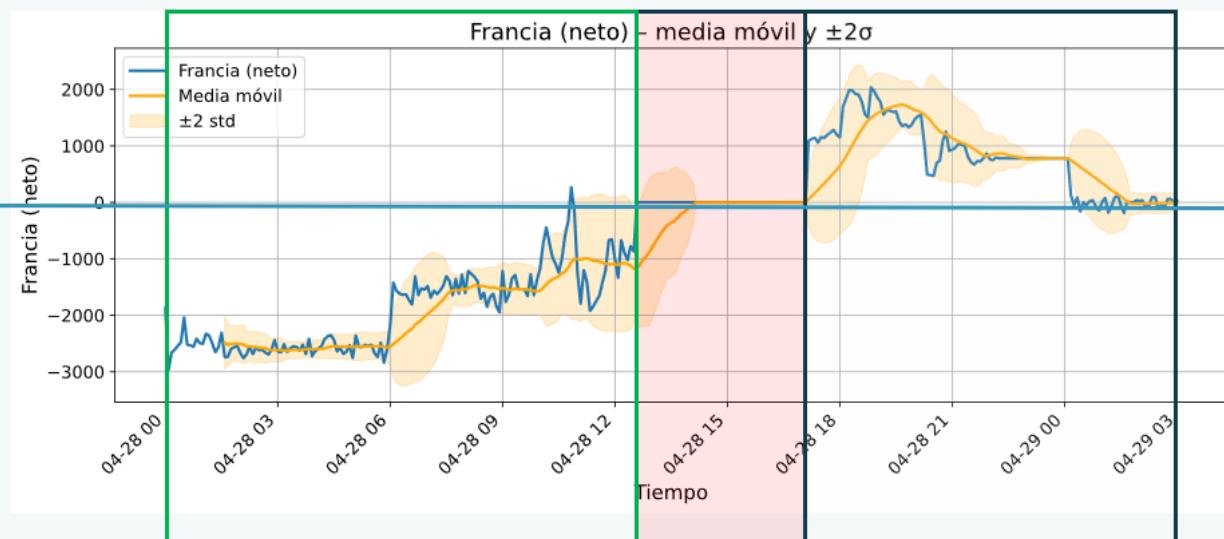
# Análisis visual básico | Caso práctico | apagón 28/04/2025 2/3

Gráficas de exportación e importación de energía eléctrica

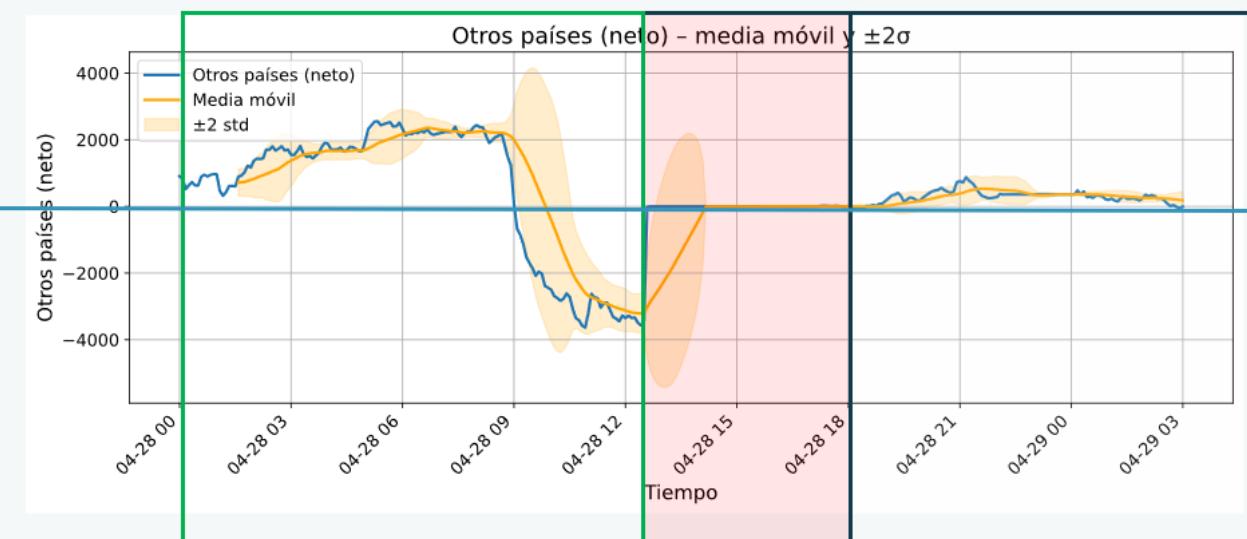


# Análisis visual básico | Caso práctico | apagón 28/04/2025 2/3

## Gráficas de exportación e importación de energía eléctrica



Con Francia



Con otros países / zonas geográficas



Leyenda

Exportamos energía a Francia

Francia bloquea a España para protegerse del apagón

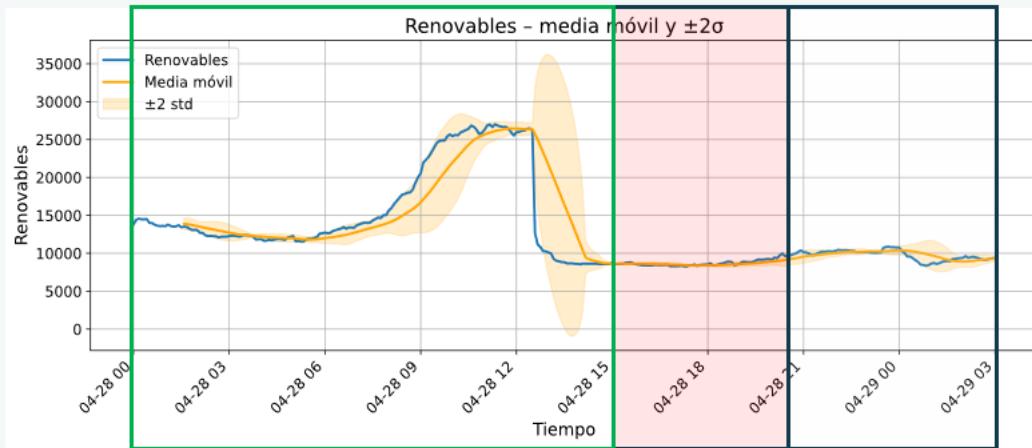
Importamos hasta estabilizar

# Análisis visual básico | Caso práctico | apagón 28/04/2025 3/3

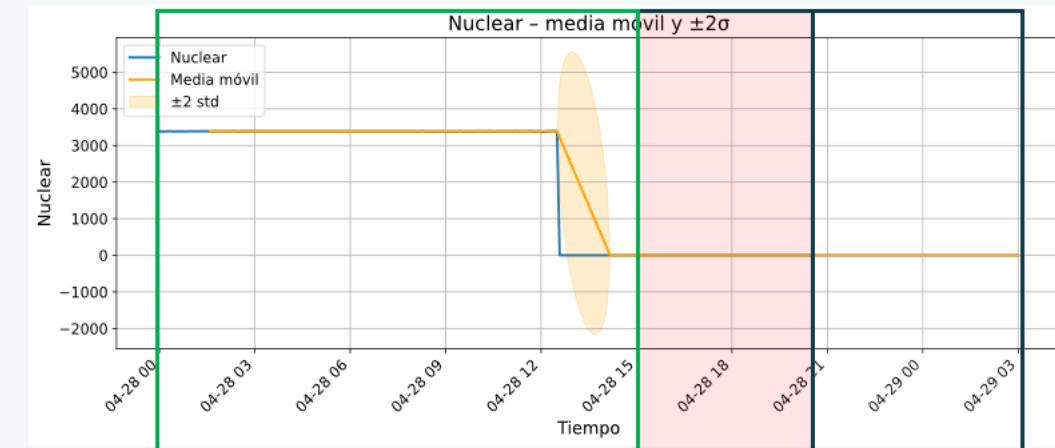
Gráficas de generación de energía



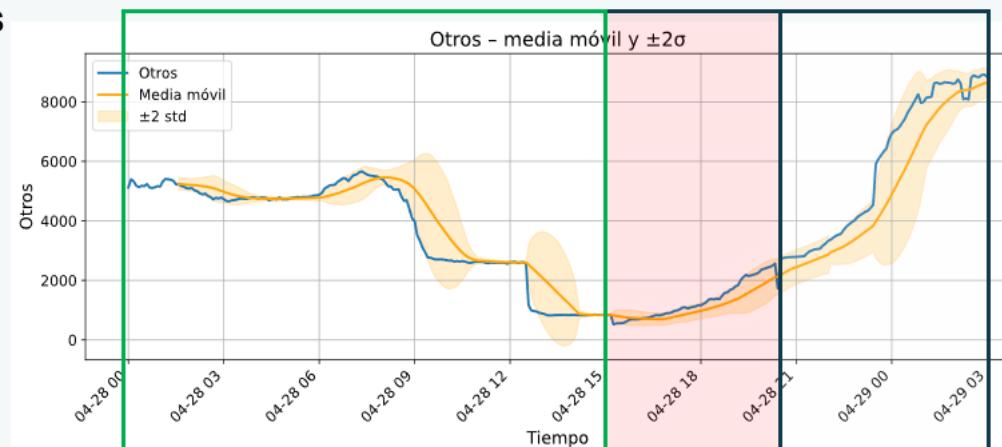
# Análisis visual básico | Caso práctico | apagón 28/04/2025 3/3



Fuentes renovables



Centrales nucleares



Otros (principalmente ciclo combinado – gas)

Gas  
Carbón  
Ciclo combinado  
Cogeneración y residuos



Leyenda

# Análisis visual: Técnicas y campos de estudio

Clasificación

Imputación

Predicción

Detección de anomalías

Detección de tendencias

Segmentación

Estadística

Minería de datos  
(DM)

Análisis de señales

Aprendizaje profundo (DL)

Tareas de análisis visual

Áreas de estudio

# Análisis visual: Técnicas y campos de estudio

Clasificación

Detección de anomalías

Imputación

Detección de tendencias

Predicción

Segmentación

Tareas de análisis visual

Estadística

Minería de datos  
(DM)

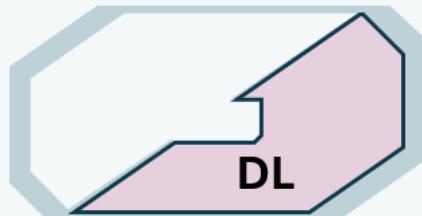
Análisis de señales

Aprendizaje  
profundo (DL)

Áreas de estudio

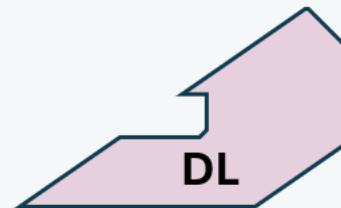
# Objetivo

Tenemos

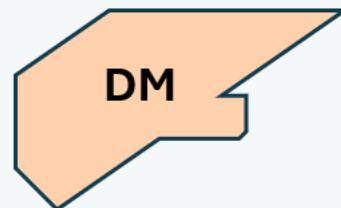


Problemas de escalabilidad  
Difícil de interpretar  
Costoso en memoria y tiempo

Existen herramientas



Rápido



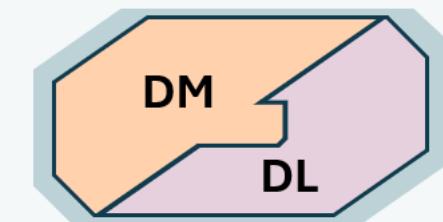
Escalable

Fácil de interpretar

Rápido

Incompleto, solo univariable

Buscamos



Escalable

Fácil de interpretar

Rápido

Completo

# Hipótesis



## Hipótesis global

Mejorar **análisis visual interactivo** de series temporales con **DL** y **DM** para ganar **interpretabilidad, interactividad**

### Hipótesis I

**DM** ayuda a mejorar la **interpretabilidad y eficiencia** de las DVA

### Hipótesis II

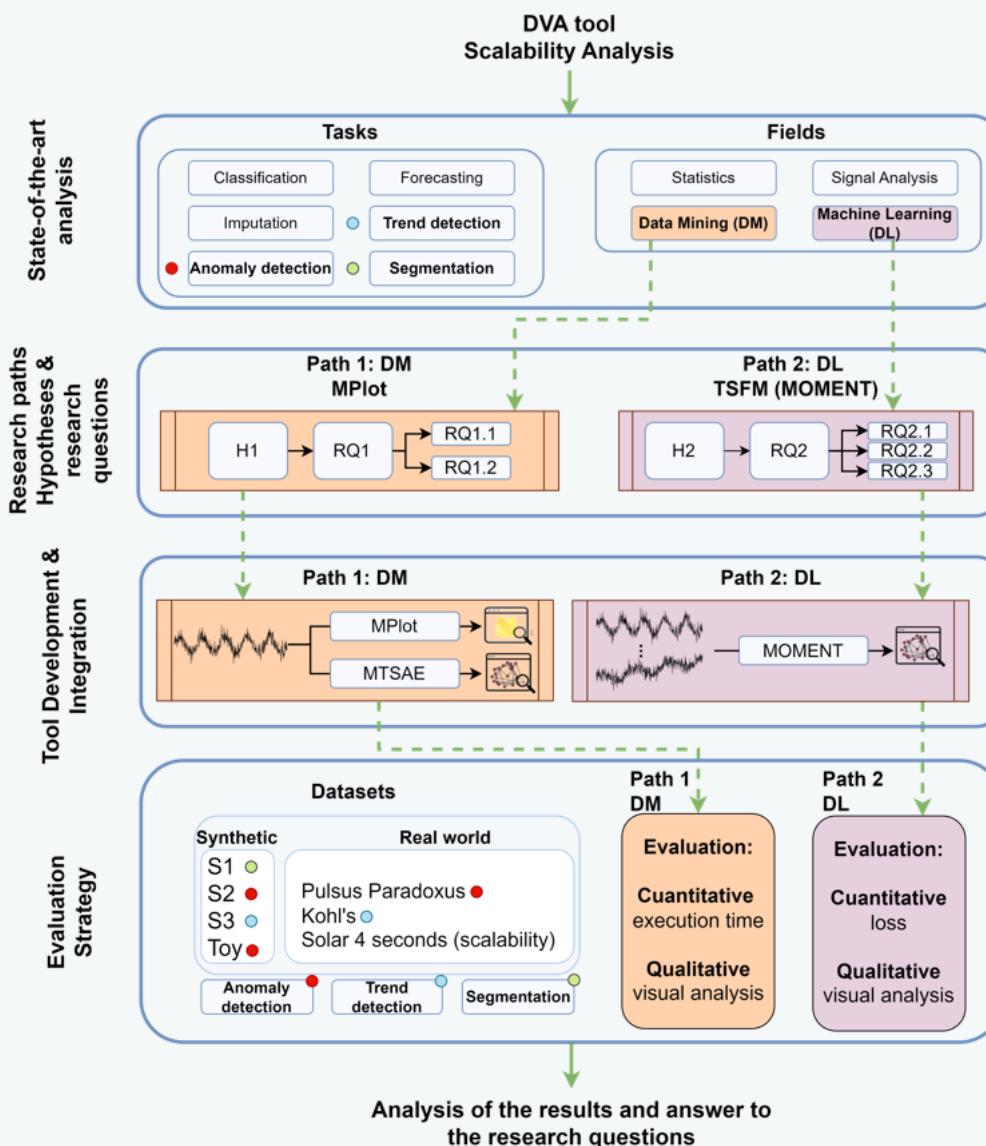
Los **modelos fundacionales** ayudan a mejorar la **eficiencia e interpretabilidad** de los DVA?



**2**/<sub>5</sub>

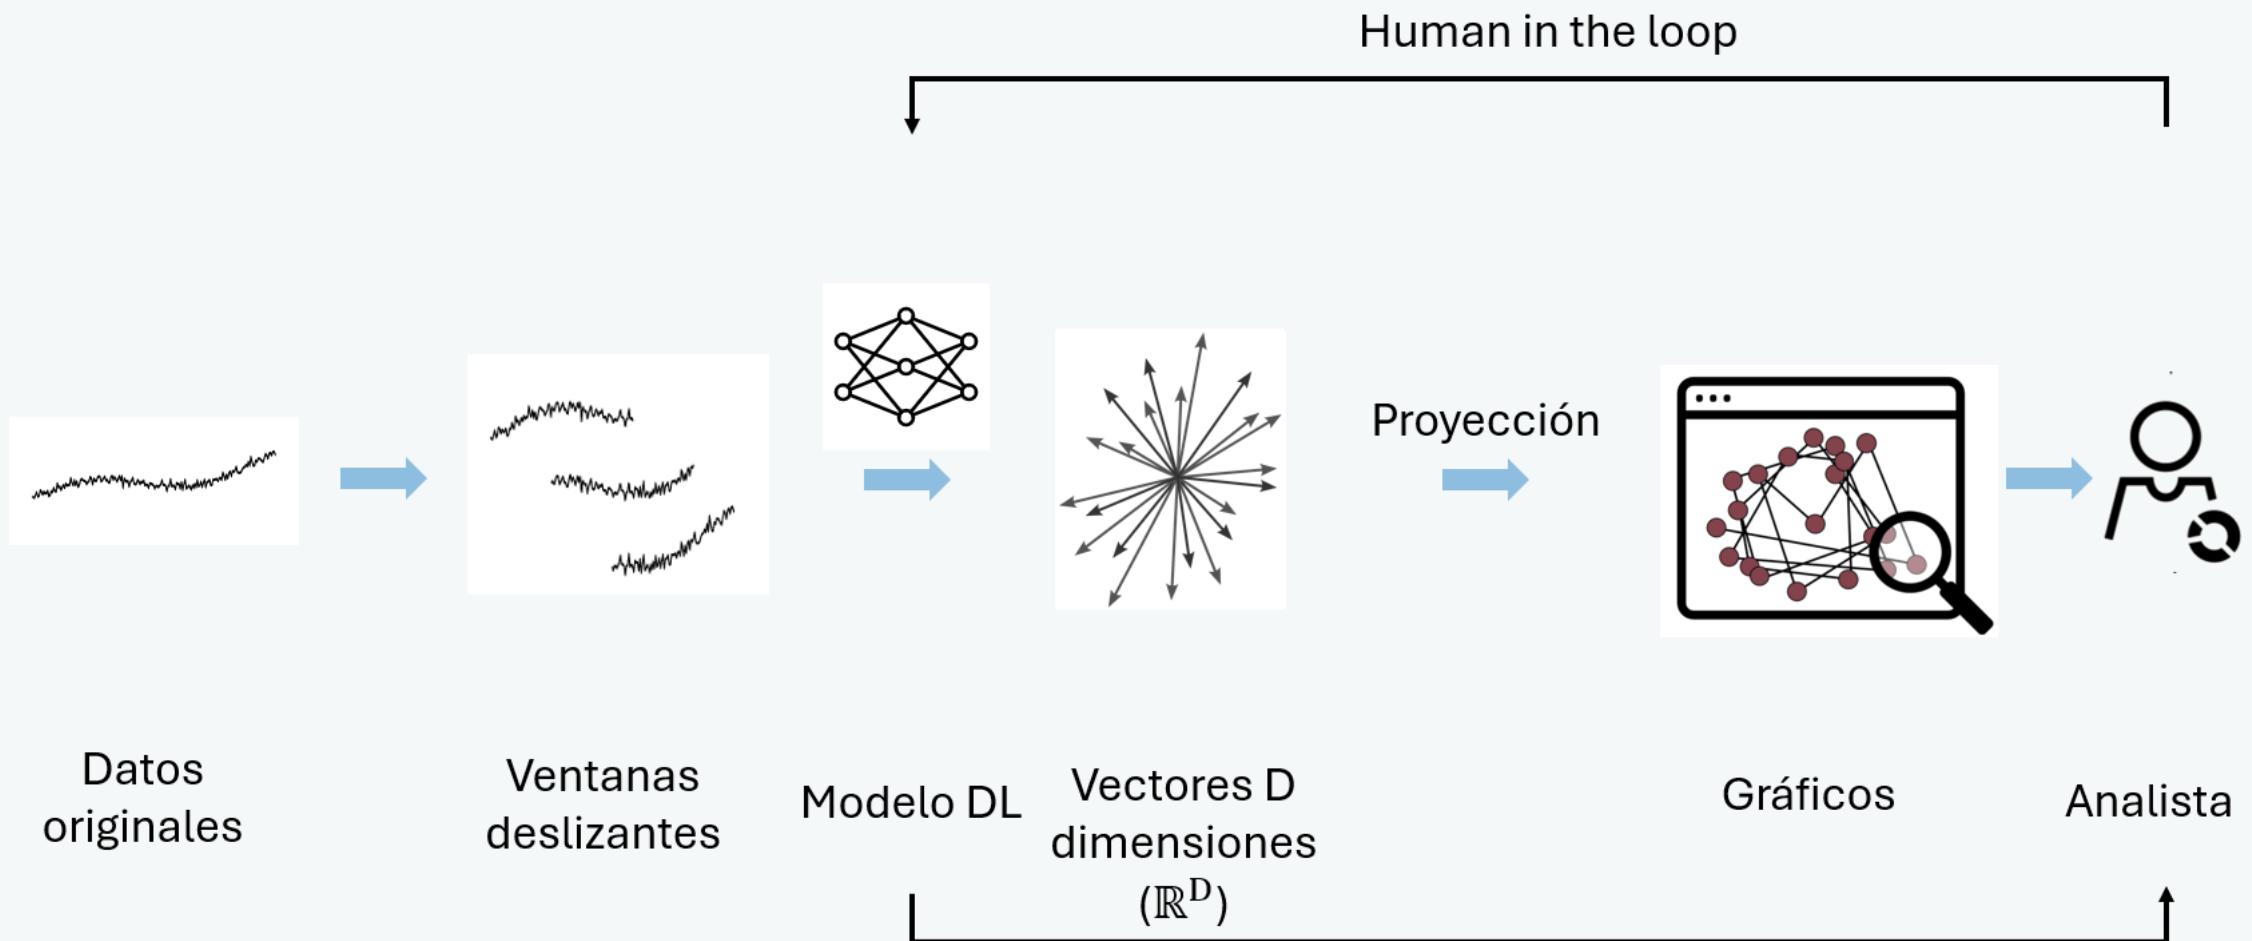
# Herramientas y metodología

# Metodología y herramientas

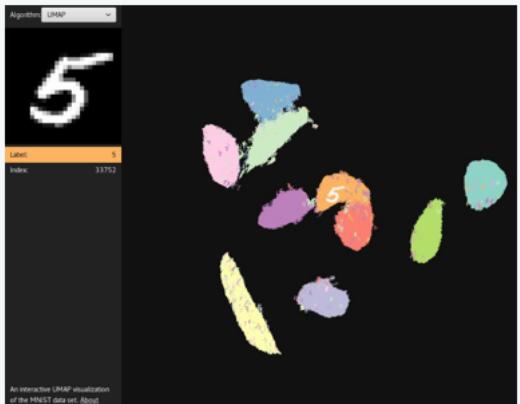


- **Herramientas:**
  - De análisis con DL
  - De análisis con DM
  - Nuestro entorno de pruebas
- **Metodología**
  - Análisis de escalabilidad
  - Selección de herramientas
  - Evaluación

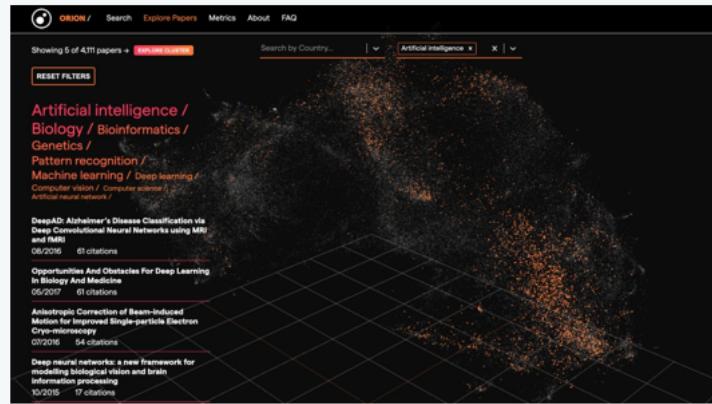
# Análisis visual basado en DL (DVA) 1/3



# Análisis visual basado en DL (DVA) 2/3

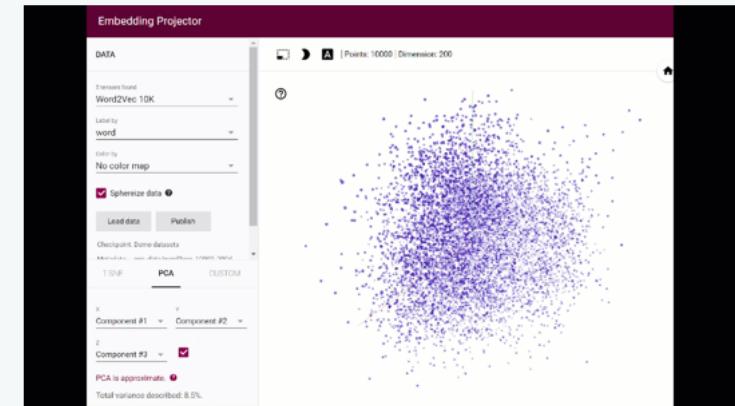


MNIST digits  
Imágenes de números



Orion Search  
Artículos académicos

UMAP Zoo



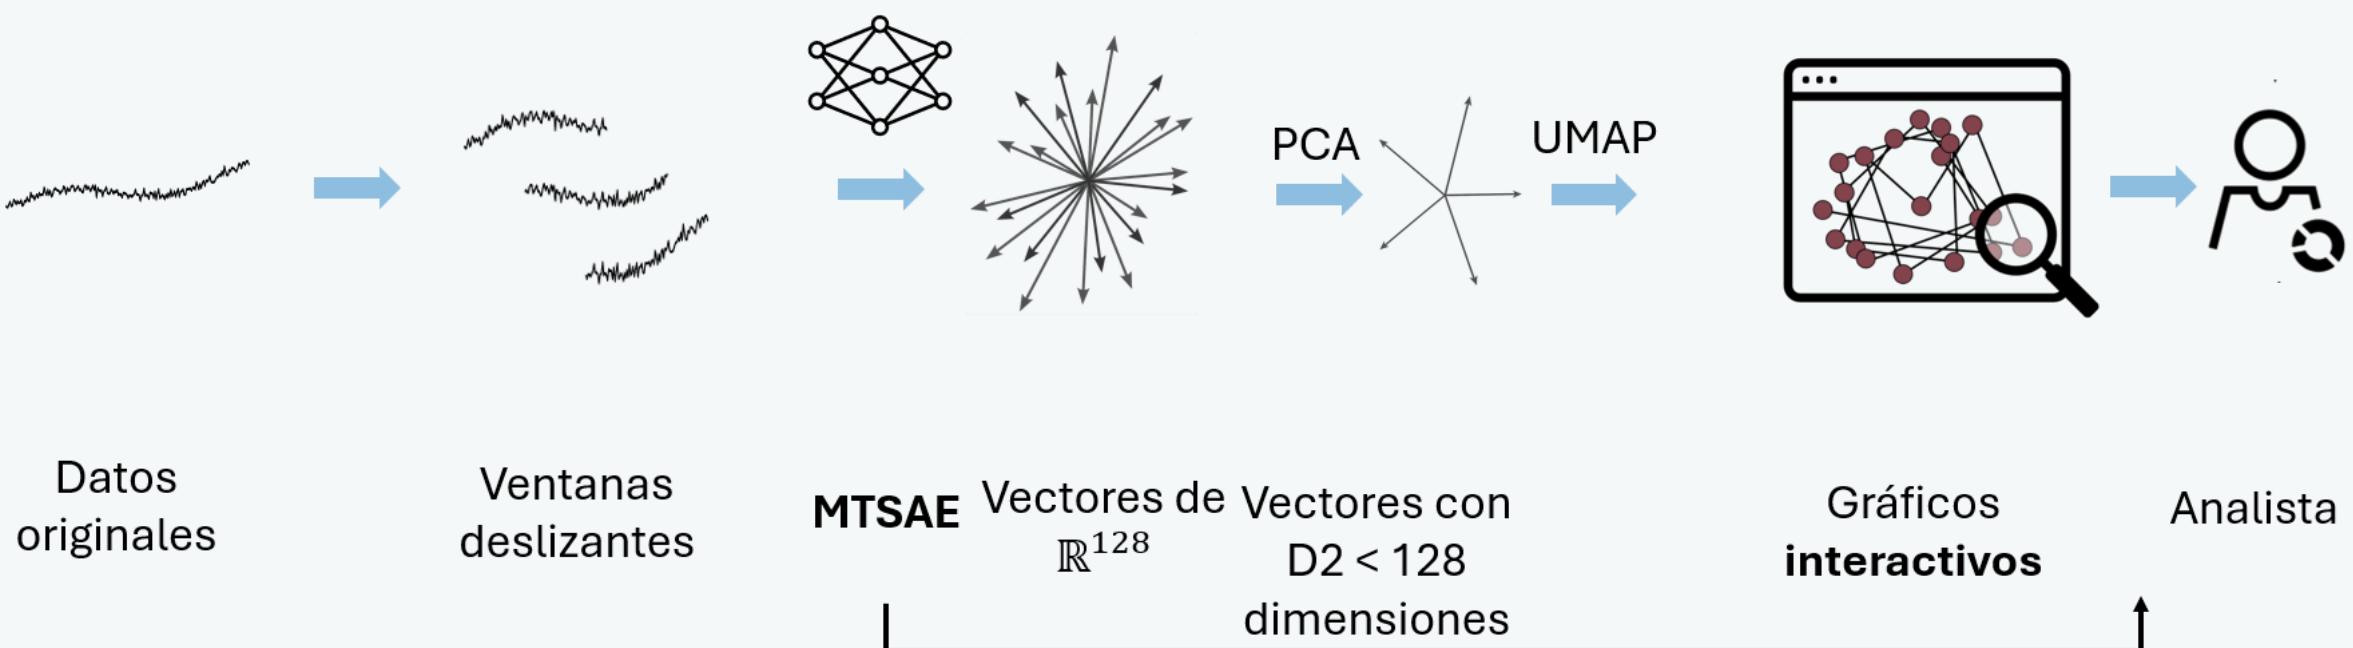
Importación genérica  
Vectores del espacio latente

TensorFlow

# Análisis visual basado en DL (DVA) 3/3



**Entorno** de experimentación: DeepVATS



# Entorno de experimentación: DeepVATS 1/3



- DeepVATS
- Módulo de Deep Learning  
  - Módulo de almacenamiento 
  - Módulo de análisis visual 

# Entorno de experimentación: DeepVATS 2/3



- Módulo de Deep Learning
- Módulo de almacenamiento
- Módulo de análisis visual



**DeepVATS**



Nuevos **modelos de DL**



Nuevas **herramientas de DM**



**Nuevas herramientas auxiliares**



Gestión de ventanas

Transformada de Fourier

Gestión de artefactos por defecto

# Entorno de experimentación: DeepVATS 3/3



**DeepVATS**



**Nuevas opciones**

Ajuste fino con los datos brutos

Ajuste / Inferencia con datos  
preprocesados

- Módulo de Deep Learning
- Módulo de almacenamiento
- **Módulo de análisis visual**



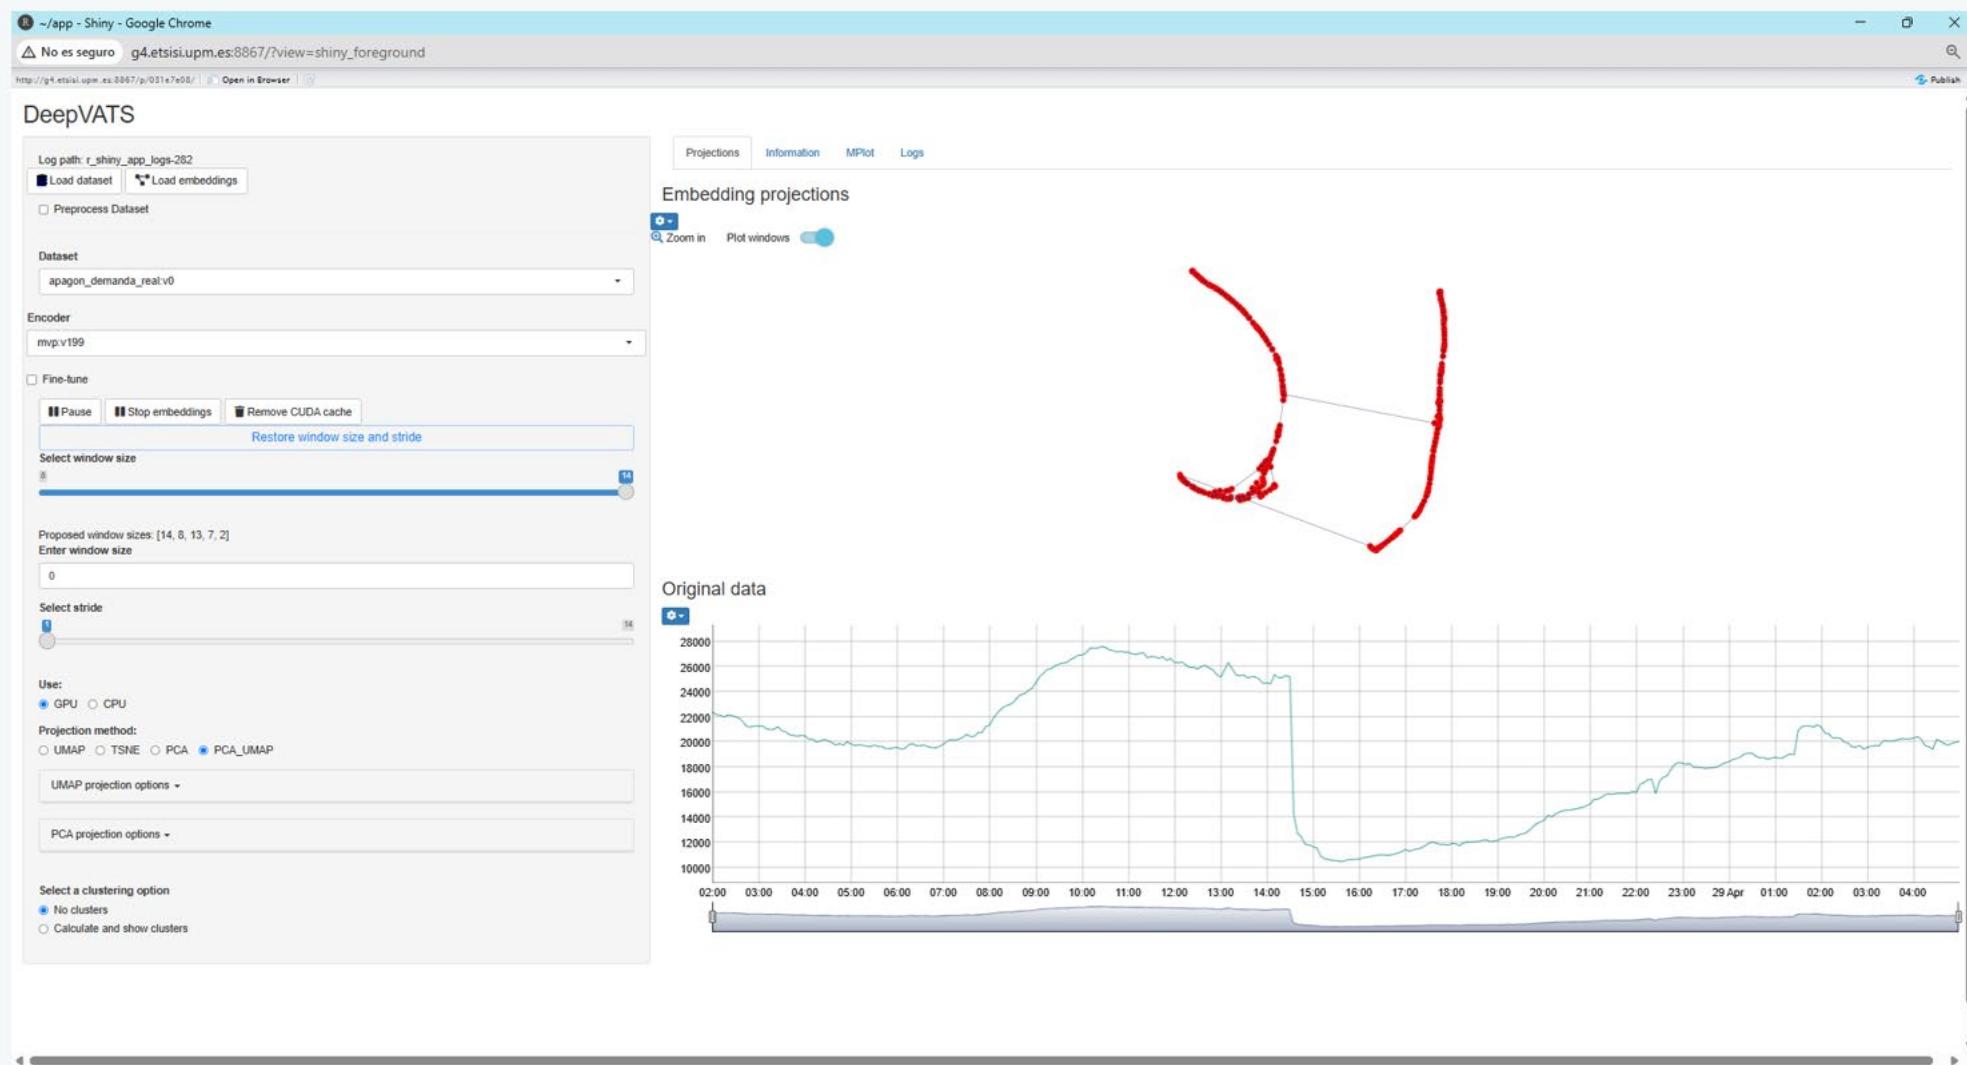
**Nuevas pestañas**

Herramientas de DM

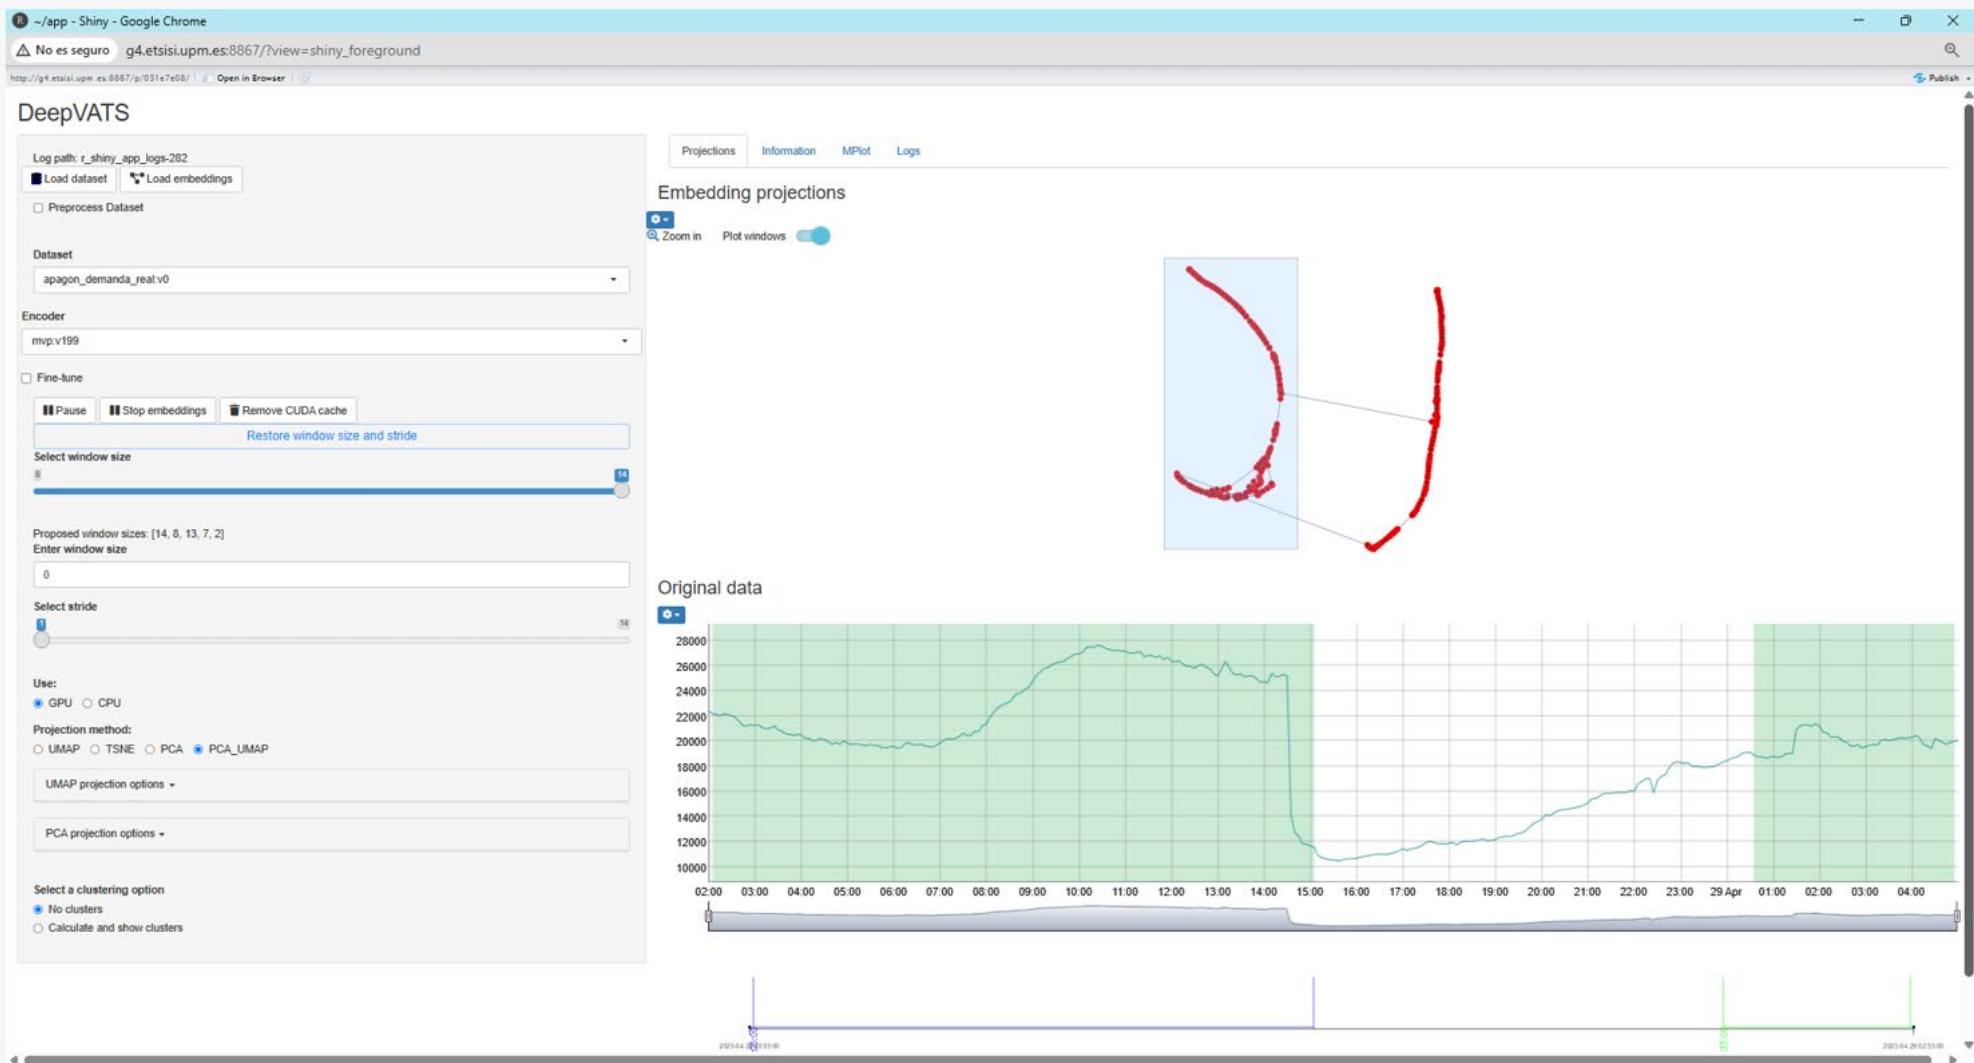
Gestión de Logs



# Caso de uso | Segmentación y anomalías | Univariable



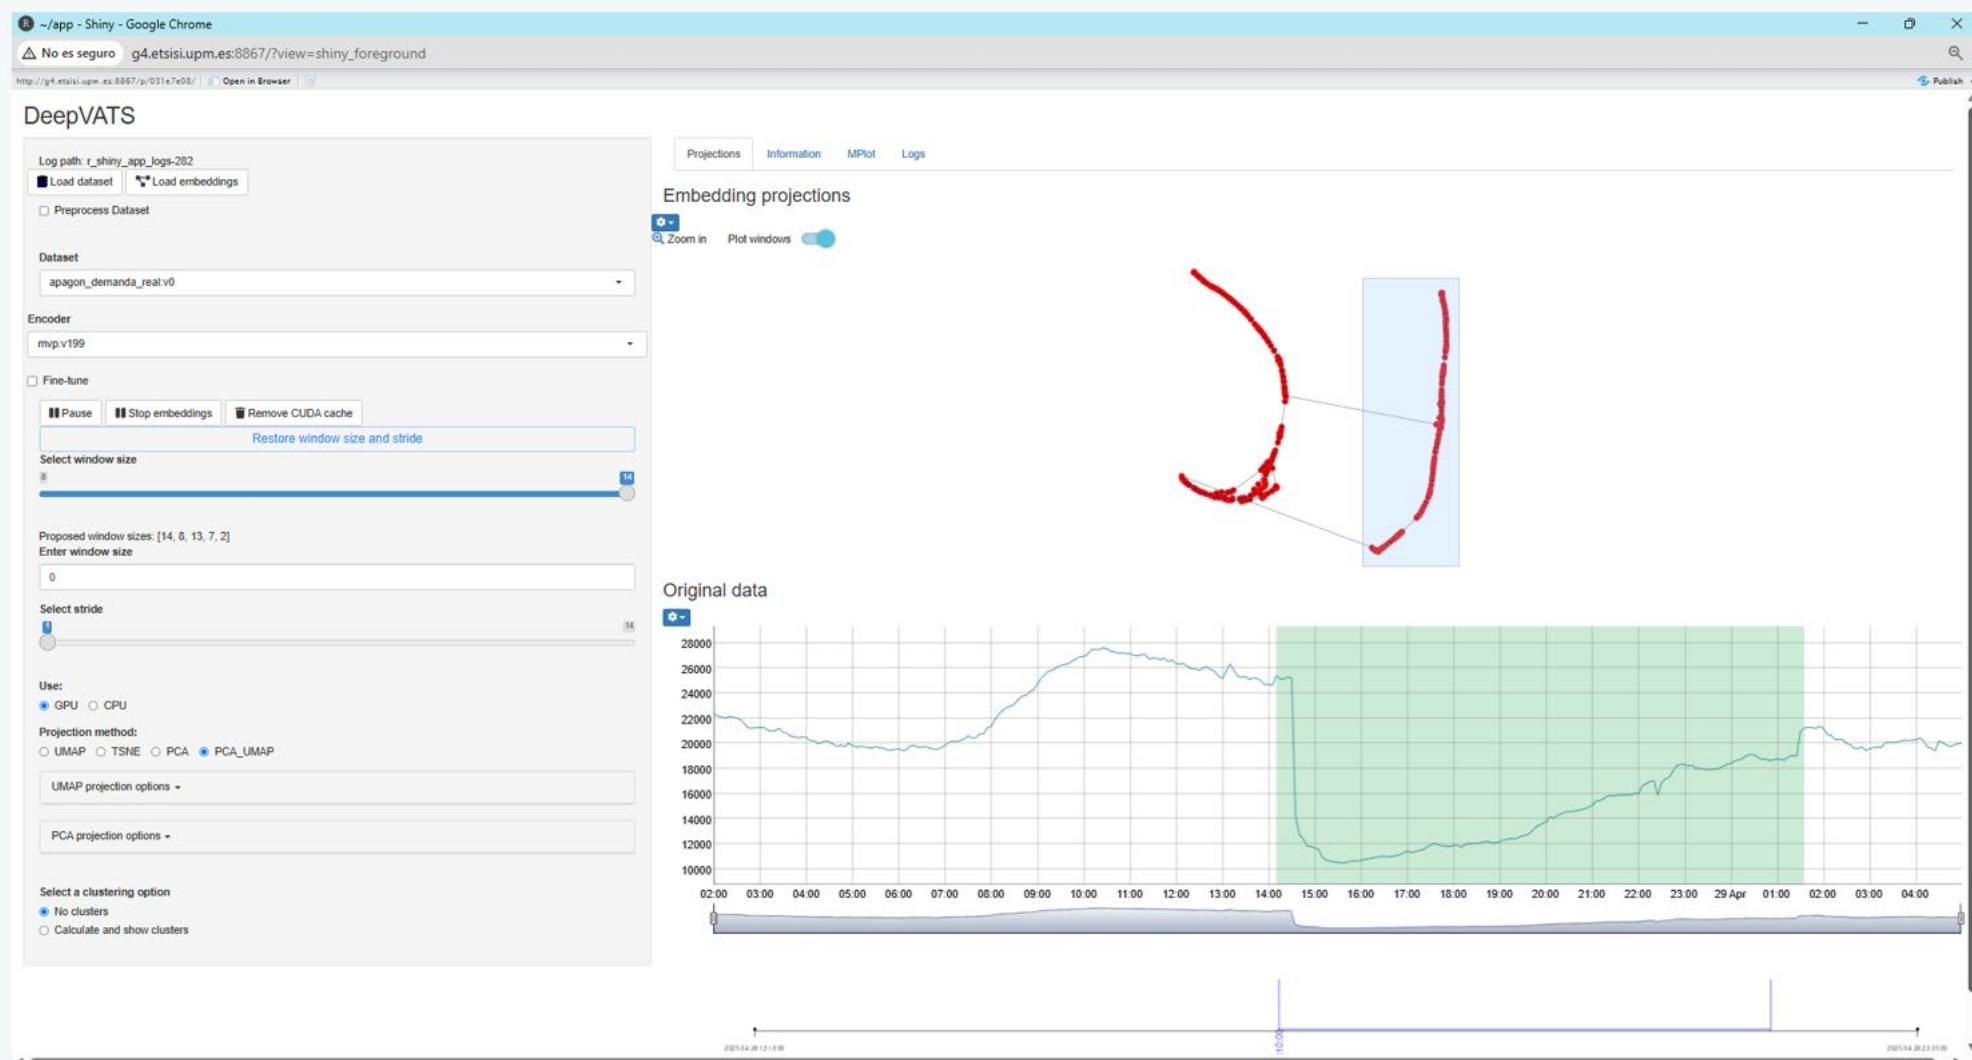
# Caso de uso | Segmentación y anomalías | Univariable



Flujo habitual y  
pico de las  
renovables



# Caso de uso | Segmentación y anomalías | Univariable

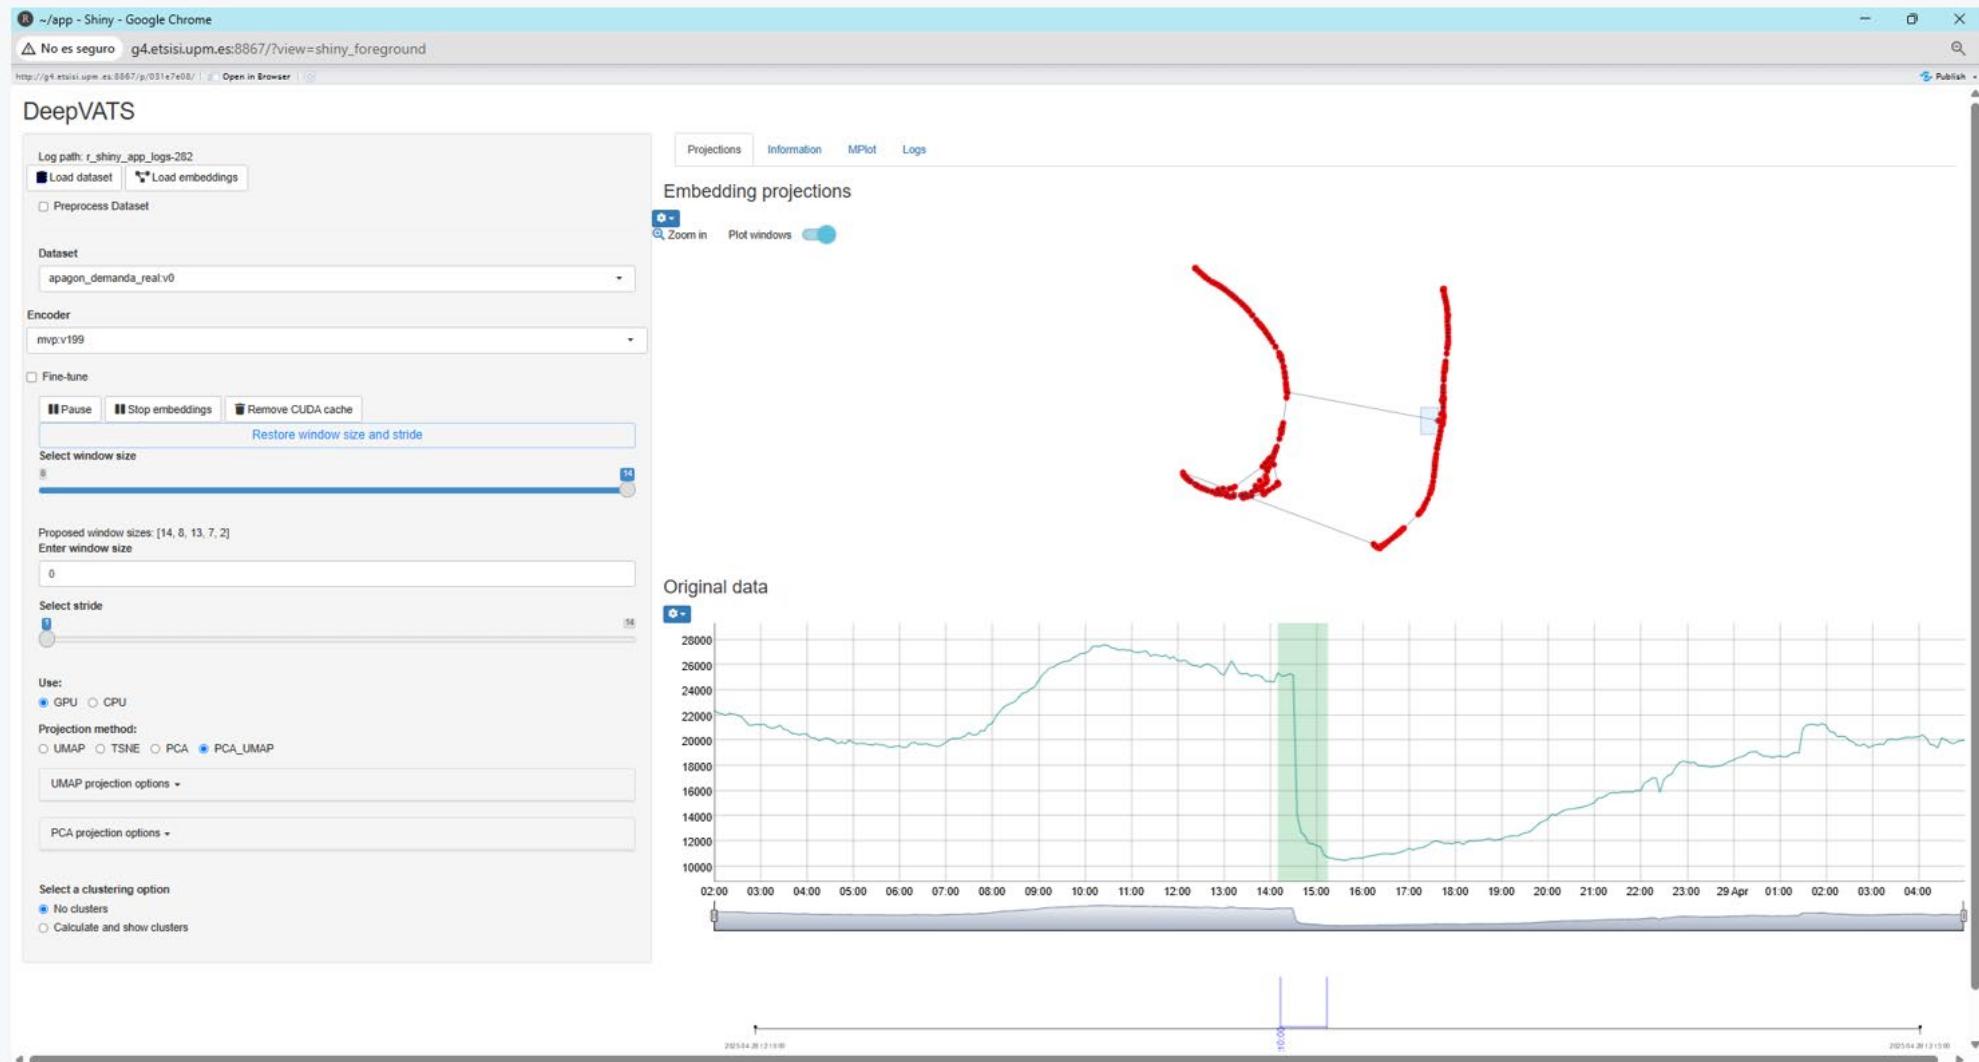


Bloqueo y recuperación

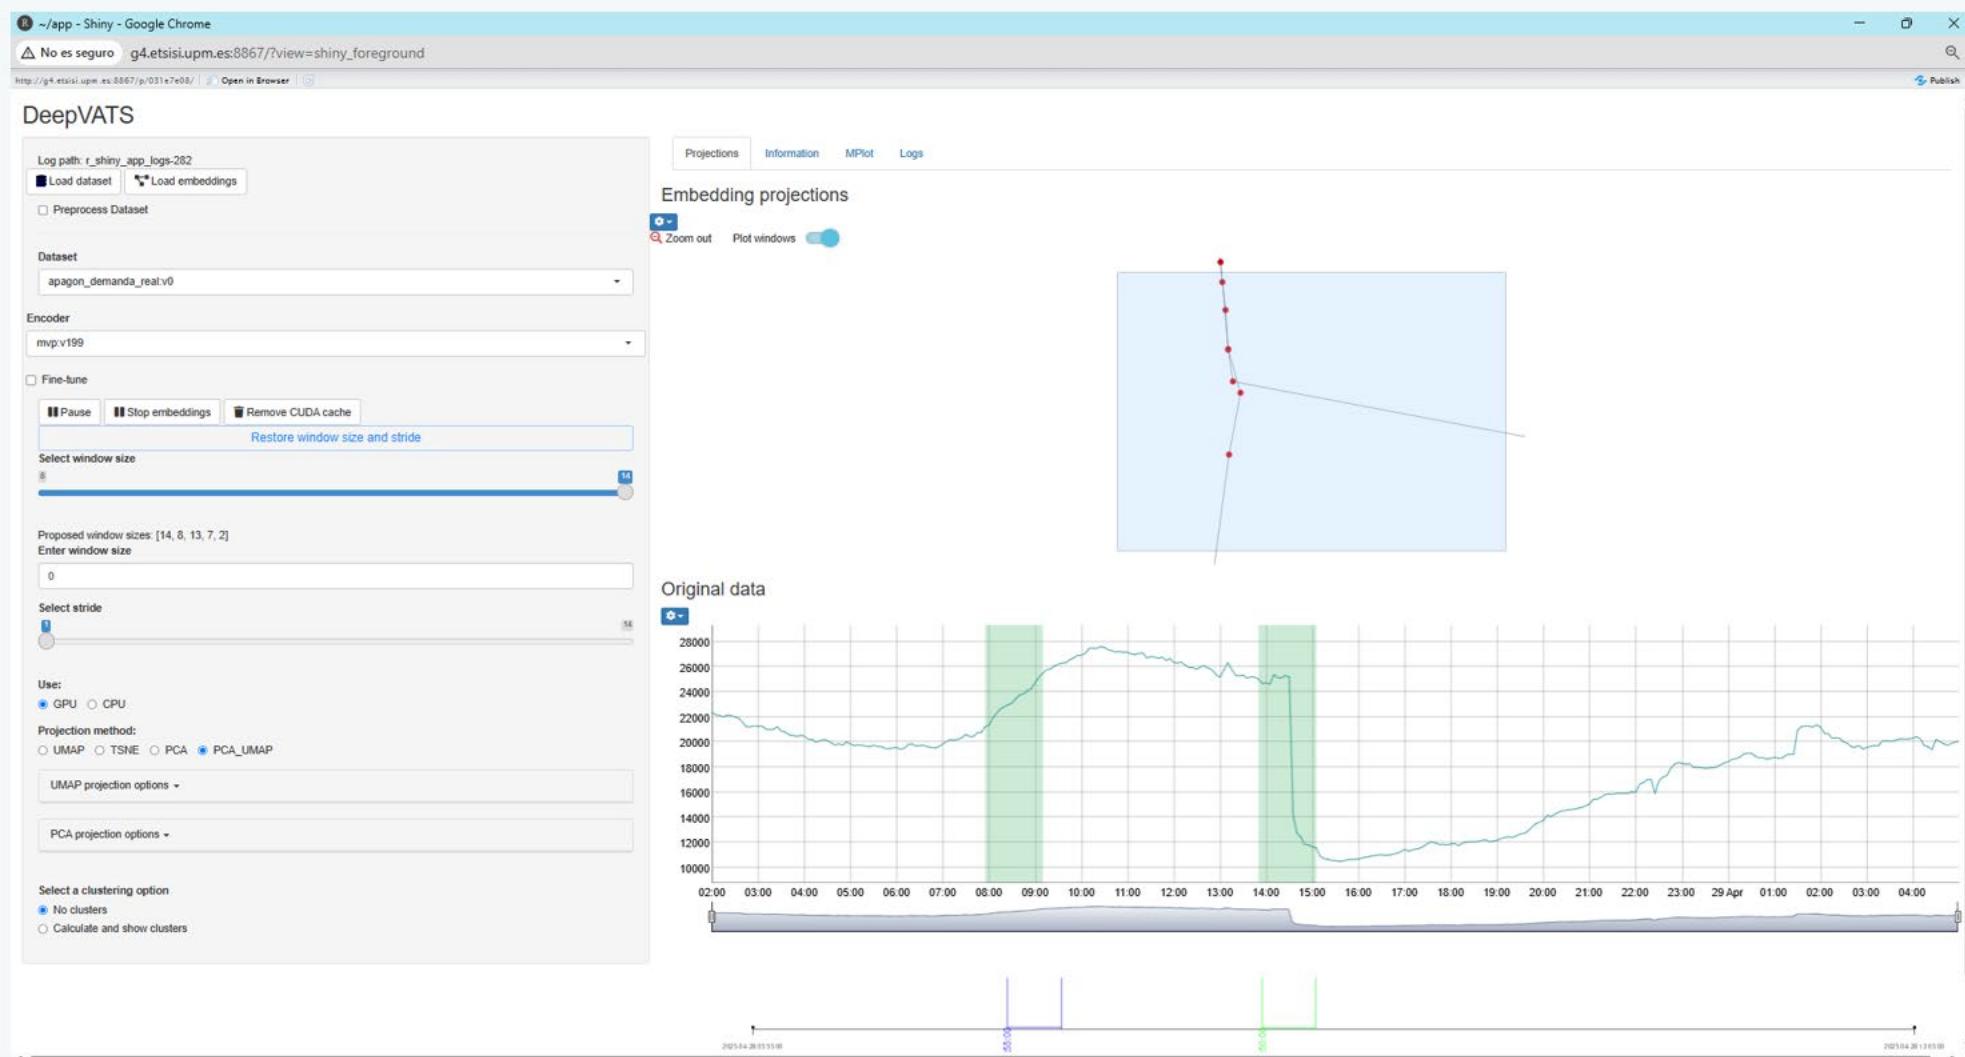


# Caso de uso | Segmentación y anomalías | Univariable

Momento  
del  
apagón



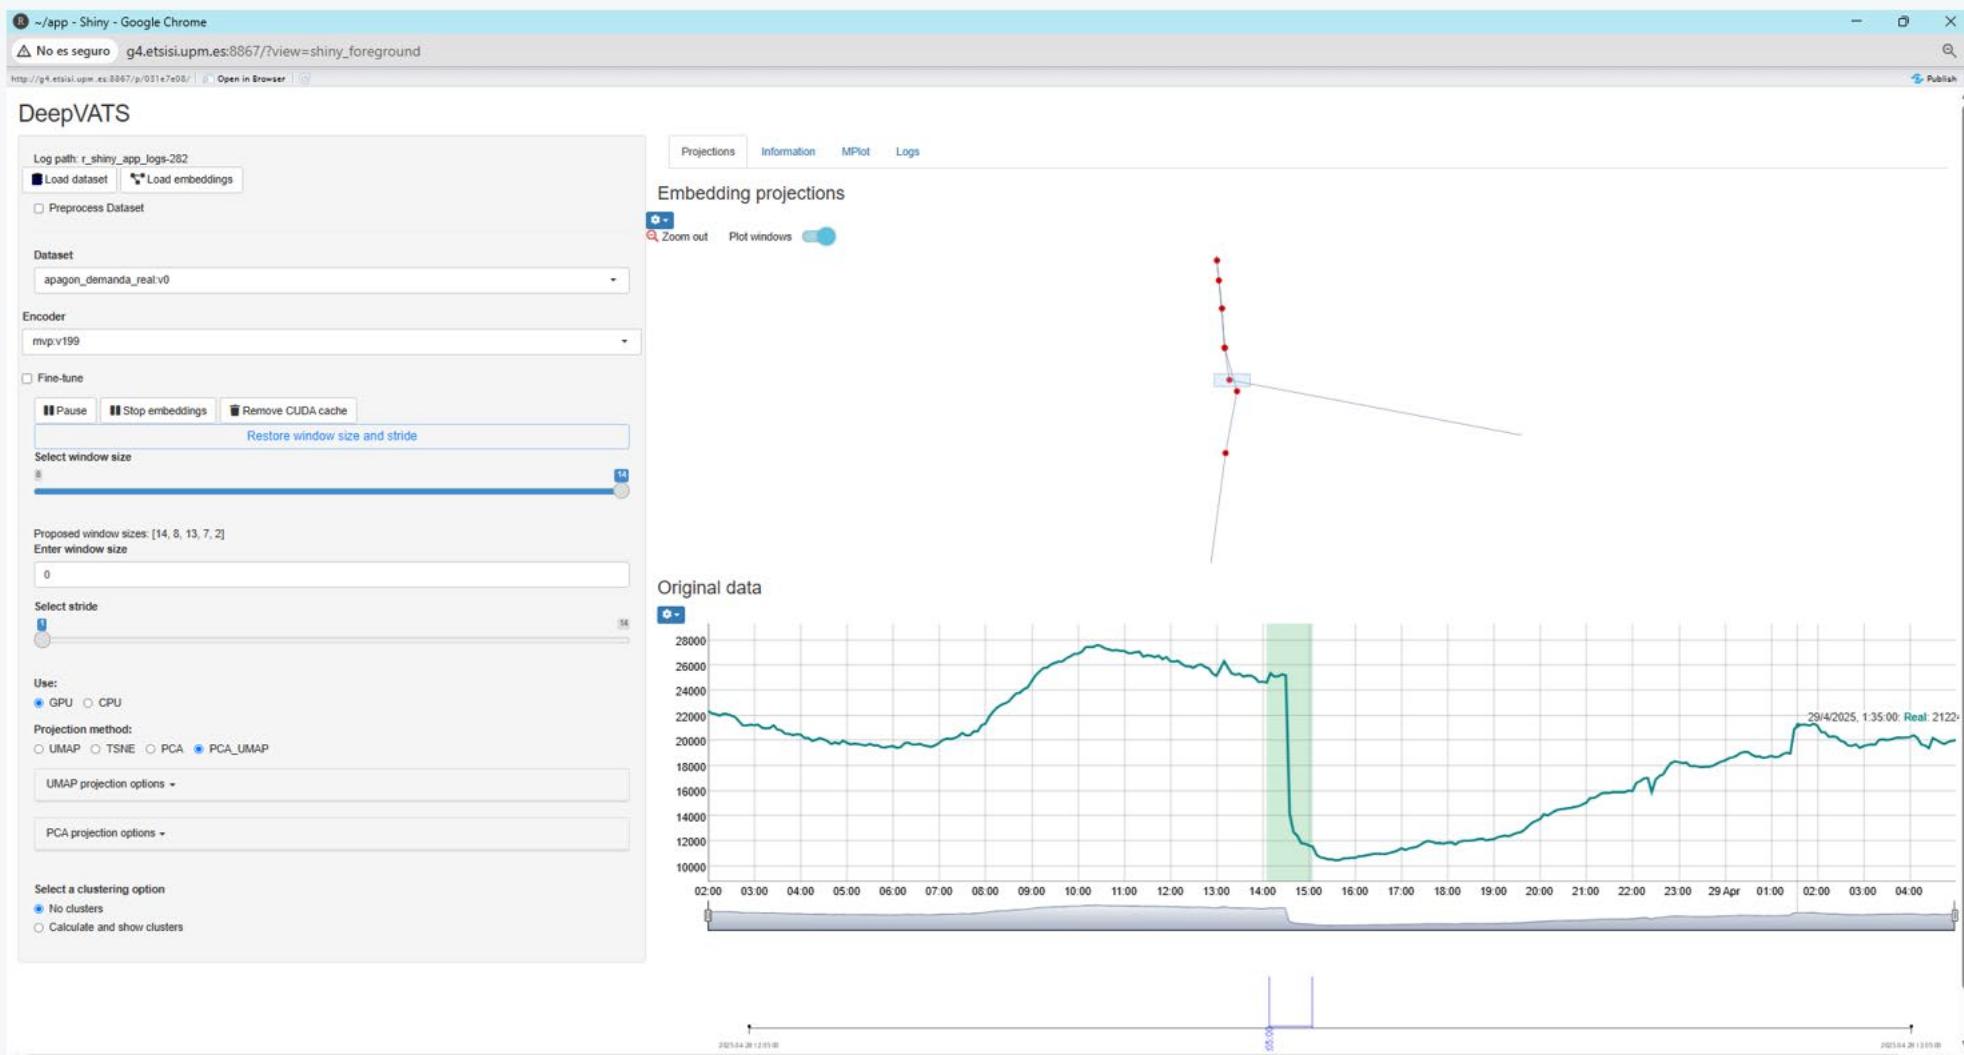
# Caso de uso | Segmentación y anomalías | Univariable



Zoom  
Izquierda



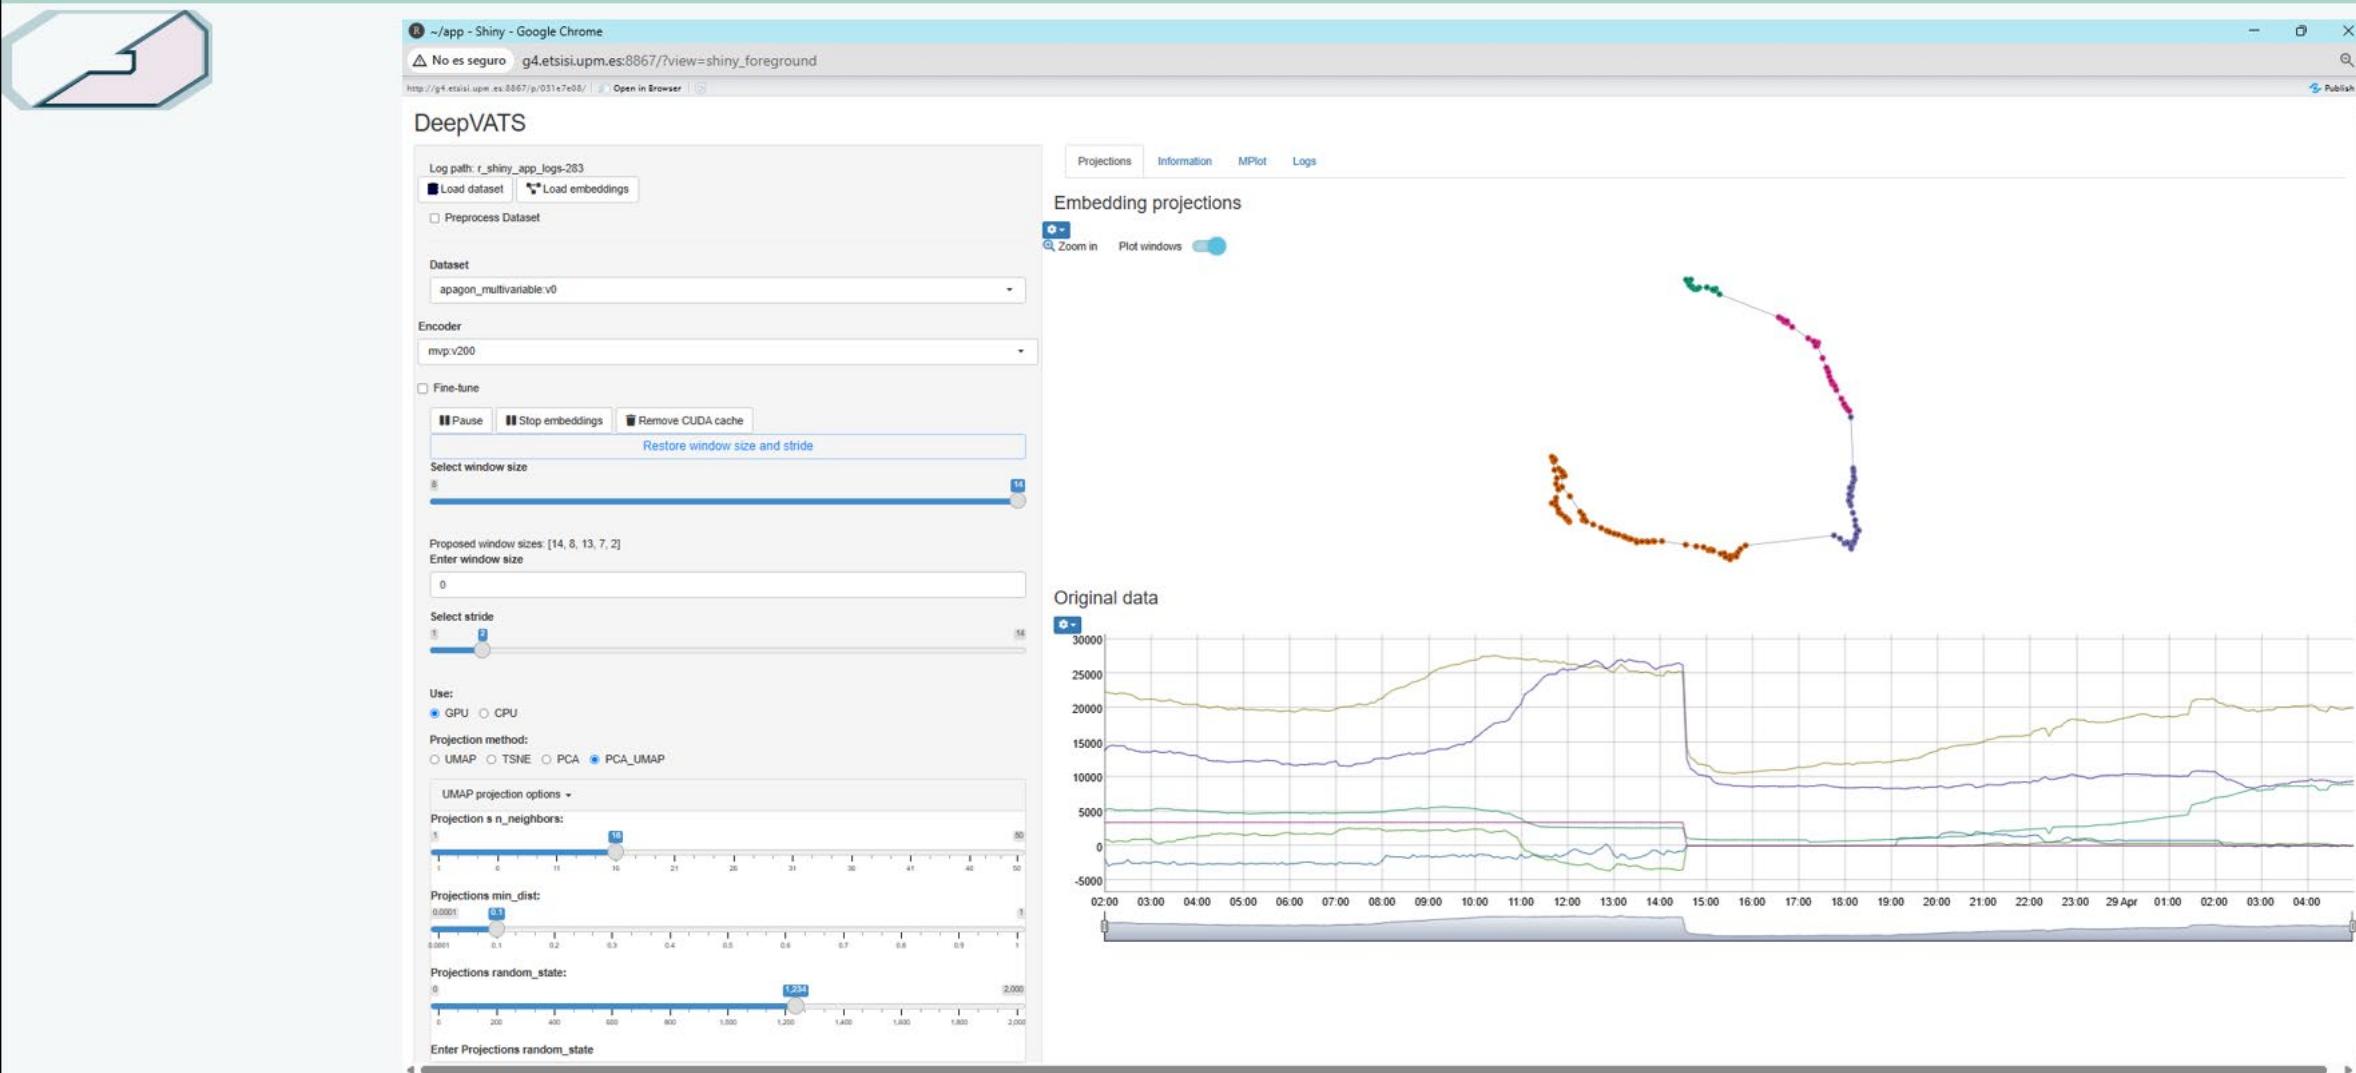
# Caso de uso | Segmentación y anomalías | Univariable



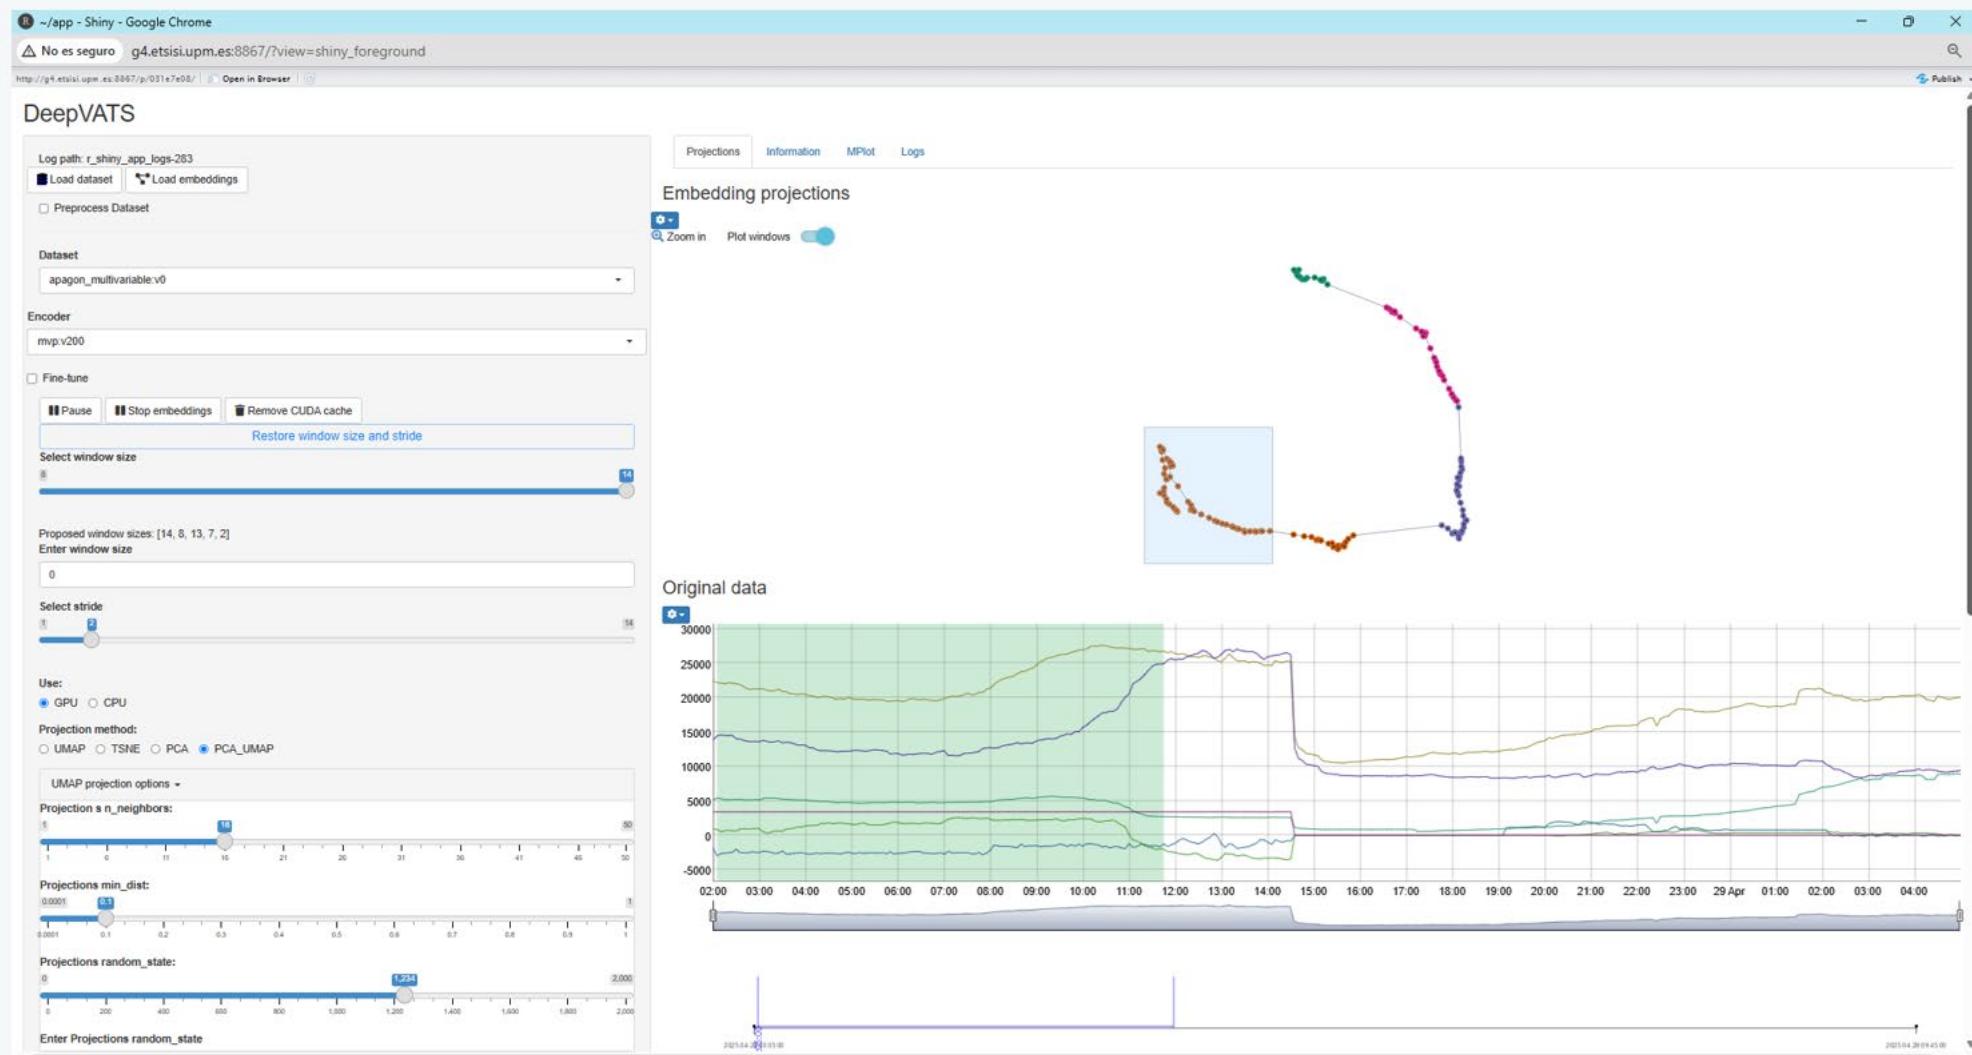
Momento  
del  
apagón



# Caso de uso | Segmentación y anomalías | Multivariable

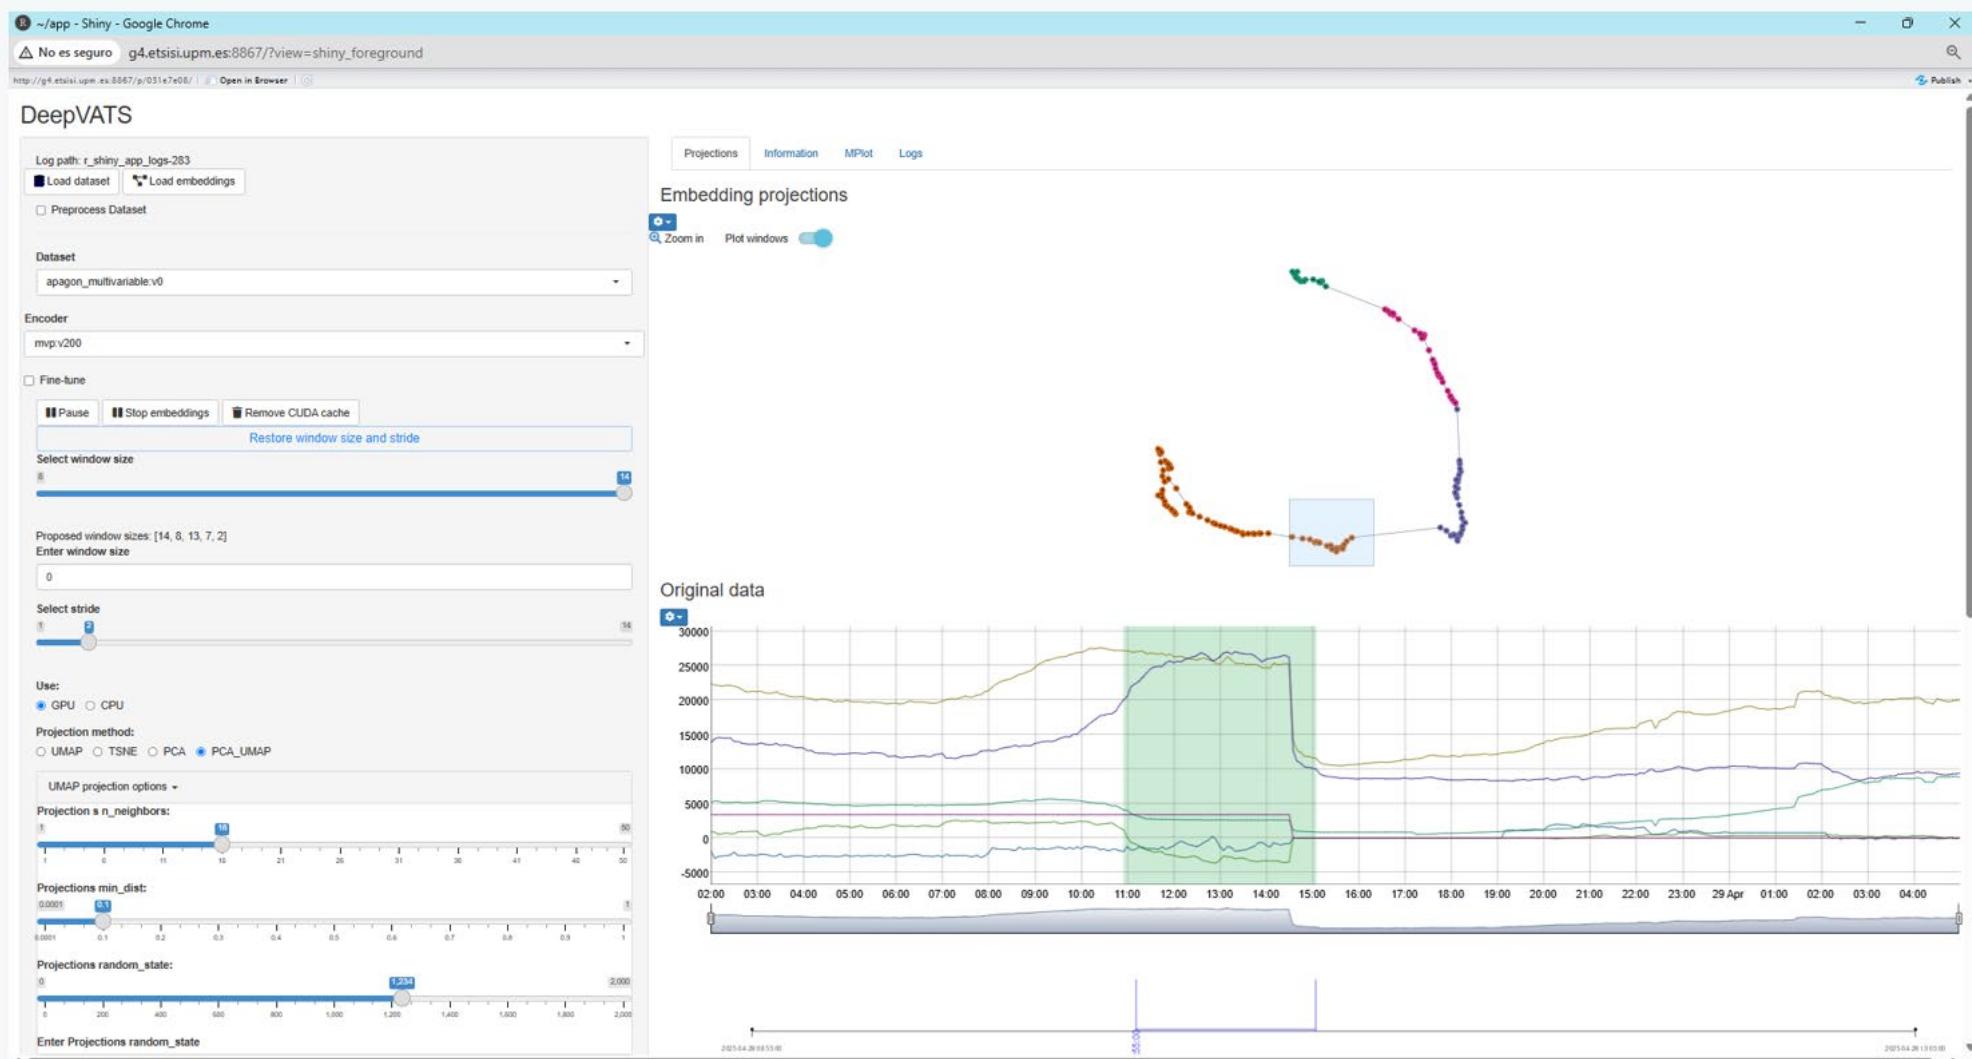


# Caso de uso | Segmentación y anomalías | Multivariable



Flujo habitual

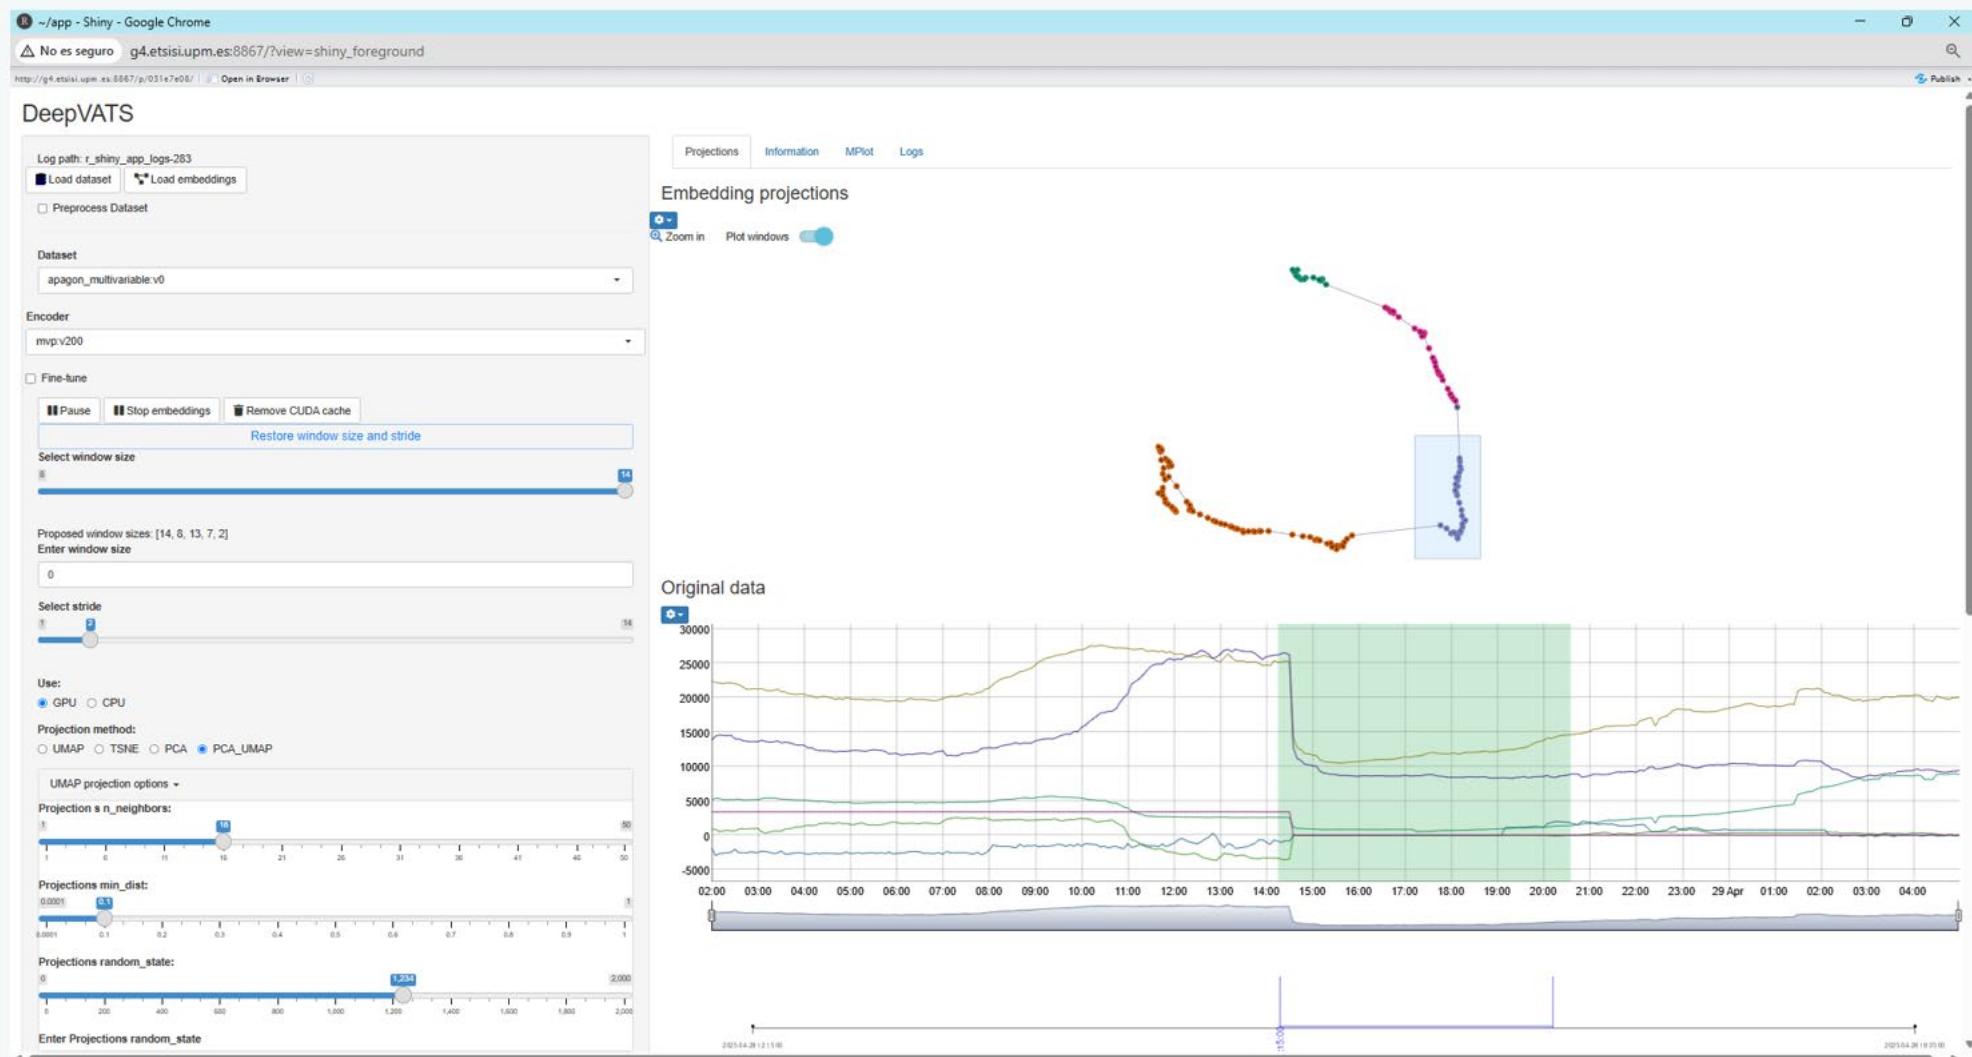
# Caso de uso | Segmentación y anomalías | Multivariable



Pico de  
renovables

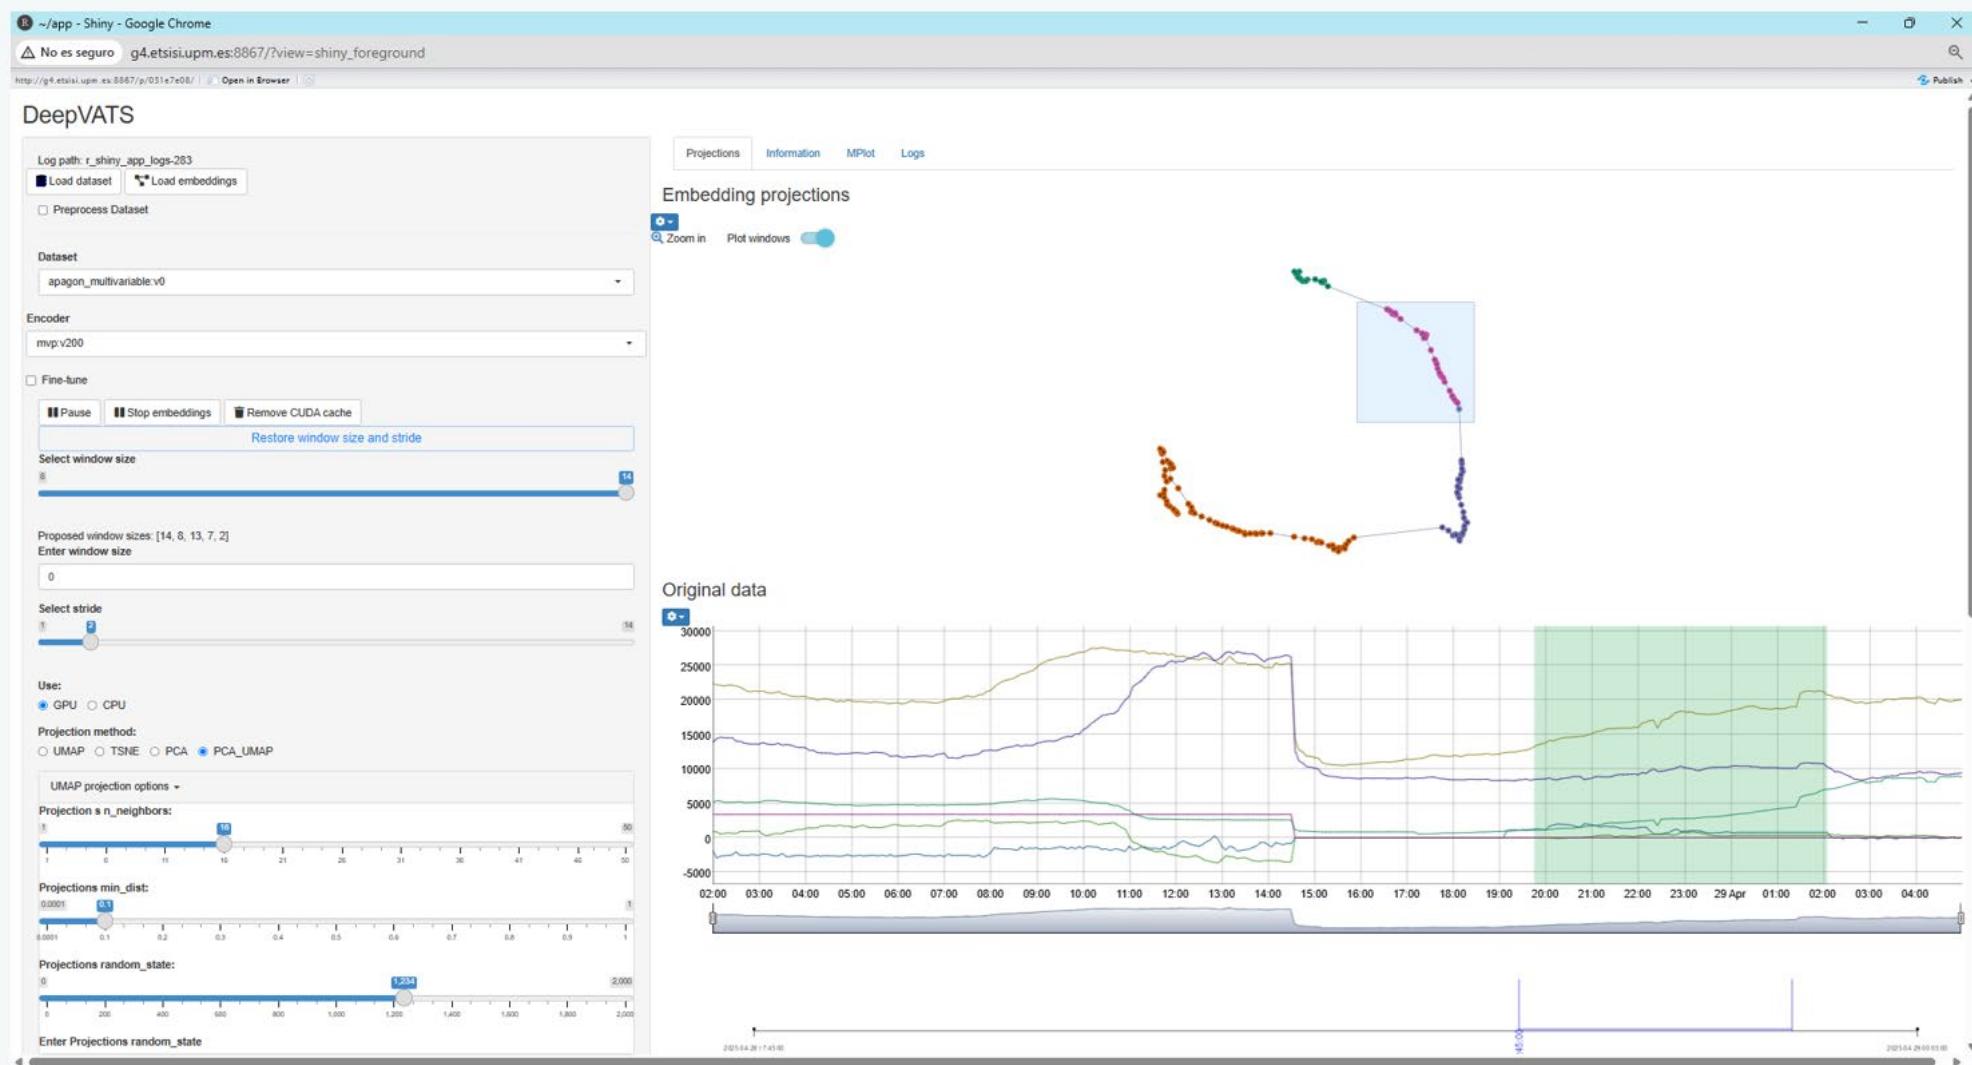


# Caso de uso | Segmentación y anomalías | Multivariable



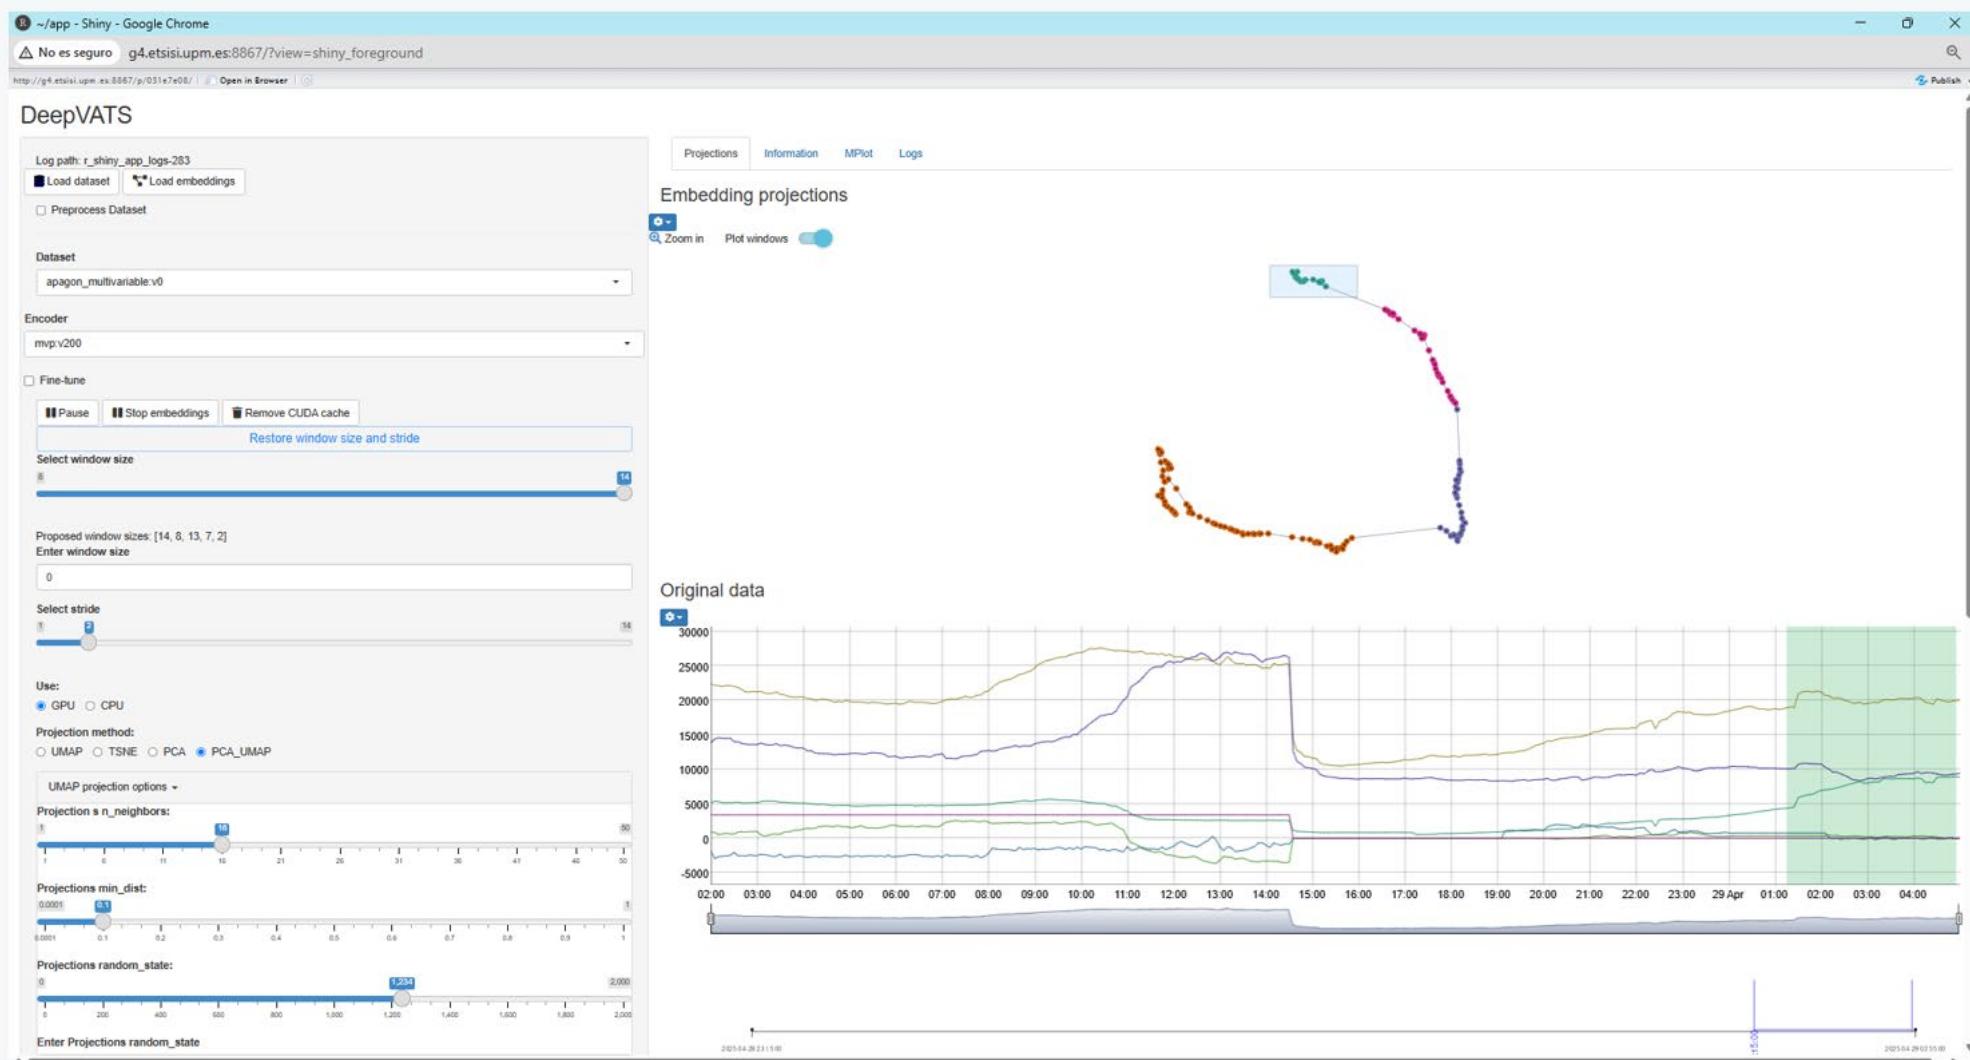
Bloqueo

# Caso de uso | Segmentación y anomalías | Multivariable



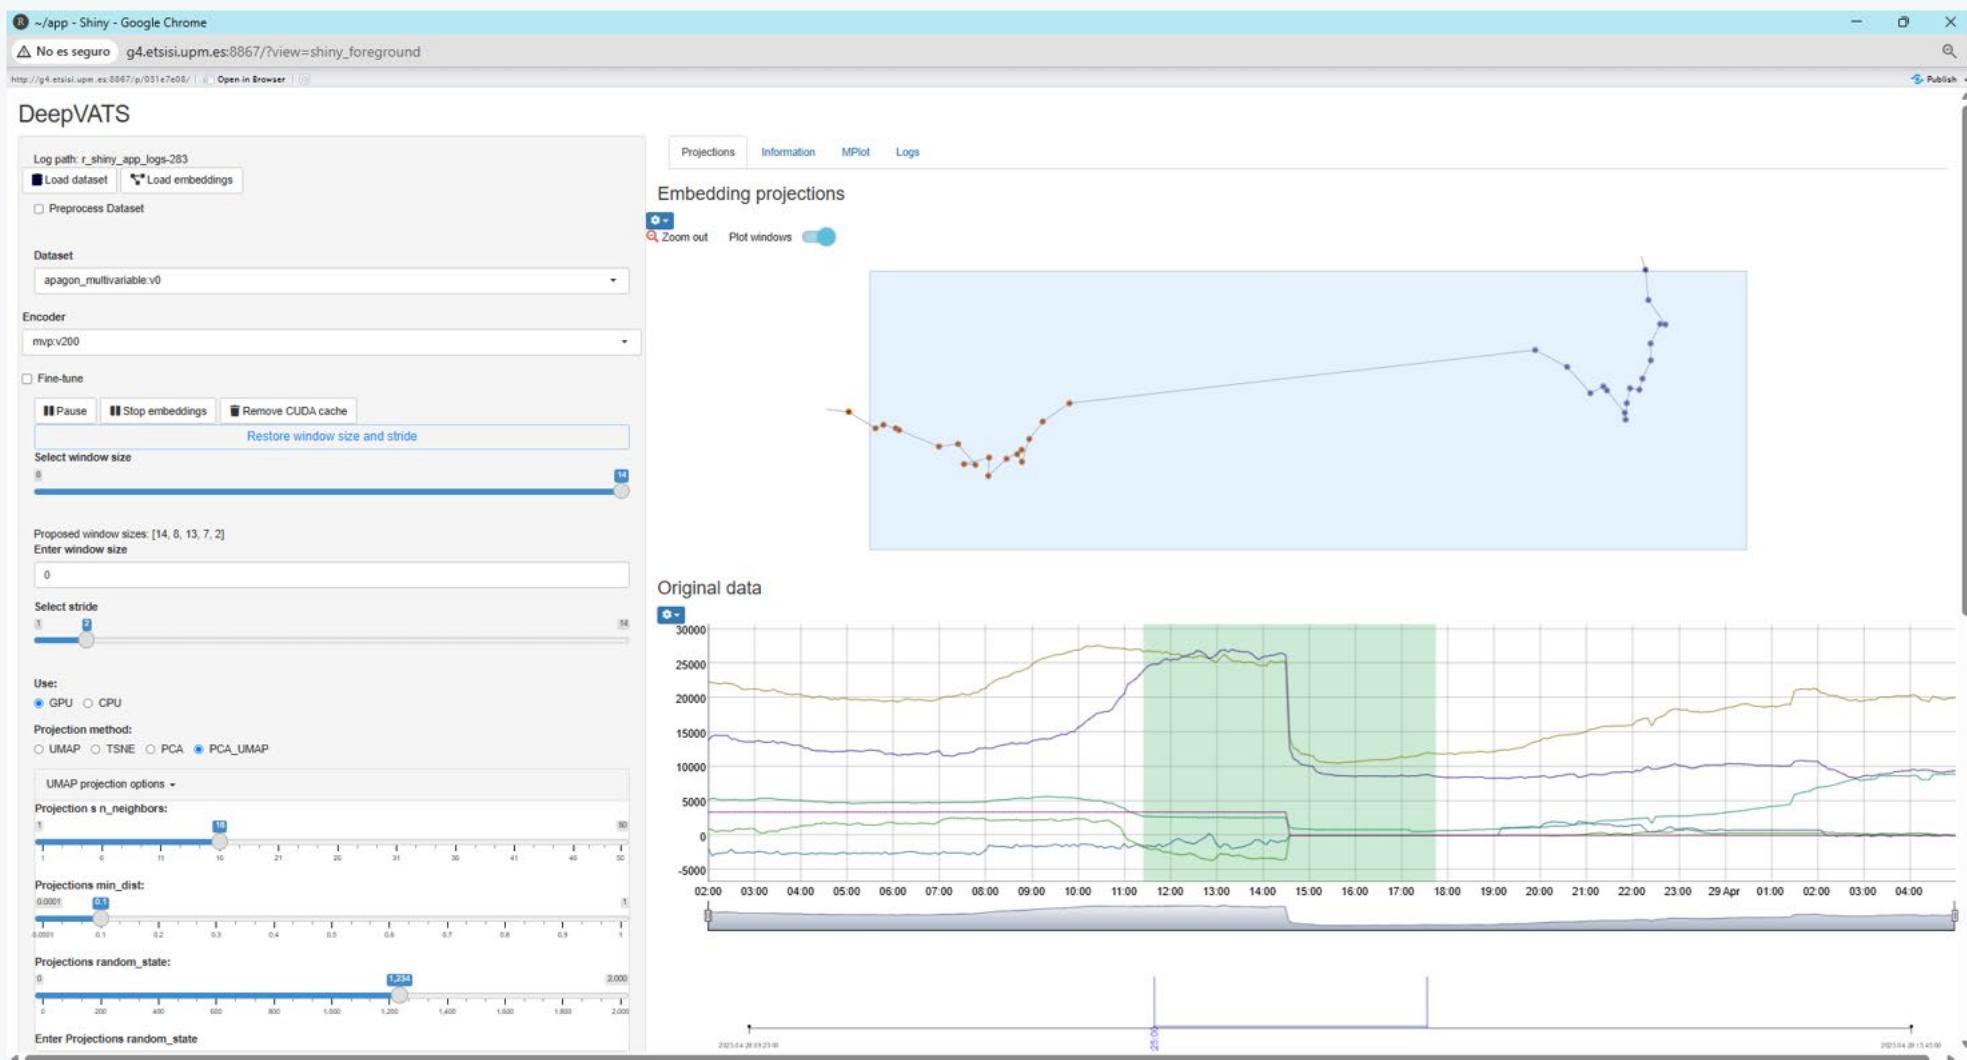
Recuperación

# Caso de uso | Segmentación y anomalías | Multivariable



Estabilización

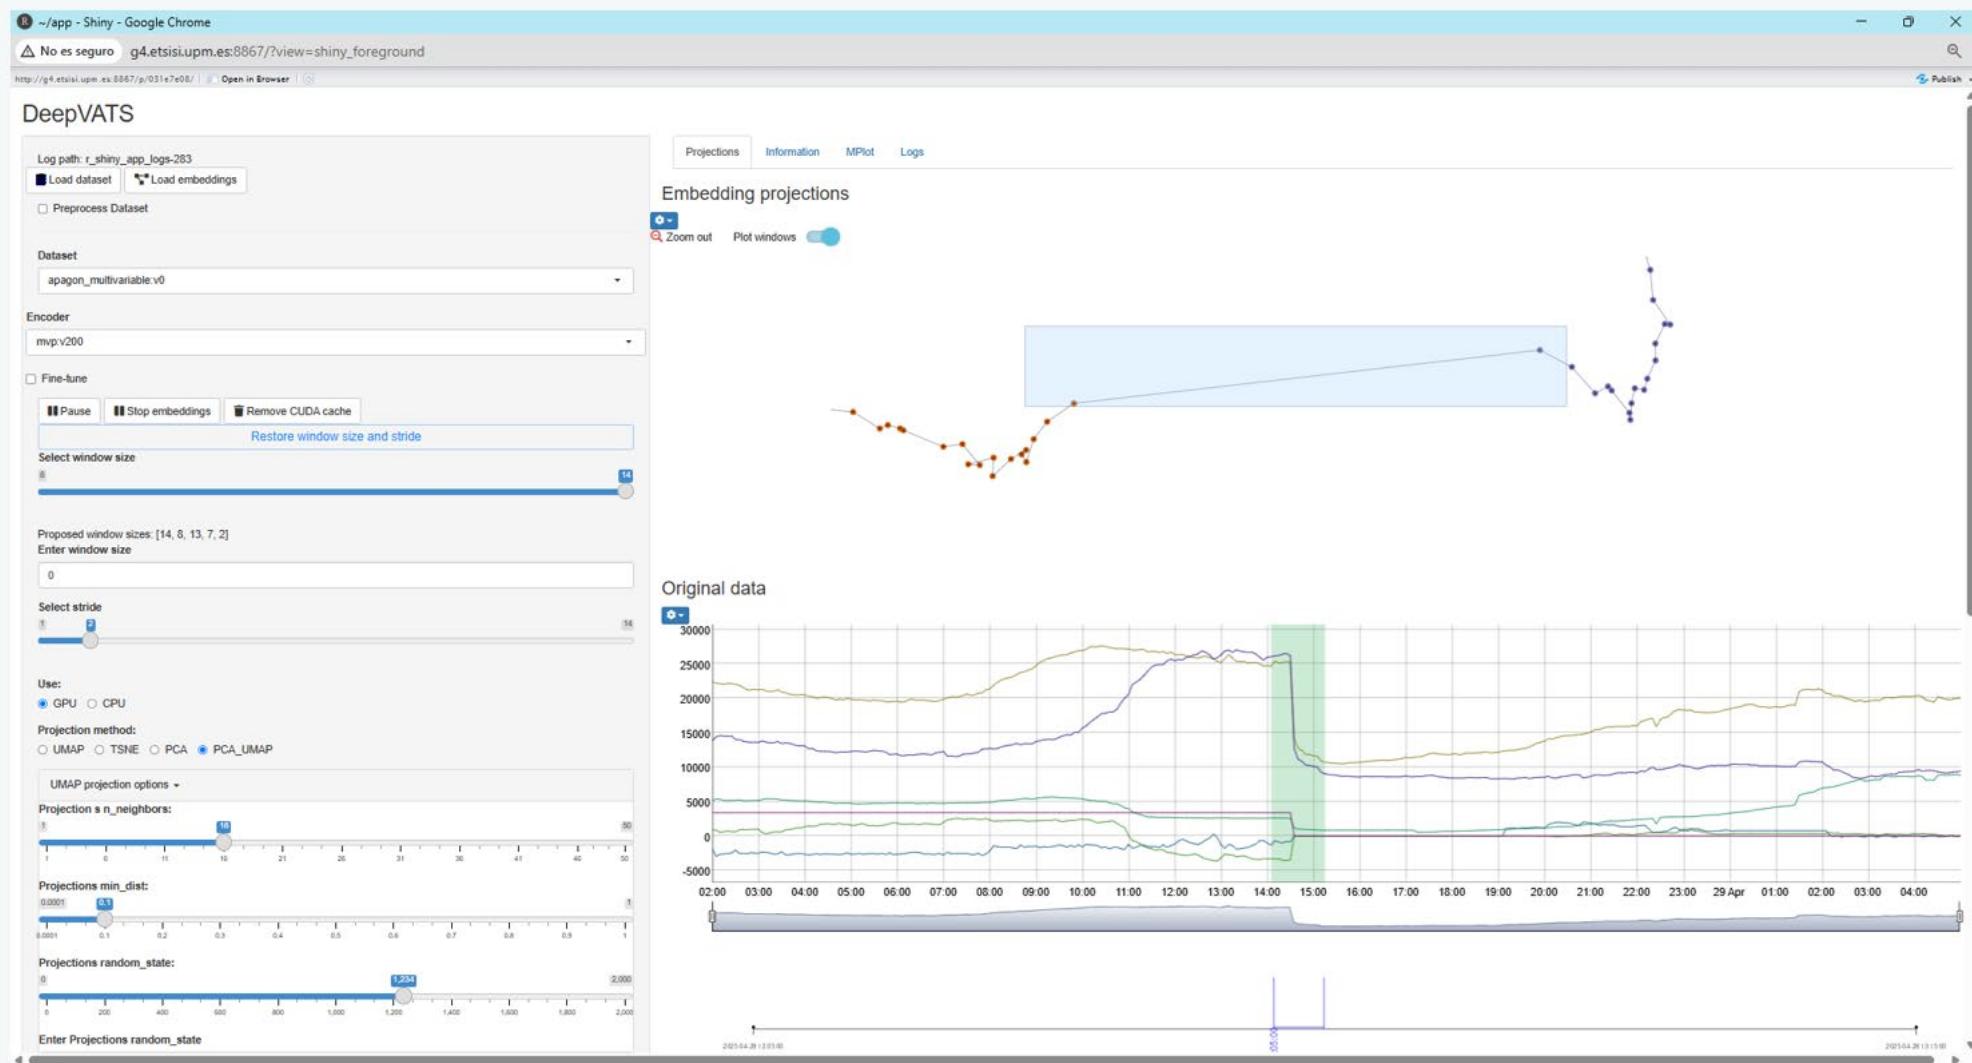
# Caso de uso | Segmentación y anomalías | Multivariable



Acerquémonos a  
la zona del  
apagón



# Caso de uso | Segmentación y anomalías | Multivariable

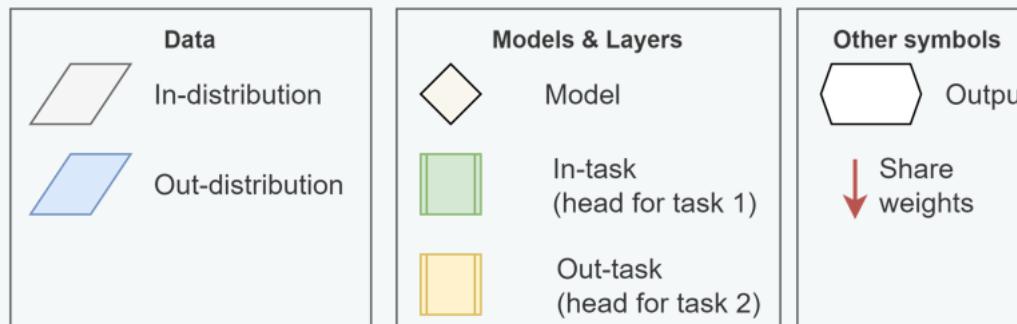
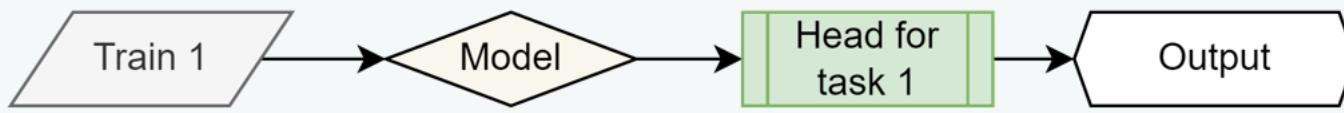


Apagón

# Análisis Visual basado en DL | Modelos pre-entrenados 1/3



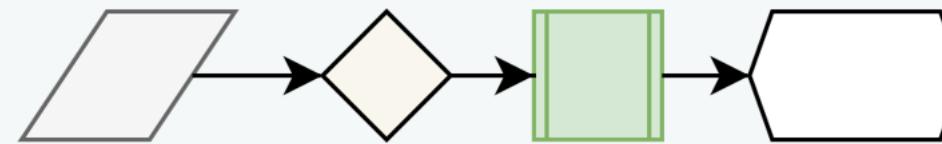
Entrenamiento  
+ Inferencia  
clásico



# Análisis Visual basado en DL | Modelos fundamentales 2/3

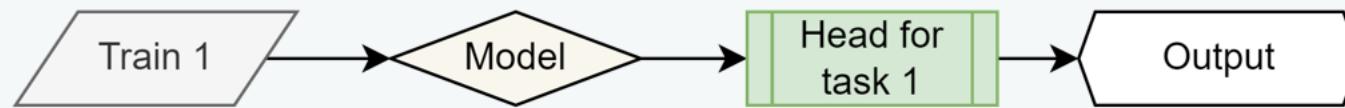


Inferencia directa

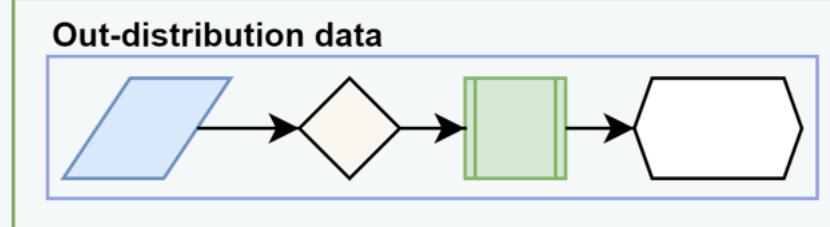


Data	Models & Layers	Other symbols
In-distribution	Model	Output
Out-distribution	In-task (head for task 1)	Share weights
	Out-task (head for task 2)	

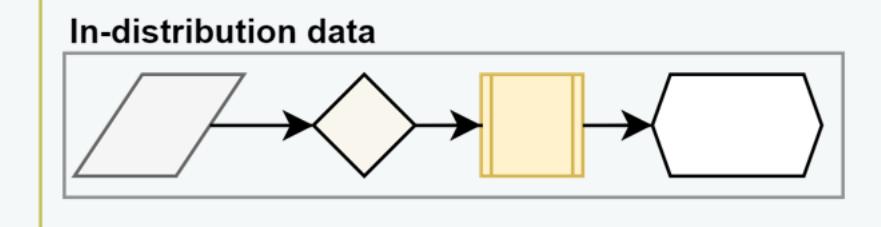
# Análisis Visual basado en DL | Modelos fundamentales 2/3



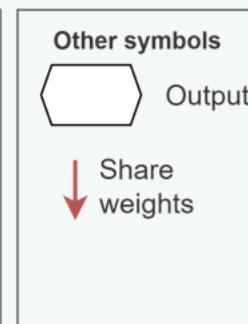
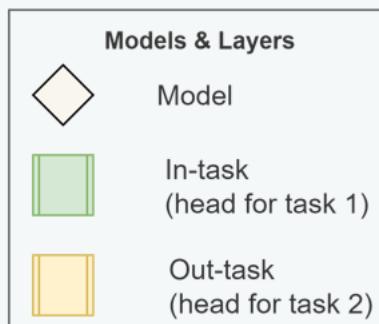
In-task



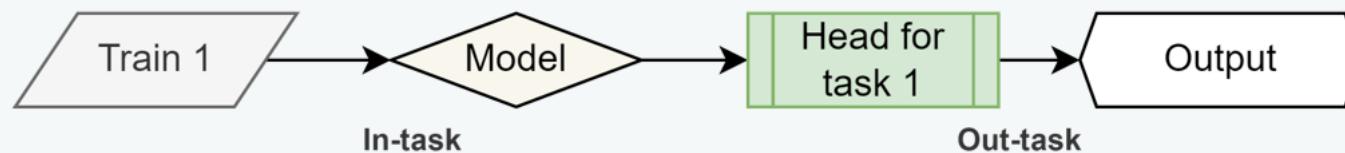
Out-task



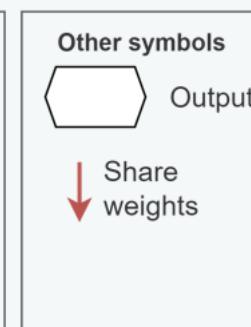
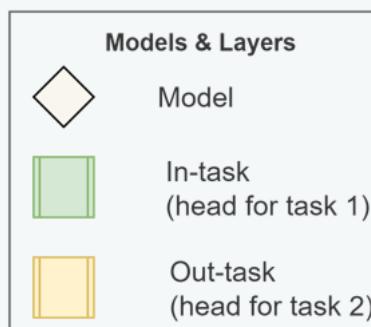
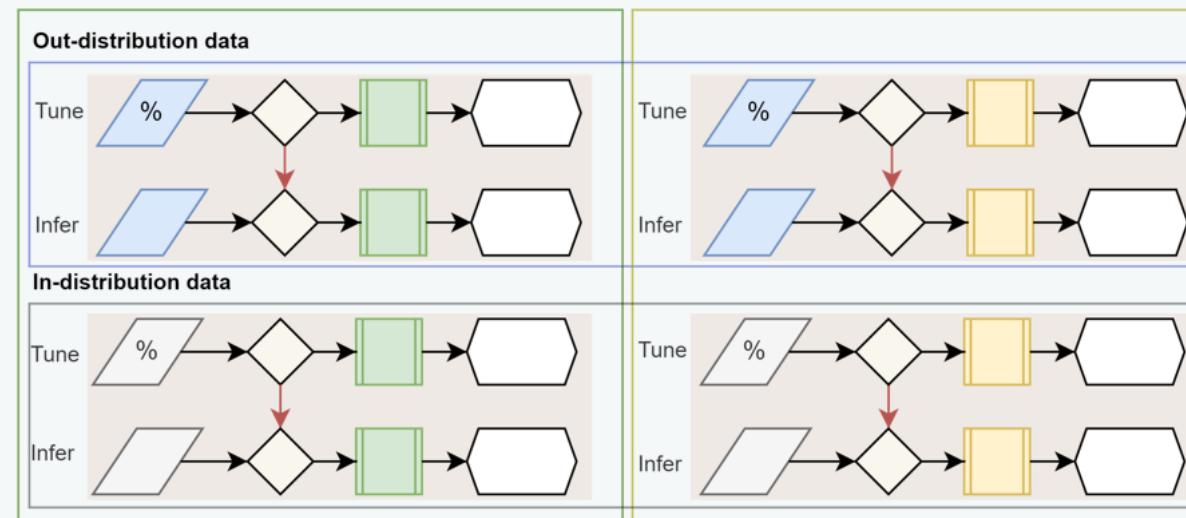
Inferencia zero-shot



Análisis Visual basado en DL | Modelos fundacionales 3/3



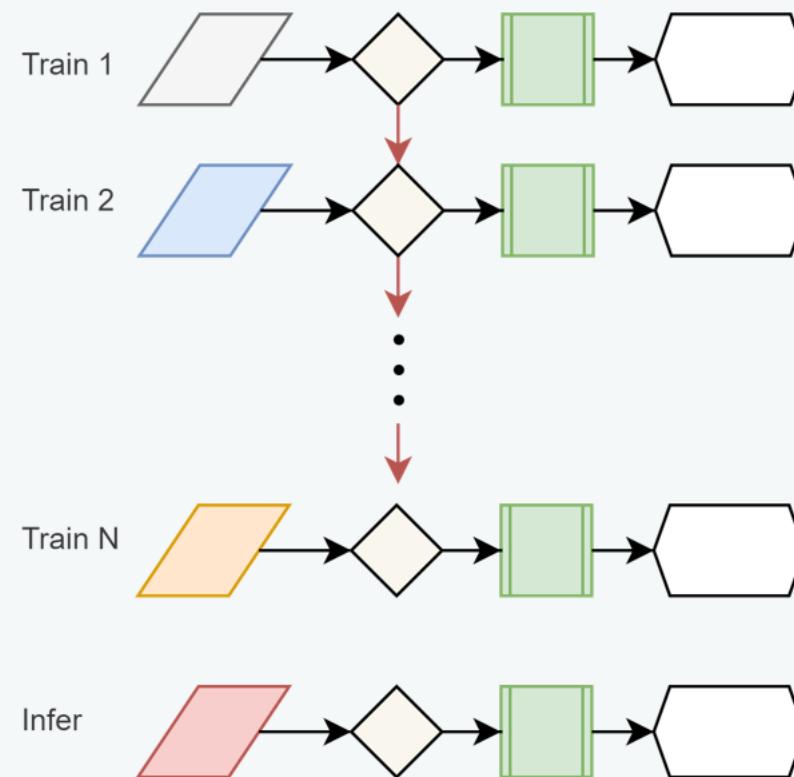
Con ajuste fino



# Análisis Visual basado en DL | Modelos fundacionales 1/2



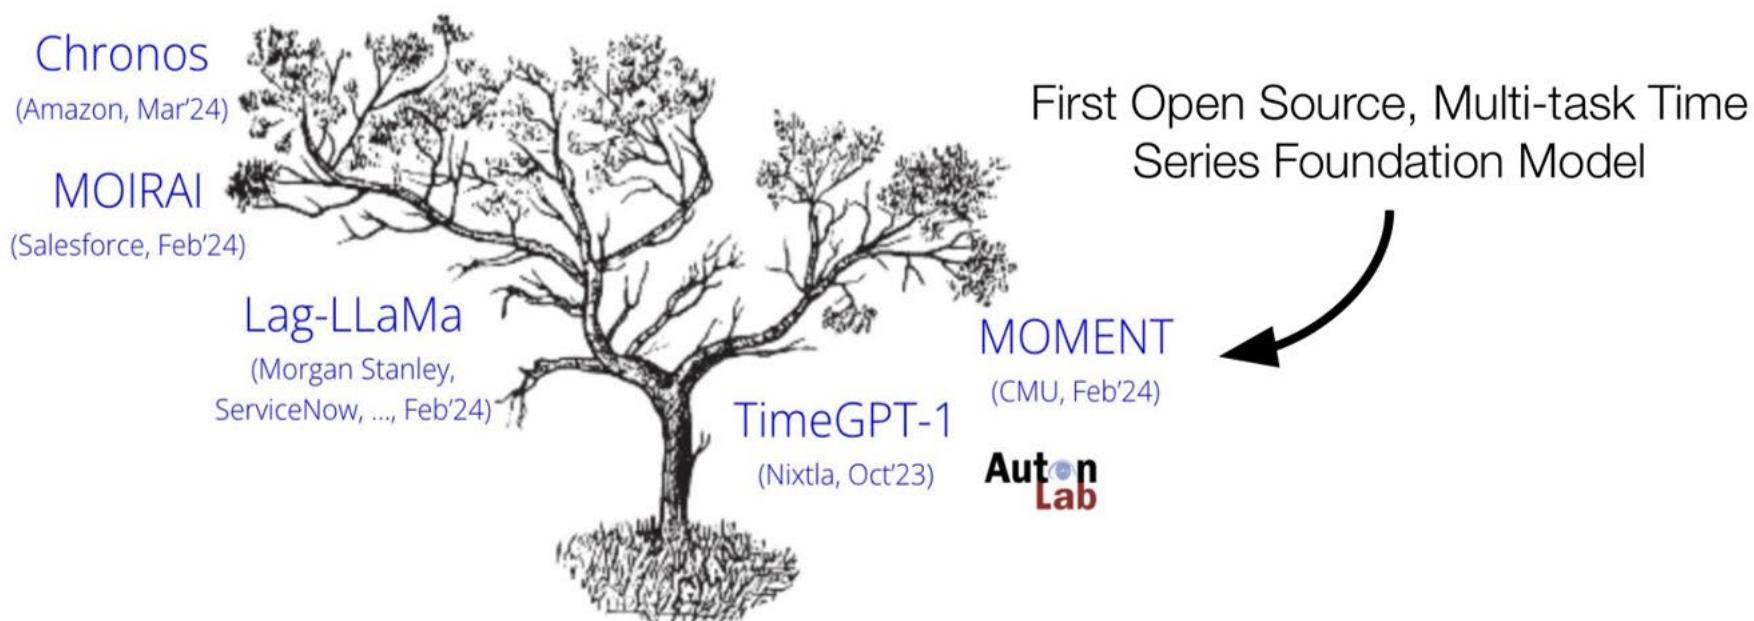
## Zero-shot inference o Fine-tuning



# Análisis Visual basado en DL | Modelos fundacionales 2/2



## Time Series Foundation Models

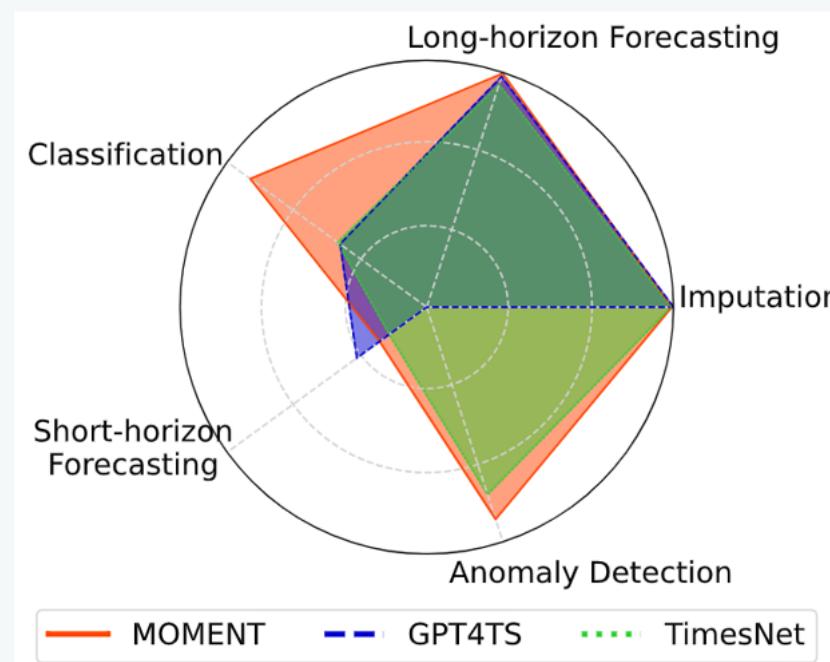


Most influential foundational models published, ordered from bottom top in chronological order and with the AutonLab branch to the right.

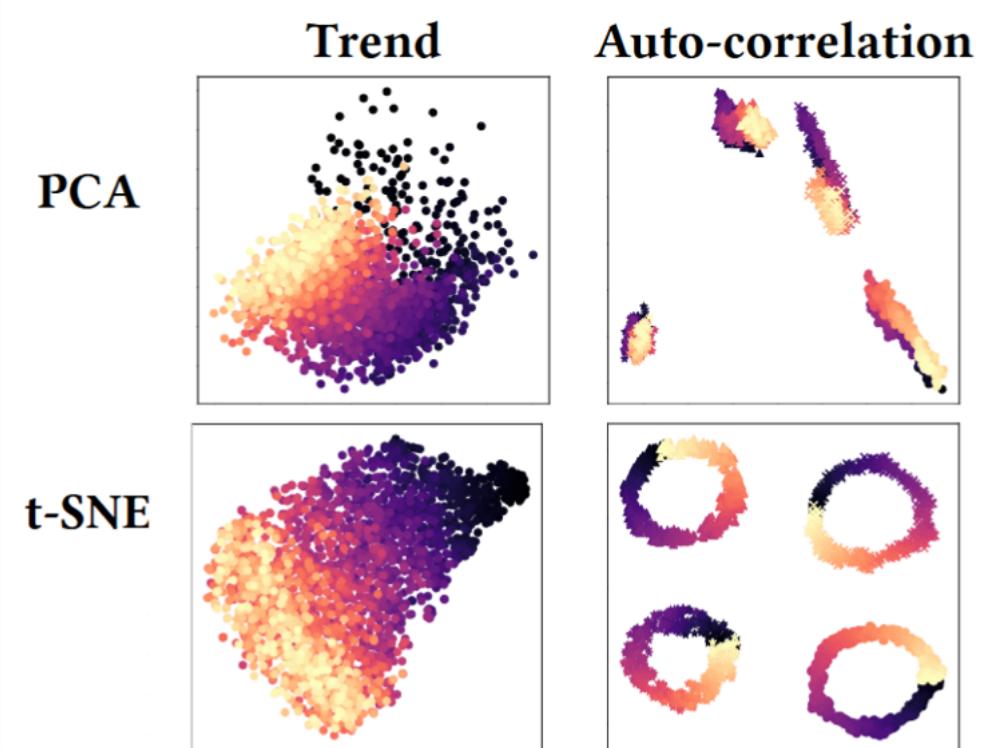
# MOMENT 1/3



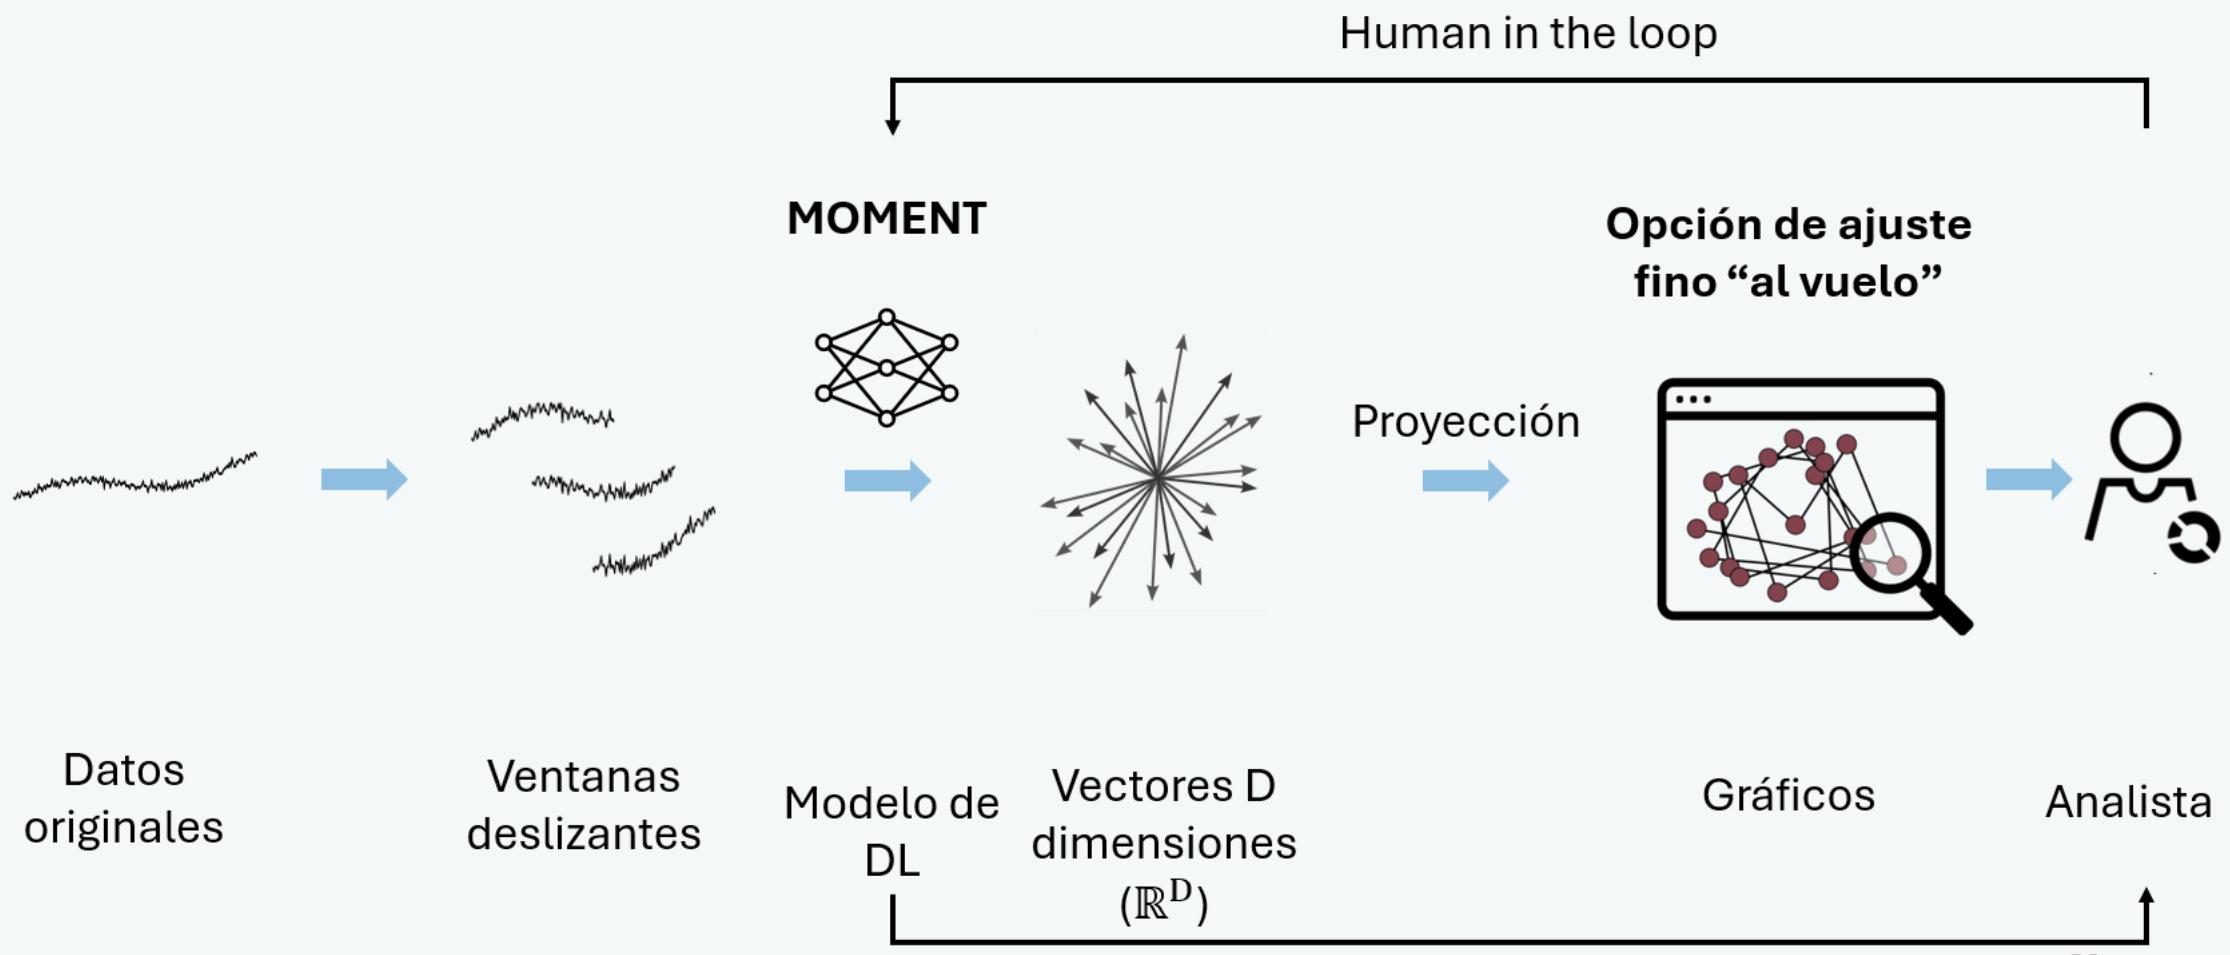
## Modelo fundacional multitarea



Afirman que **captura comportamientos en el espacio latente**



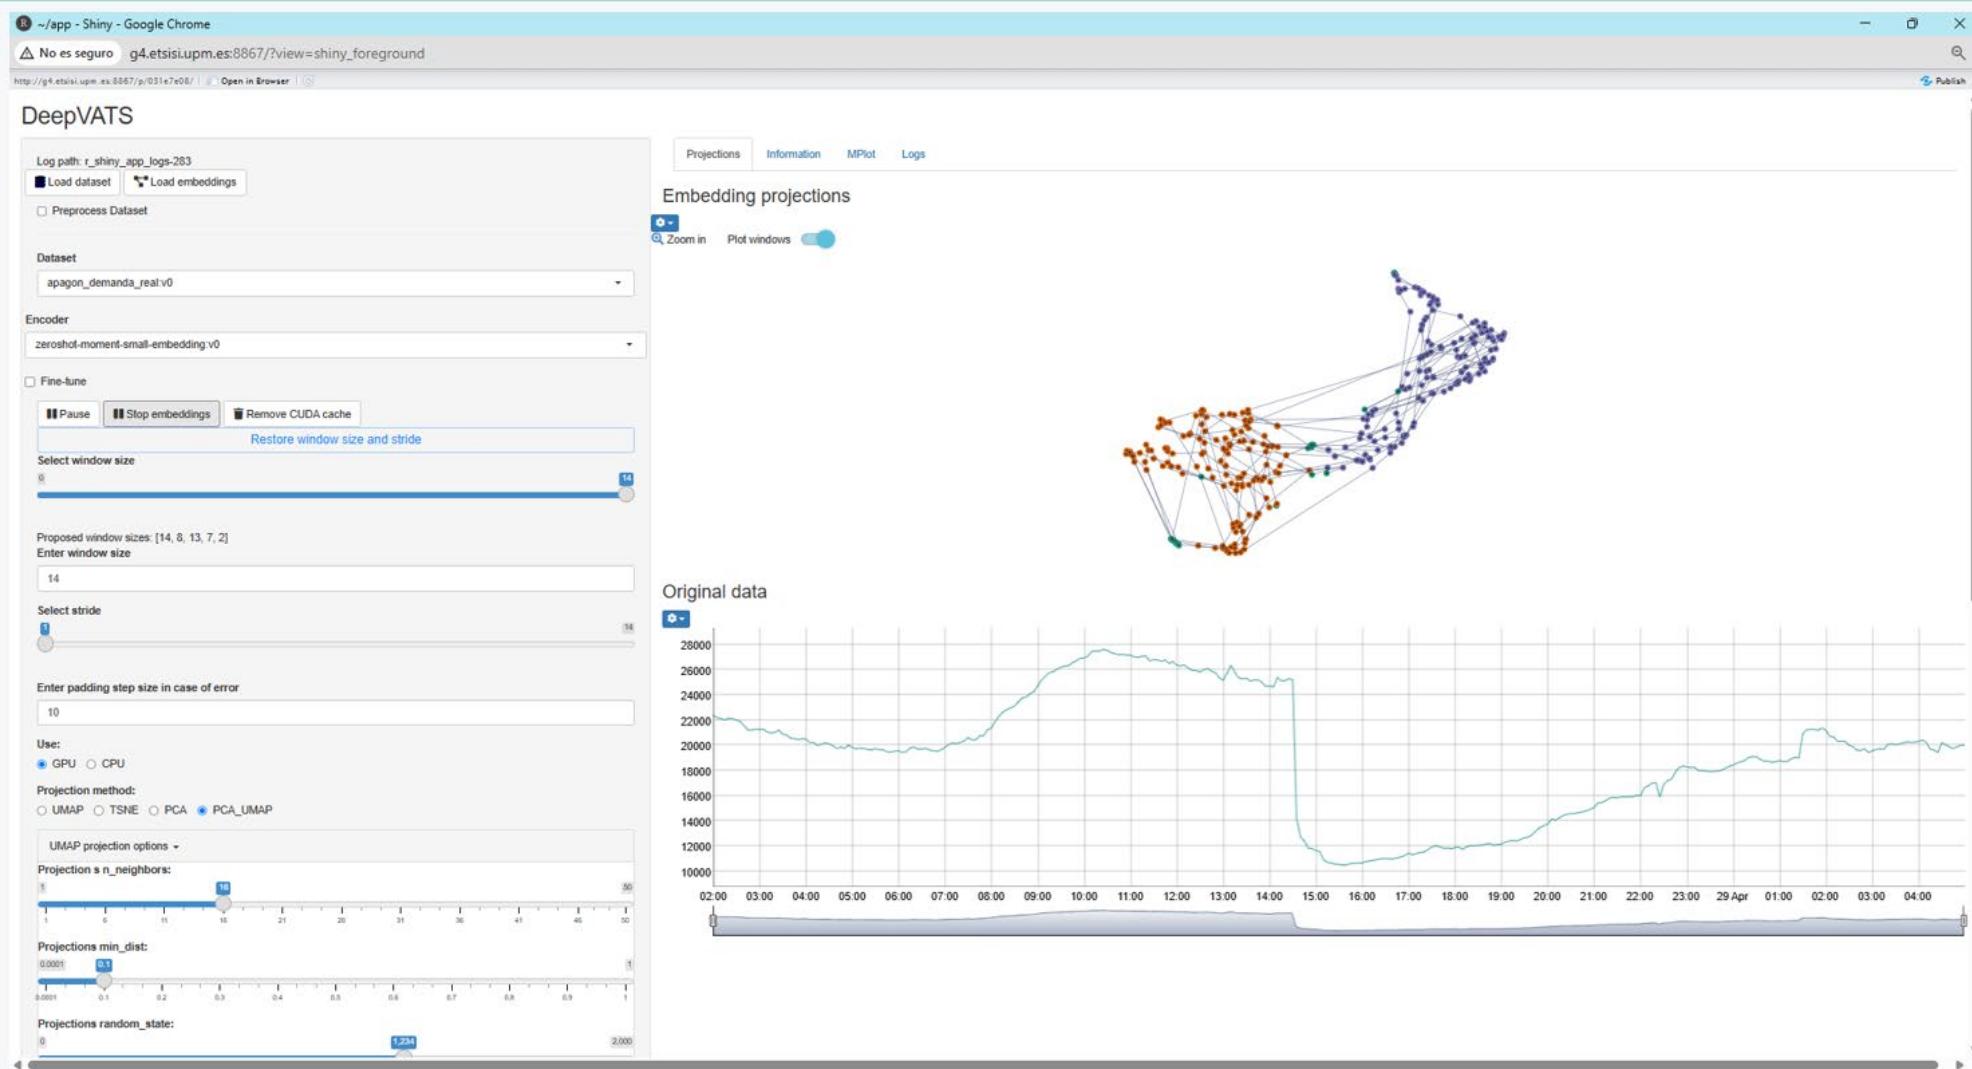
# MOMENT 2/3



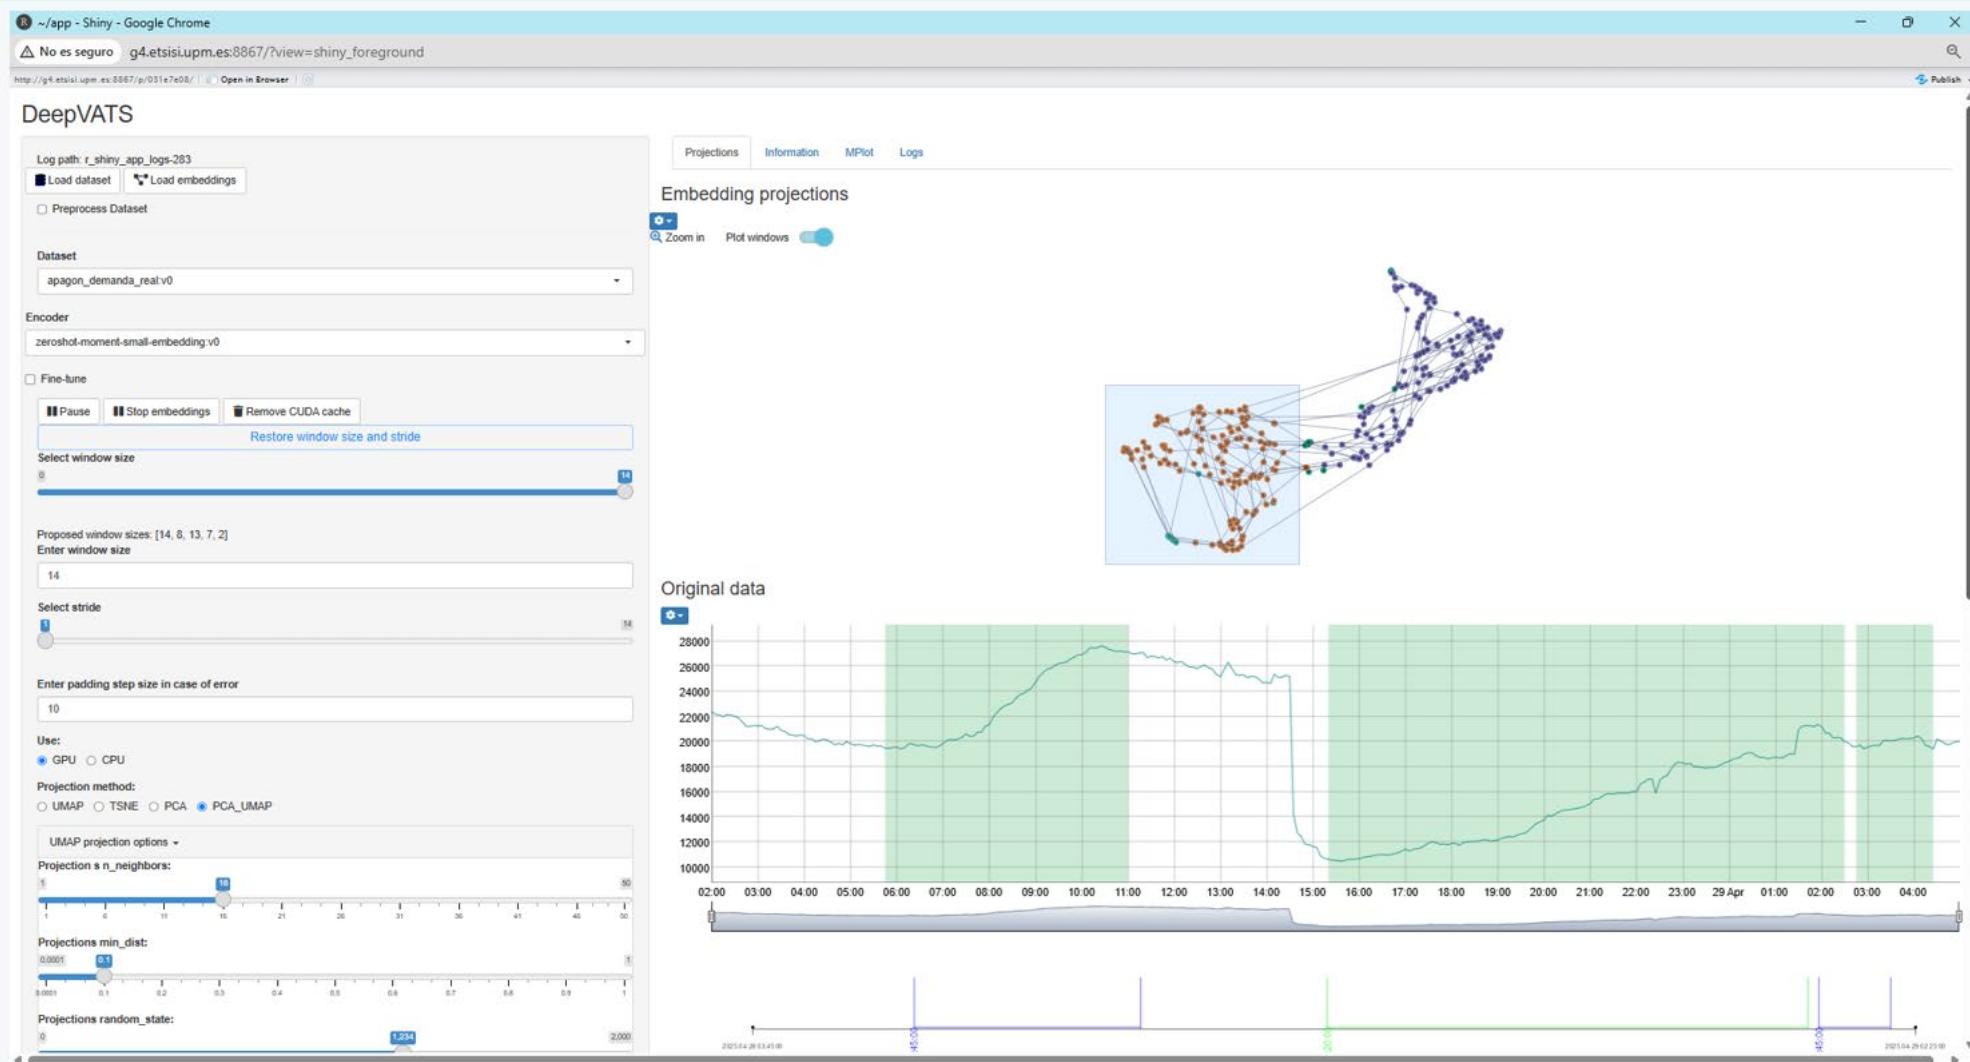
# MOMENT 3/3

Modelo	Capas	Dimensión oculta (D)	Parámetros ( $\approx$ )
MOMENT-Small	8	512	$\approx 38$ M
MOMENT-Base	12	768	$\approx 113$ M
MOMENT-Large	24	1024	$\approx 346$ M
MTSAE	6	128	$\approx 457$ K

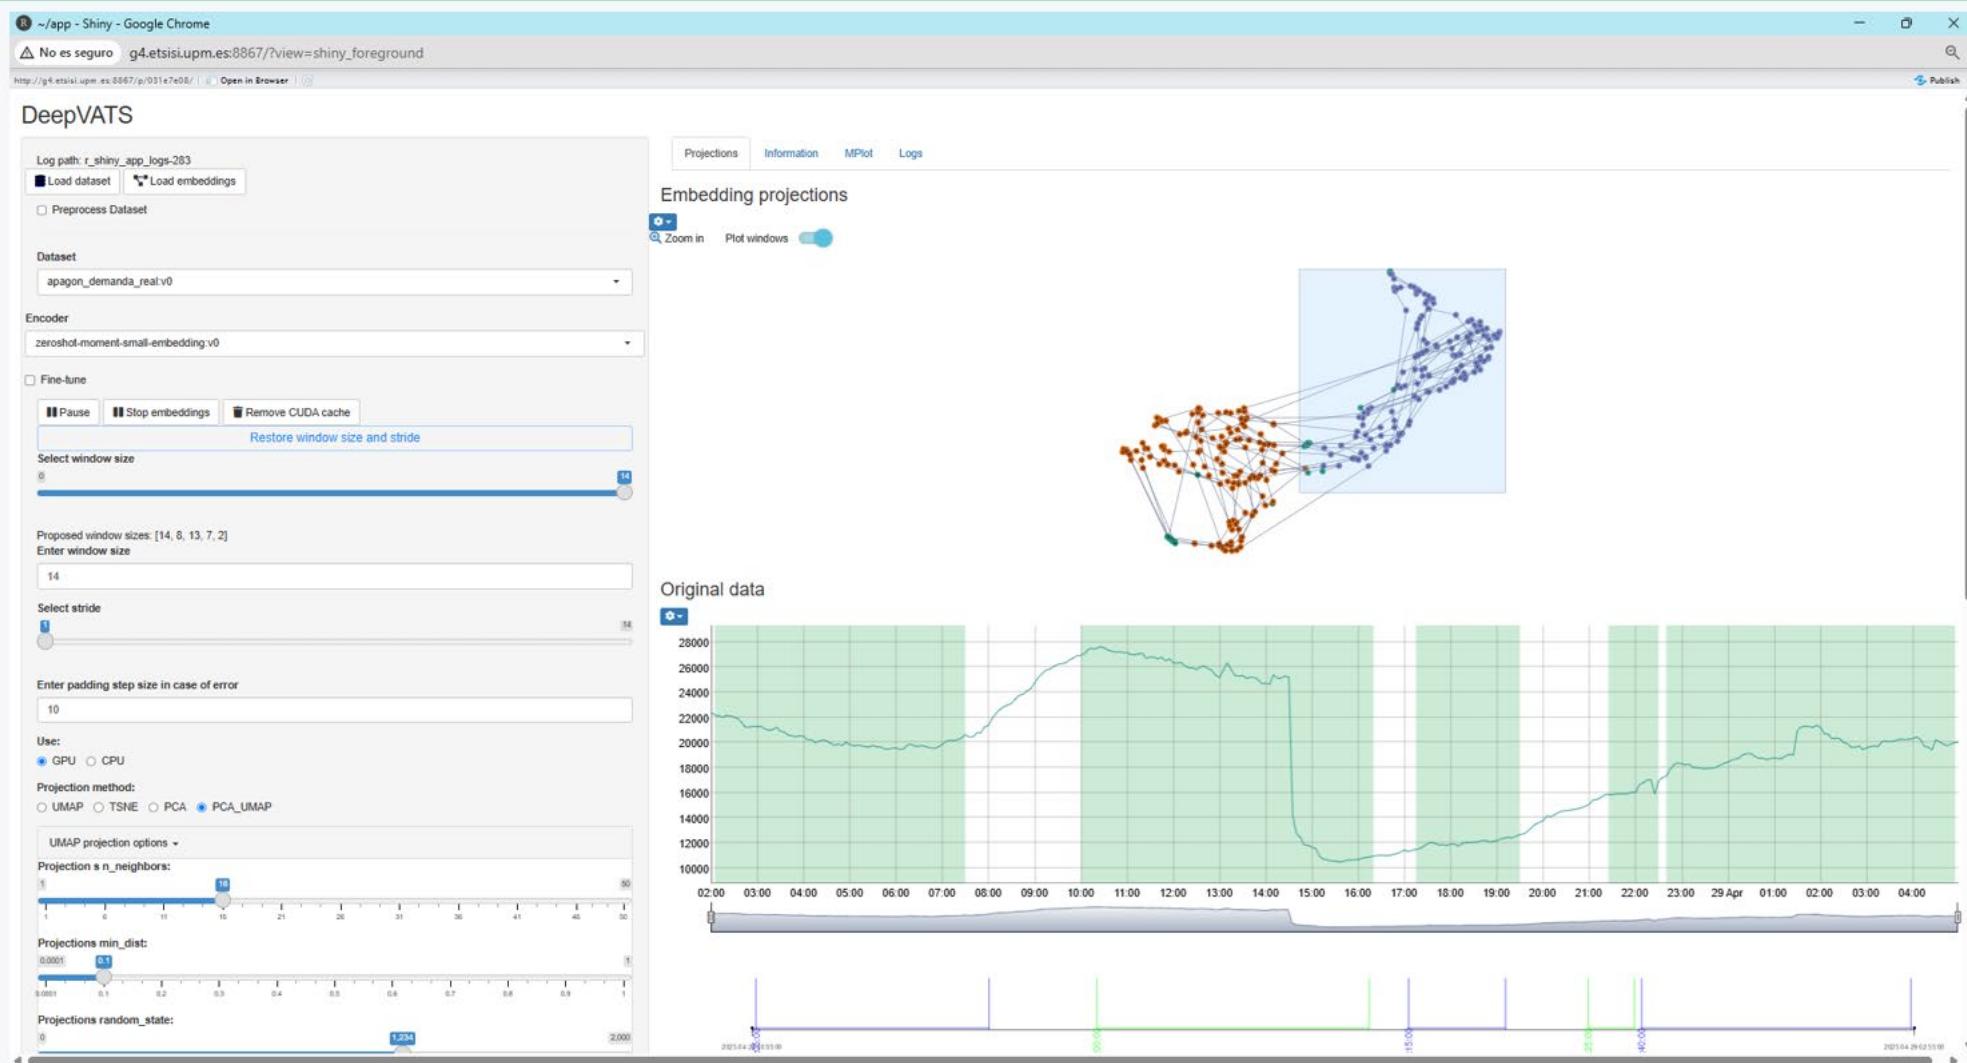
# MOMENT | Caso de uso | Univariable (zero-shot)



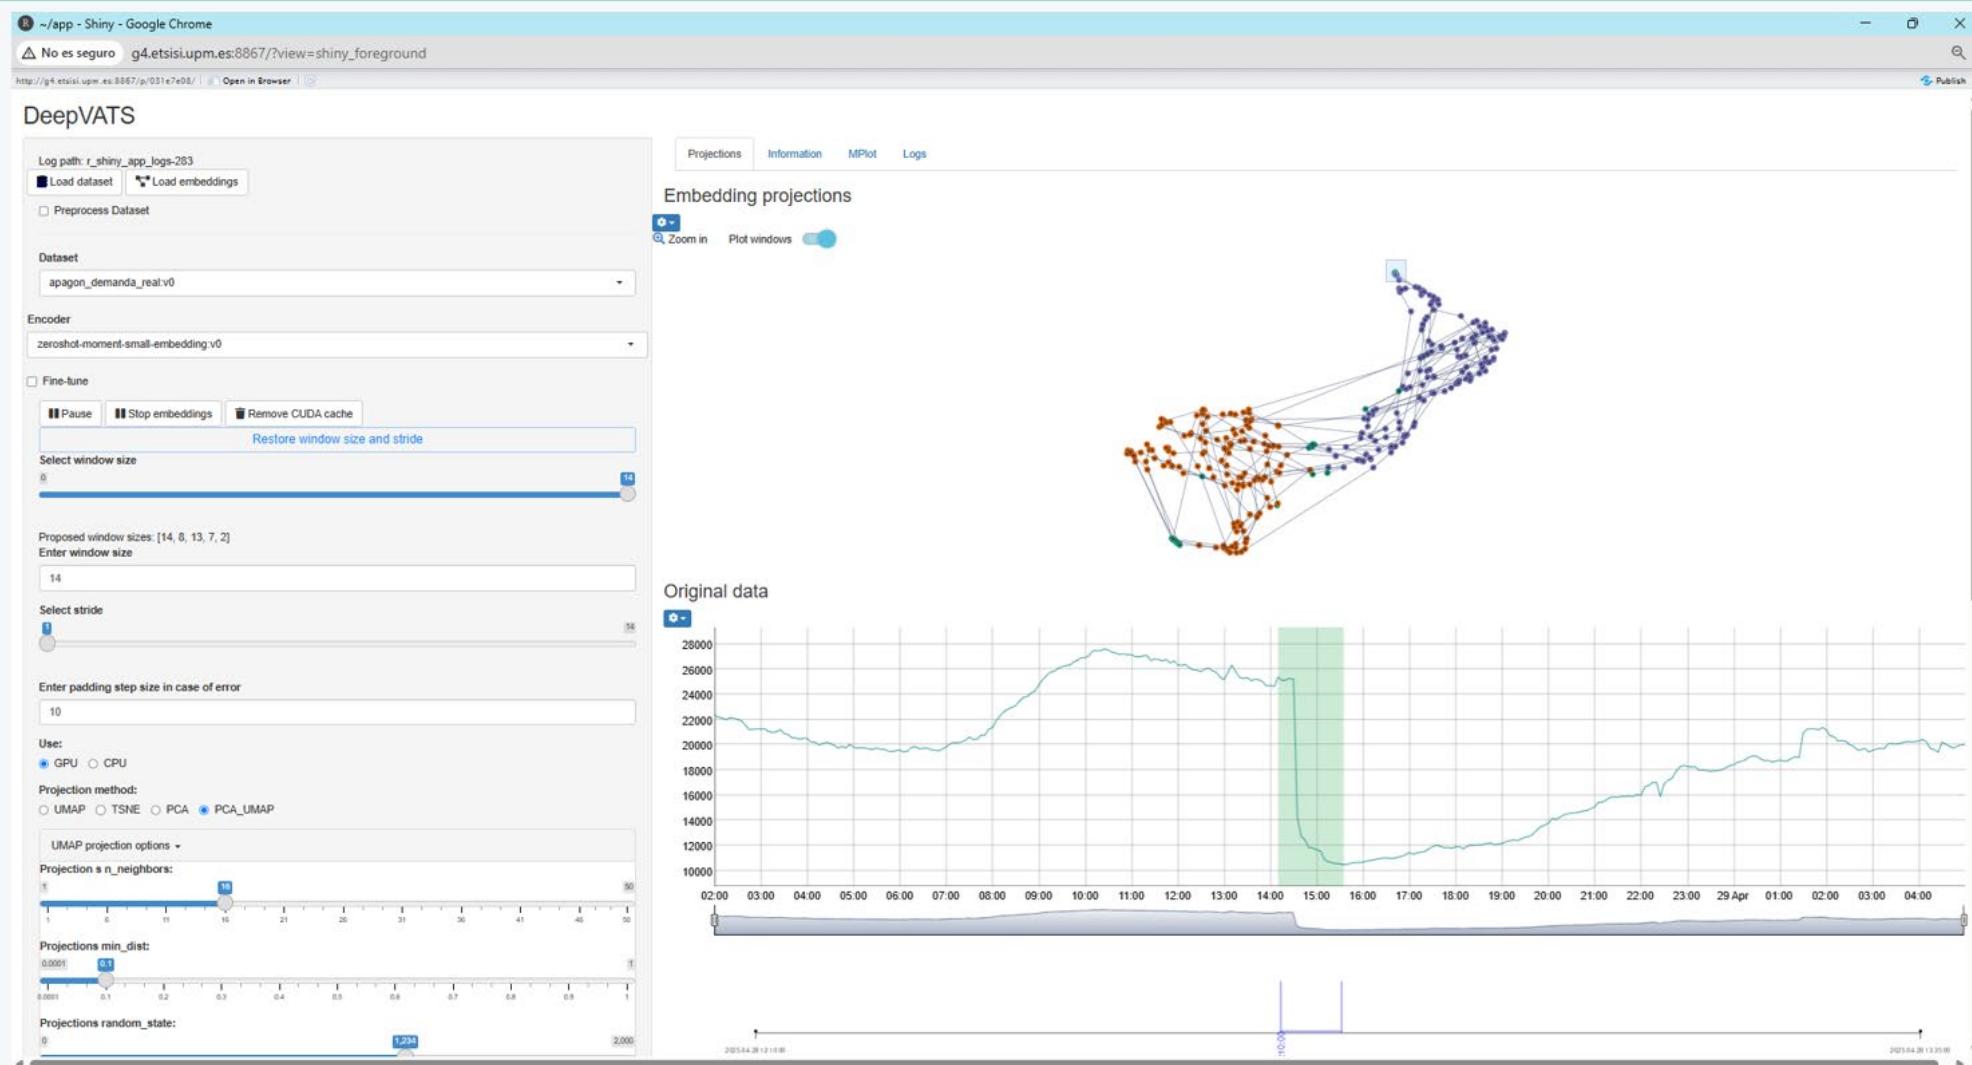
# MOMENT | Caso de uso | Univariable (zero-shot)



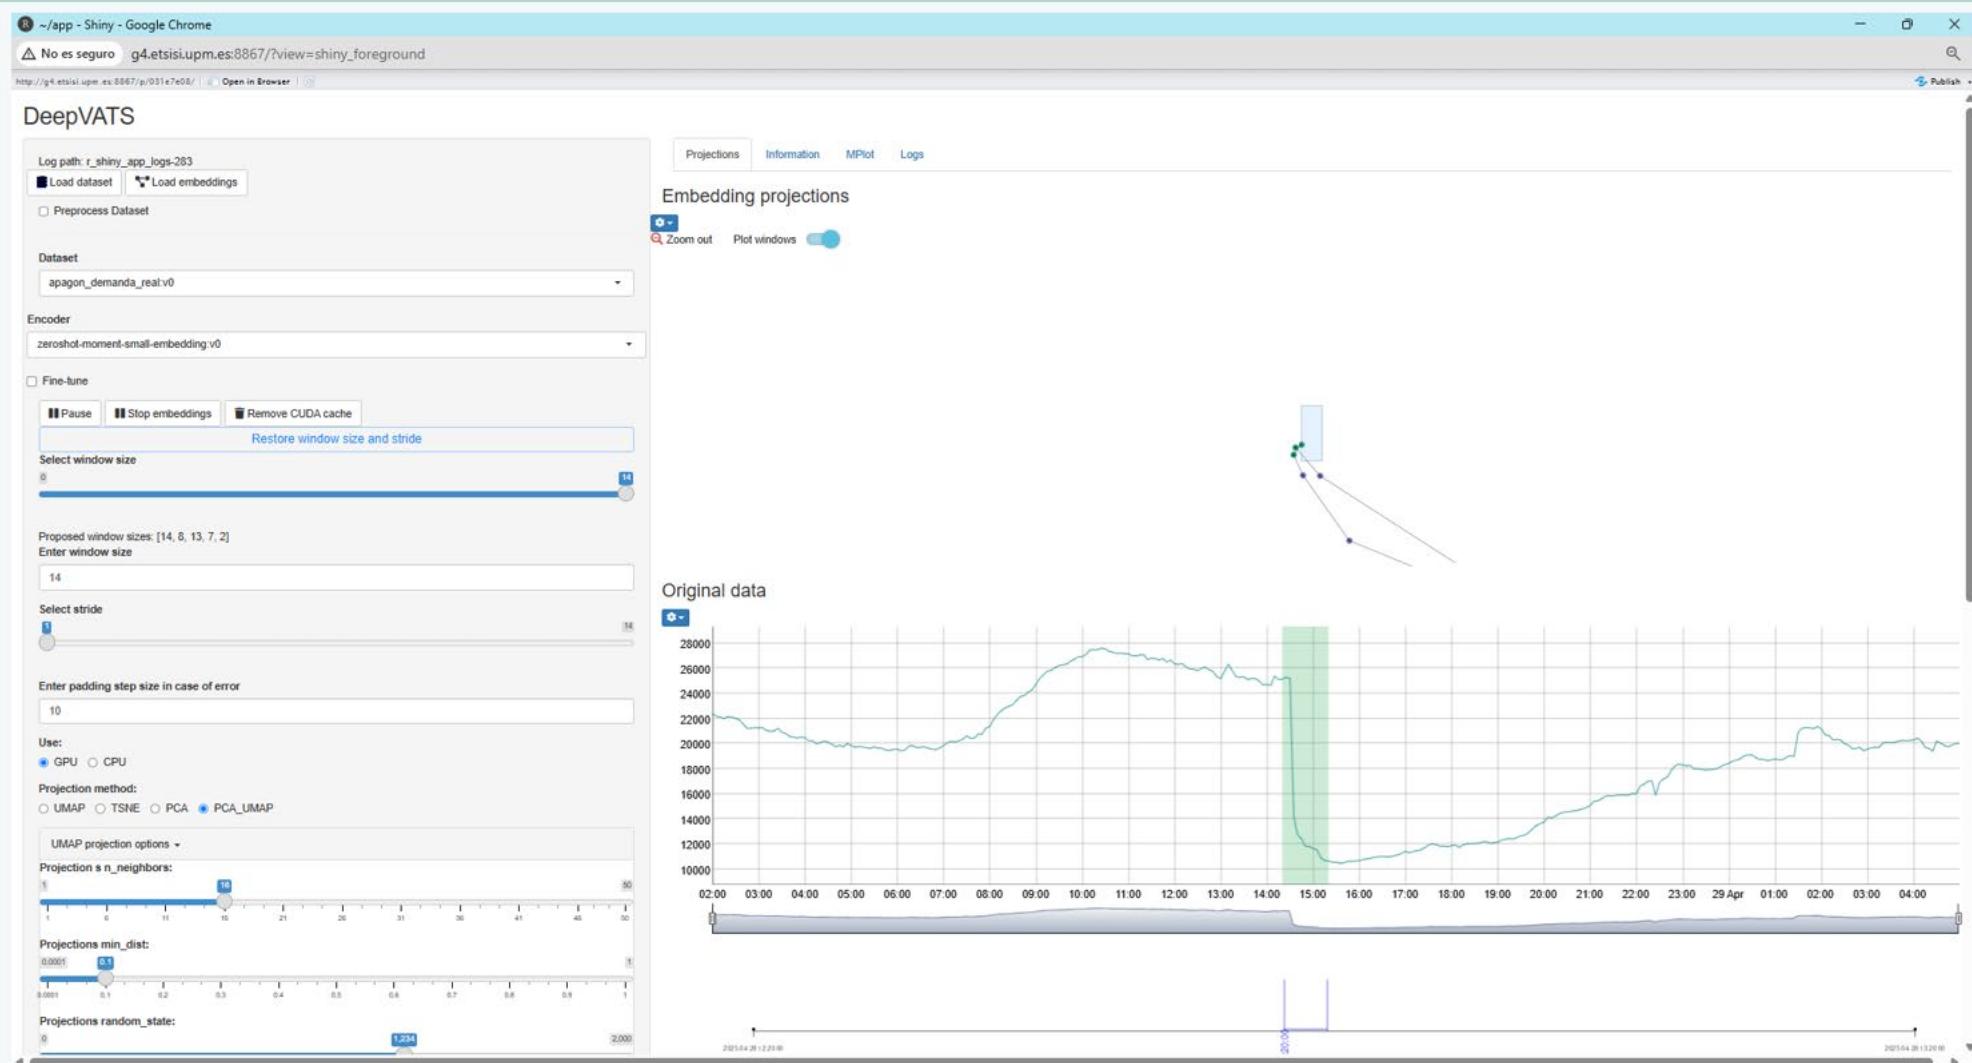
# MOMENT | Caso de uso | Univariable (zero-shot)



# MOMENT | Caso de uso | Univariable (zero-shot)



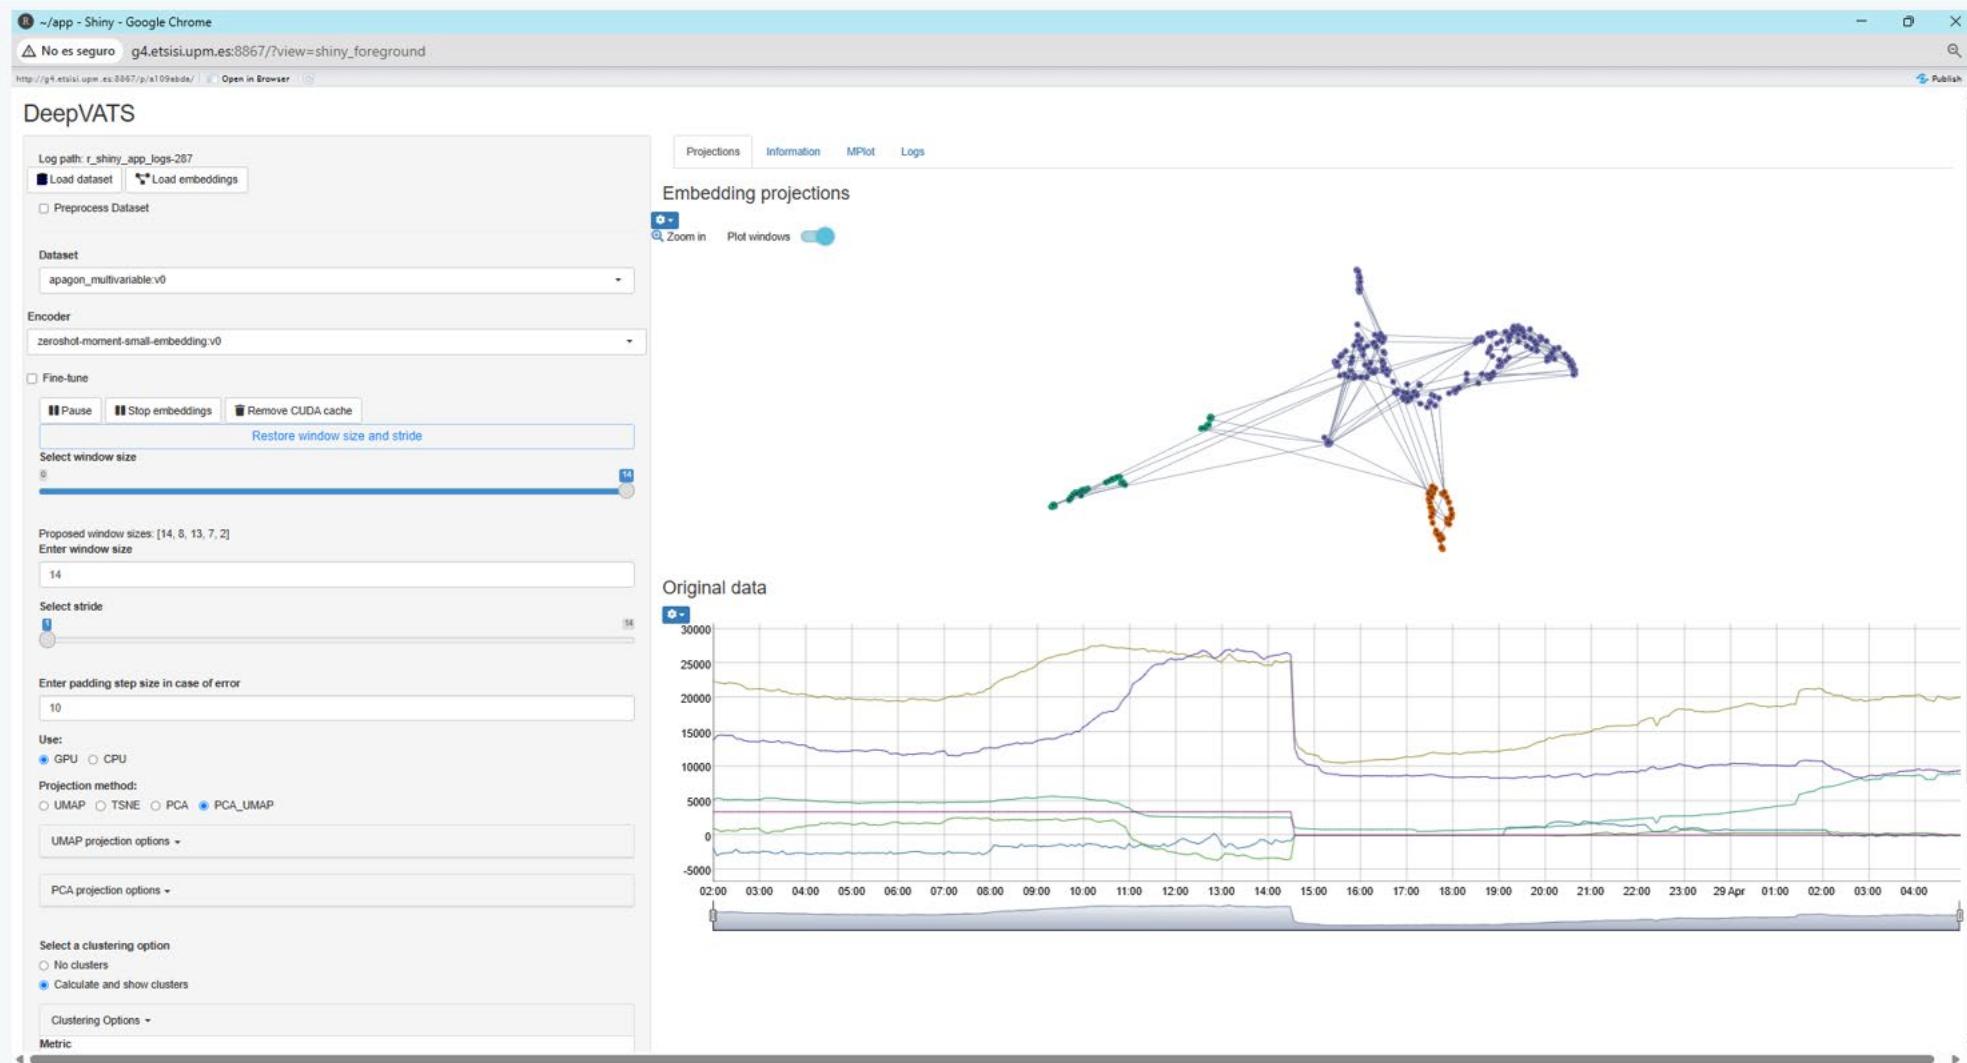
# MOMENT | Caso de uso | Univariable (zero-shot)



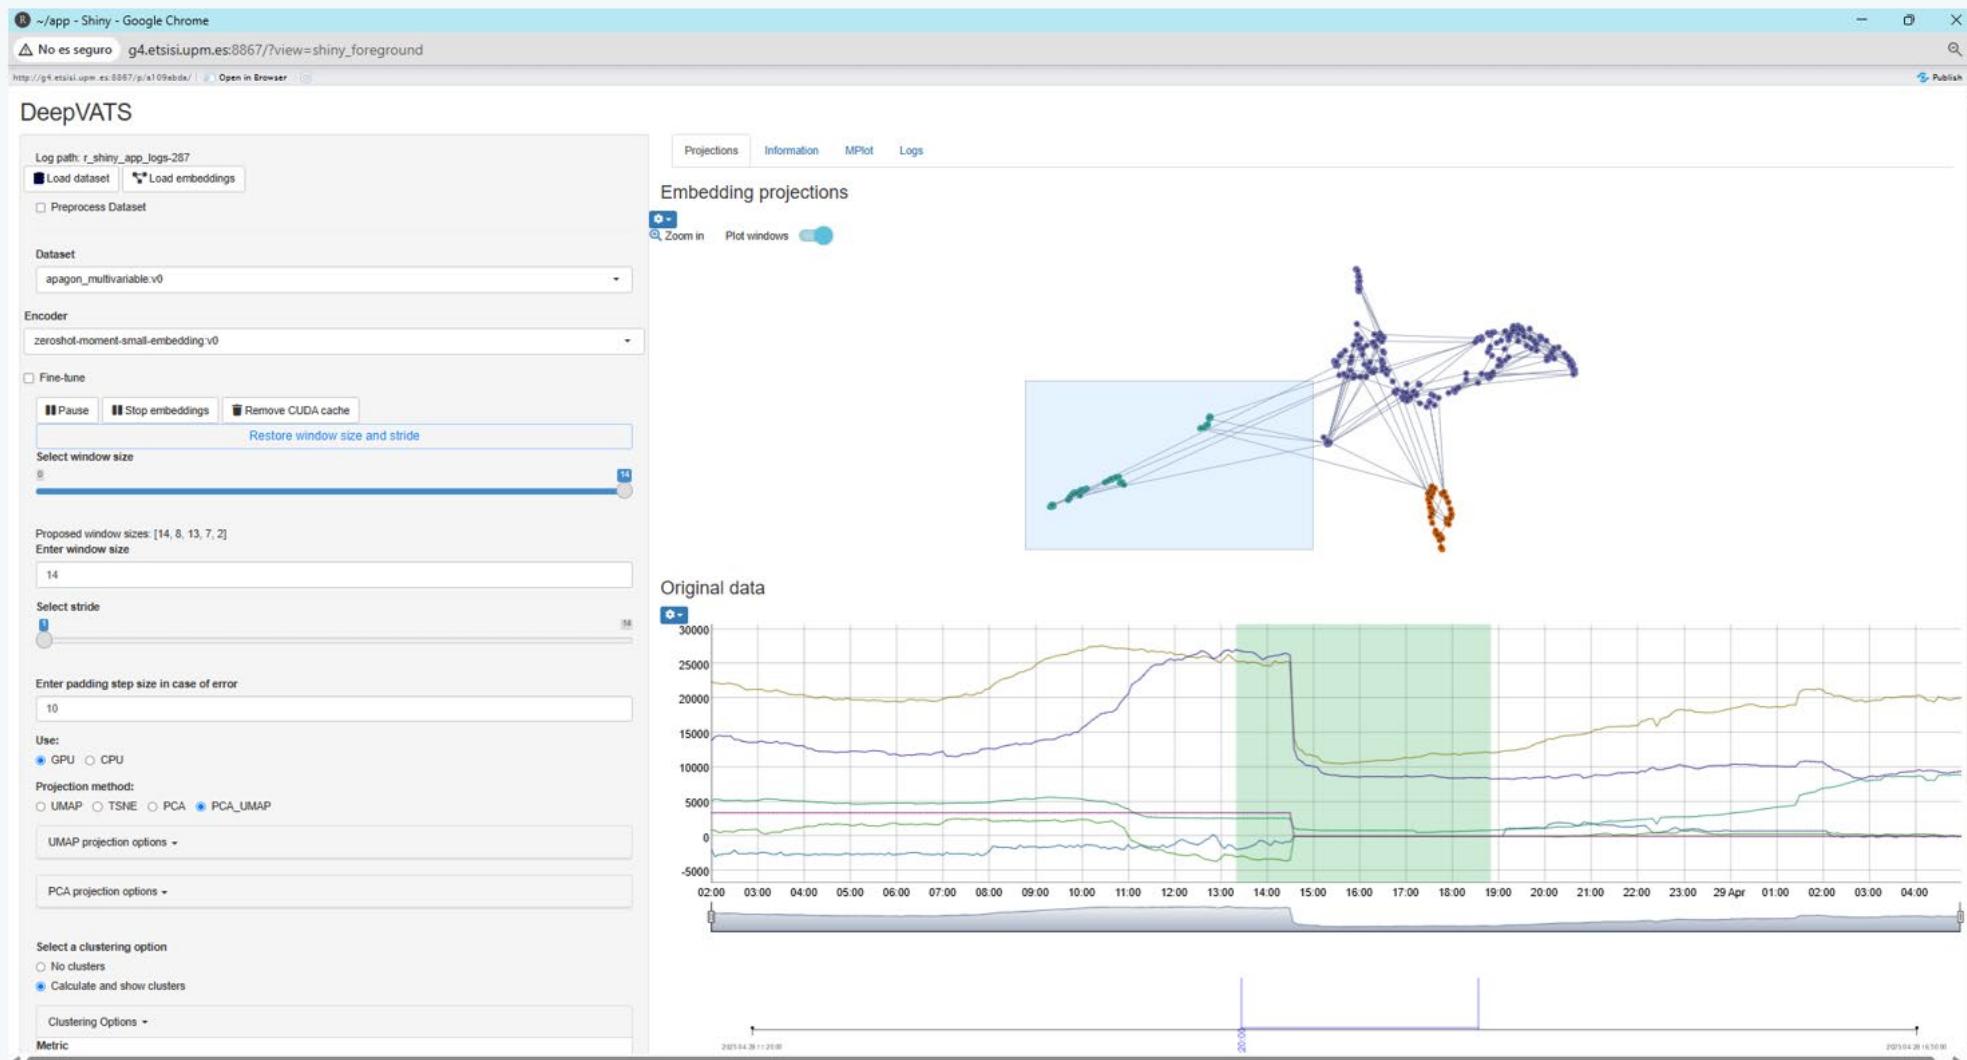
# MOMENT | Caso de uso | Univariable (zero-shot)

- Se detecta la anomalía (menos clara que con MTSAE)
- La segmentación no es clara

# MOMENT | Caso de uso | Multivariable (zero-shot)

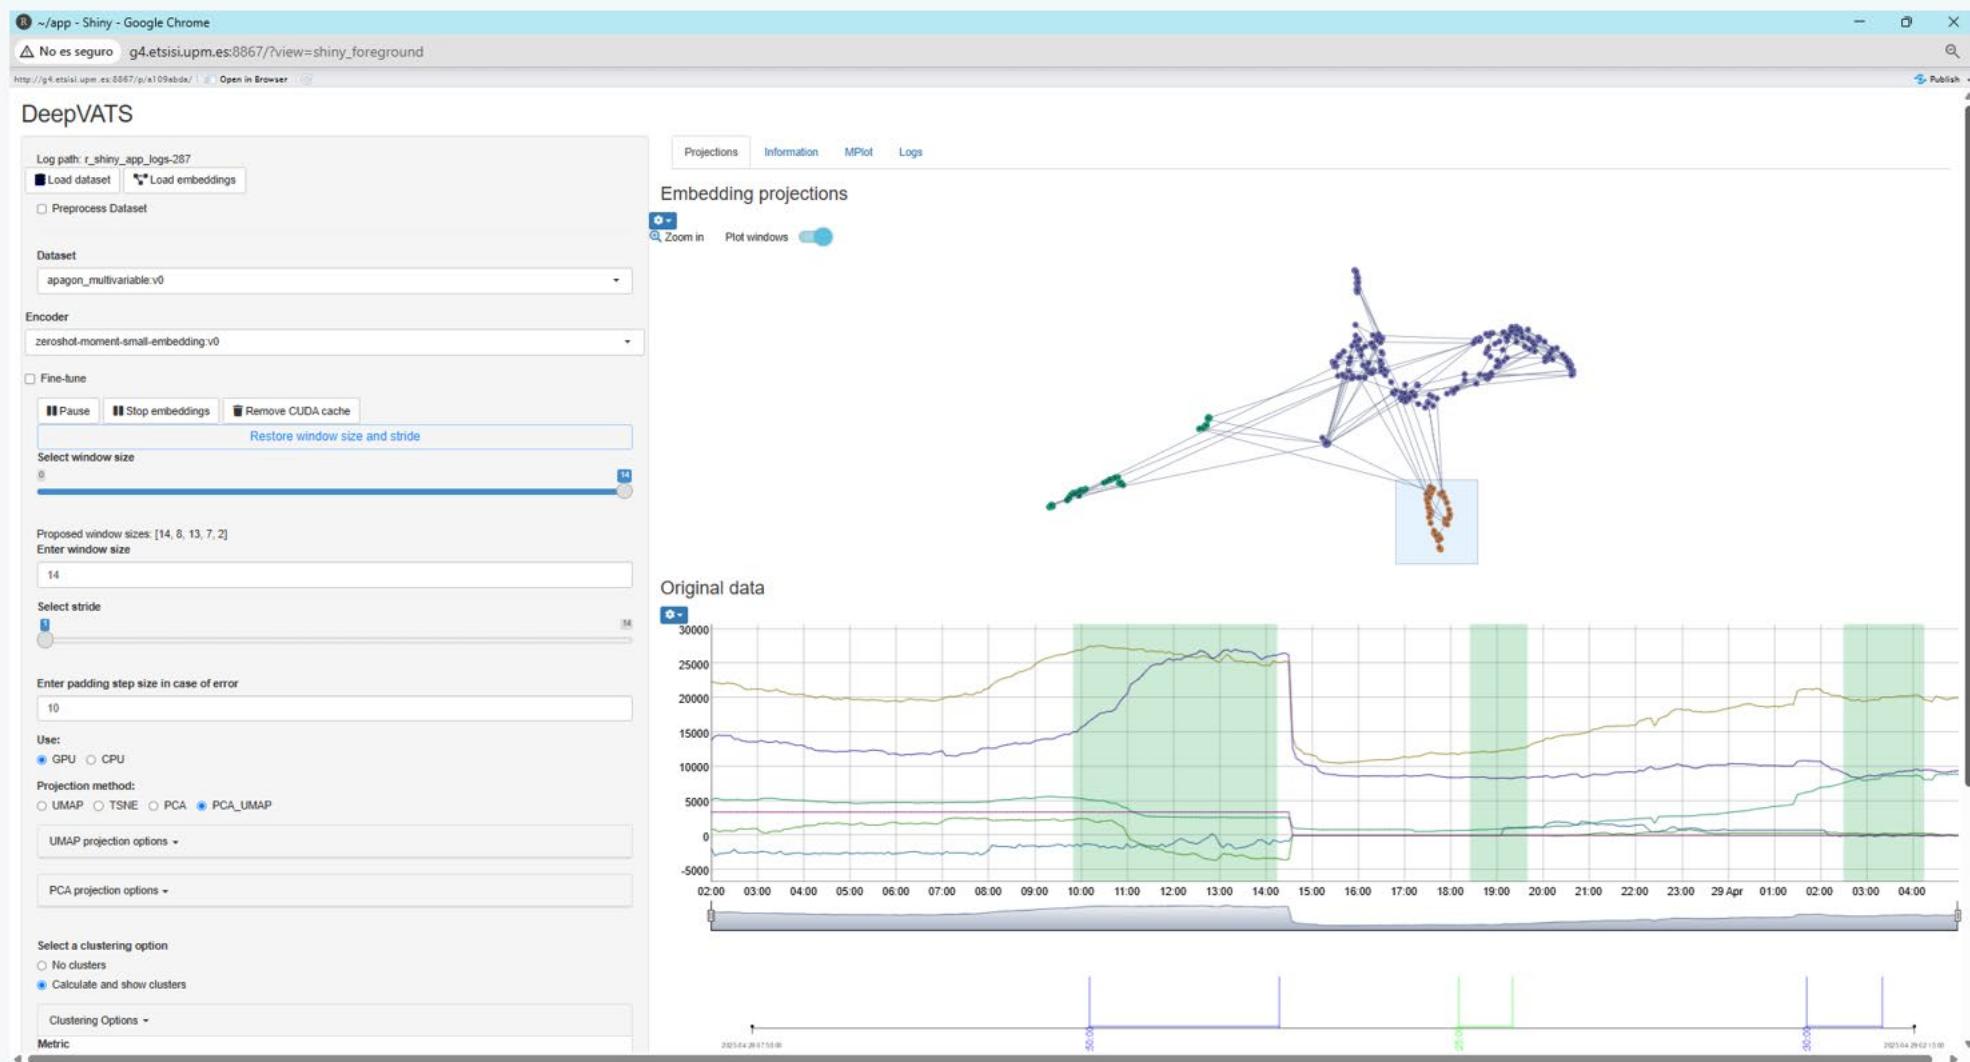


# MOMENT | Caso de uso | Multivariable (zero-shot)



¿Apagón y  
bloqueo?

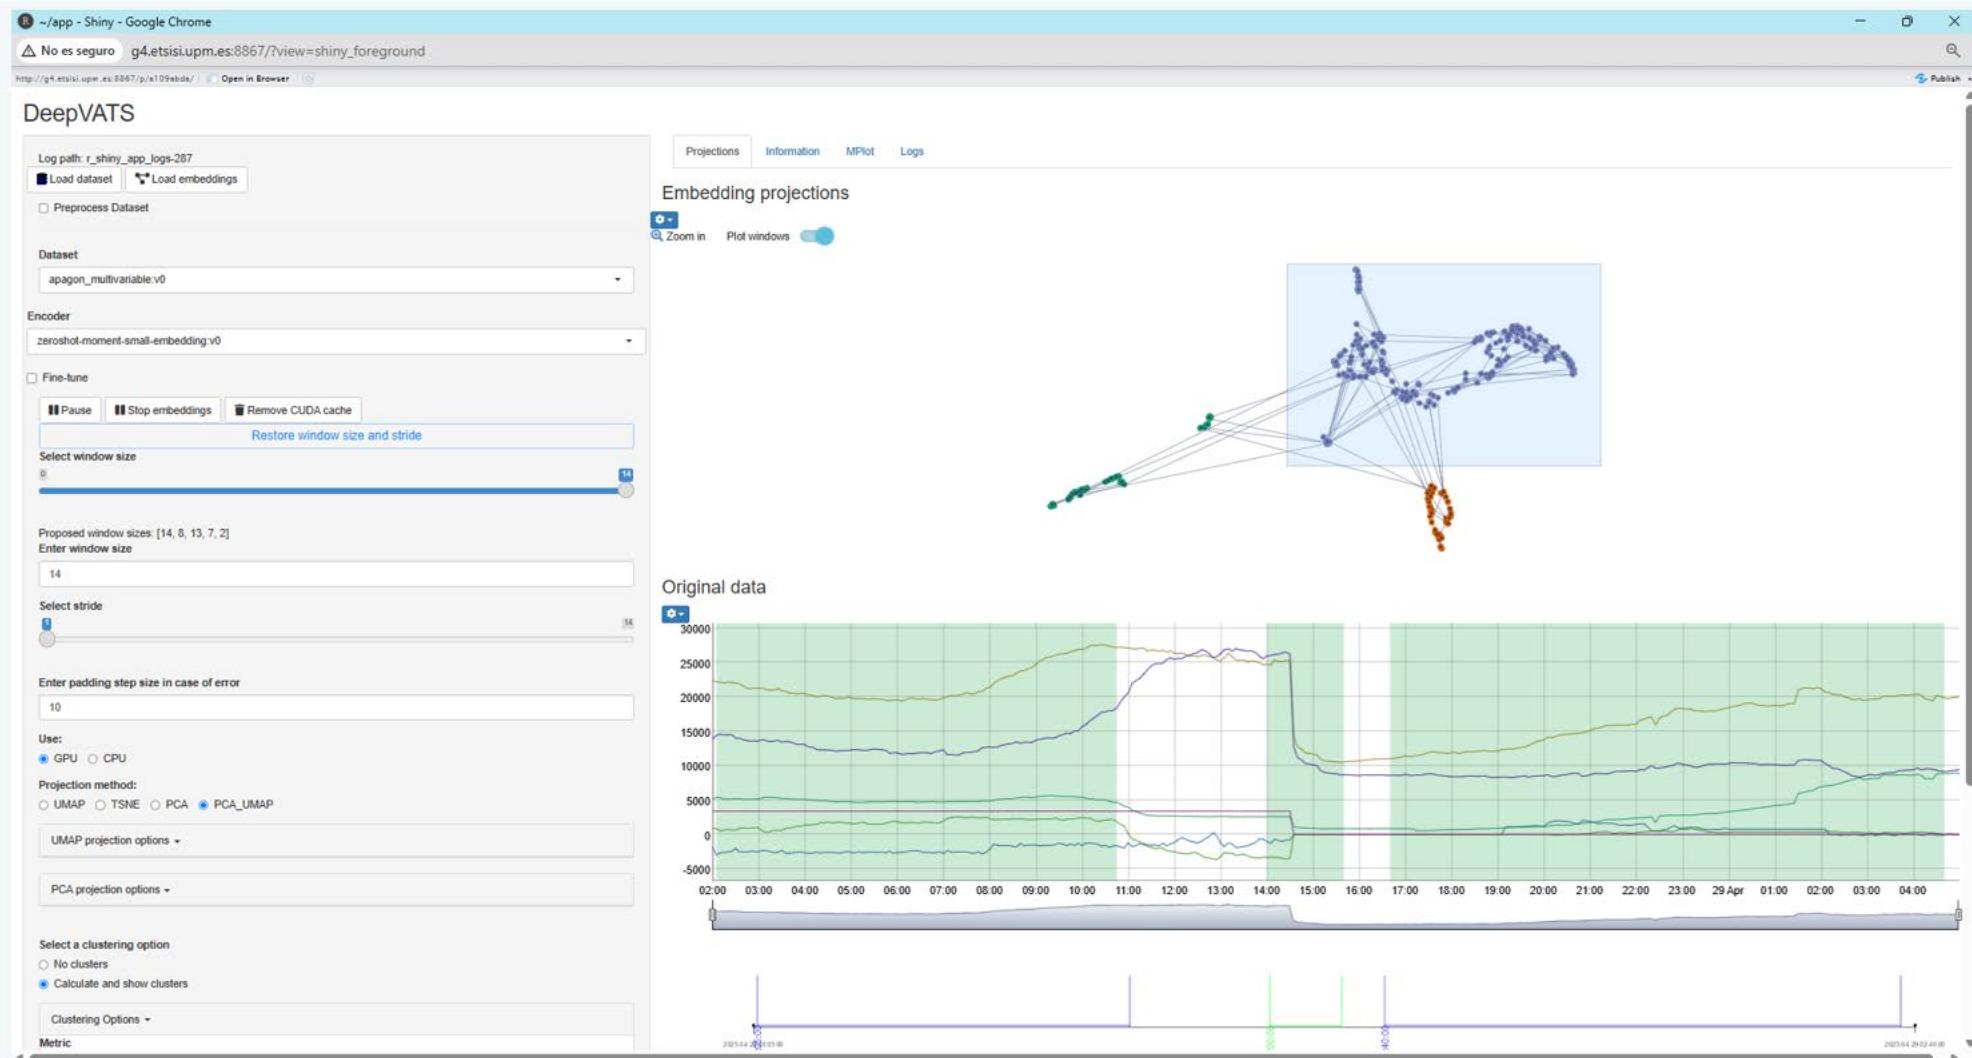
# MOMENT | Caso de uso | Multivariable (zero-shot)



Pico de las  
renovables (...y  
un par de trozos)



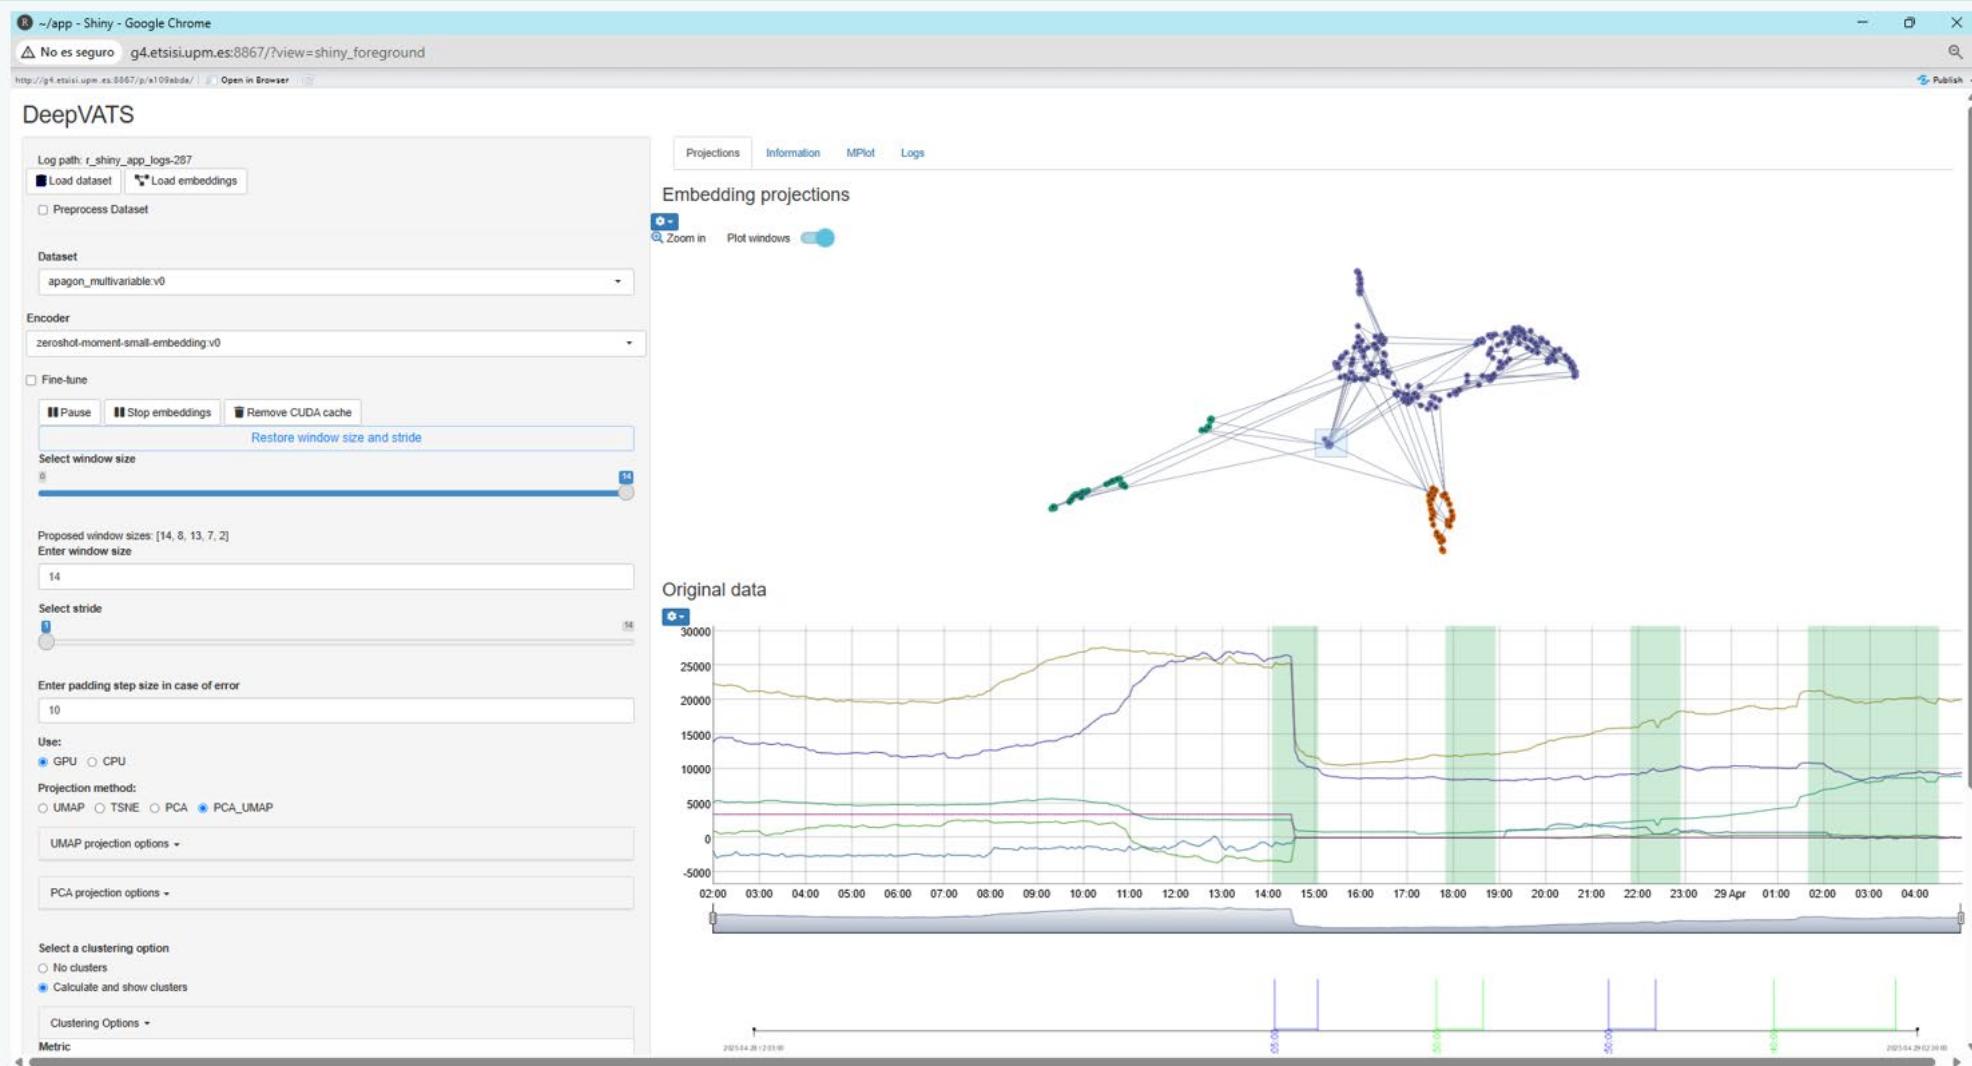
# MOMENT | Caso de uso | Multivariable (zero-shot)



¿Estado habitual  
+ apagón? No  
muy claro

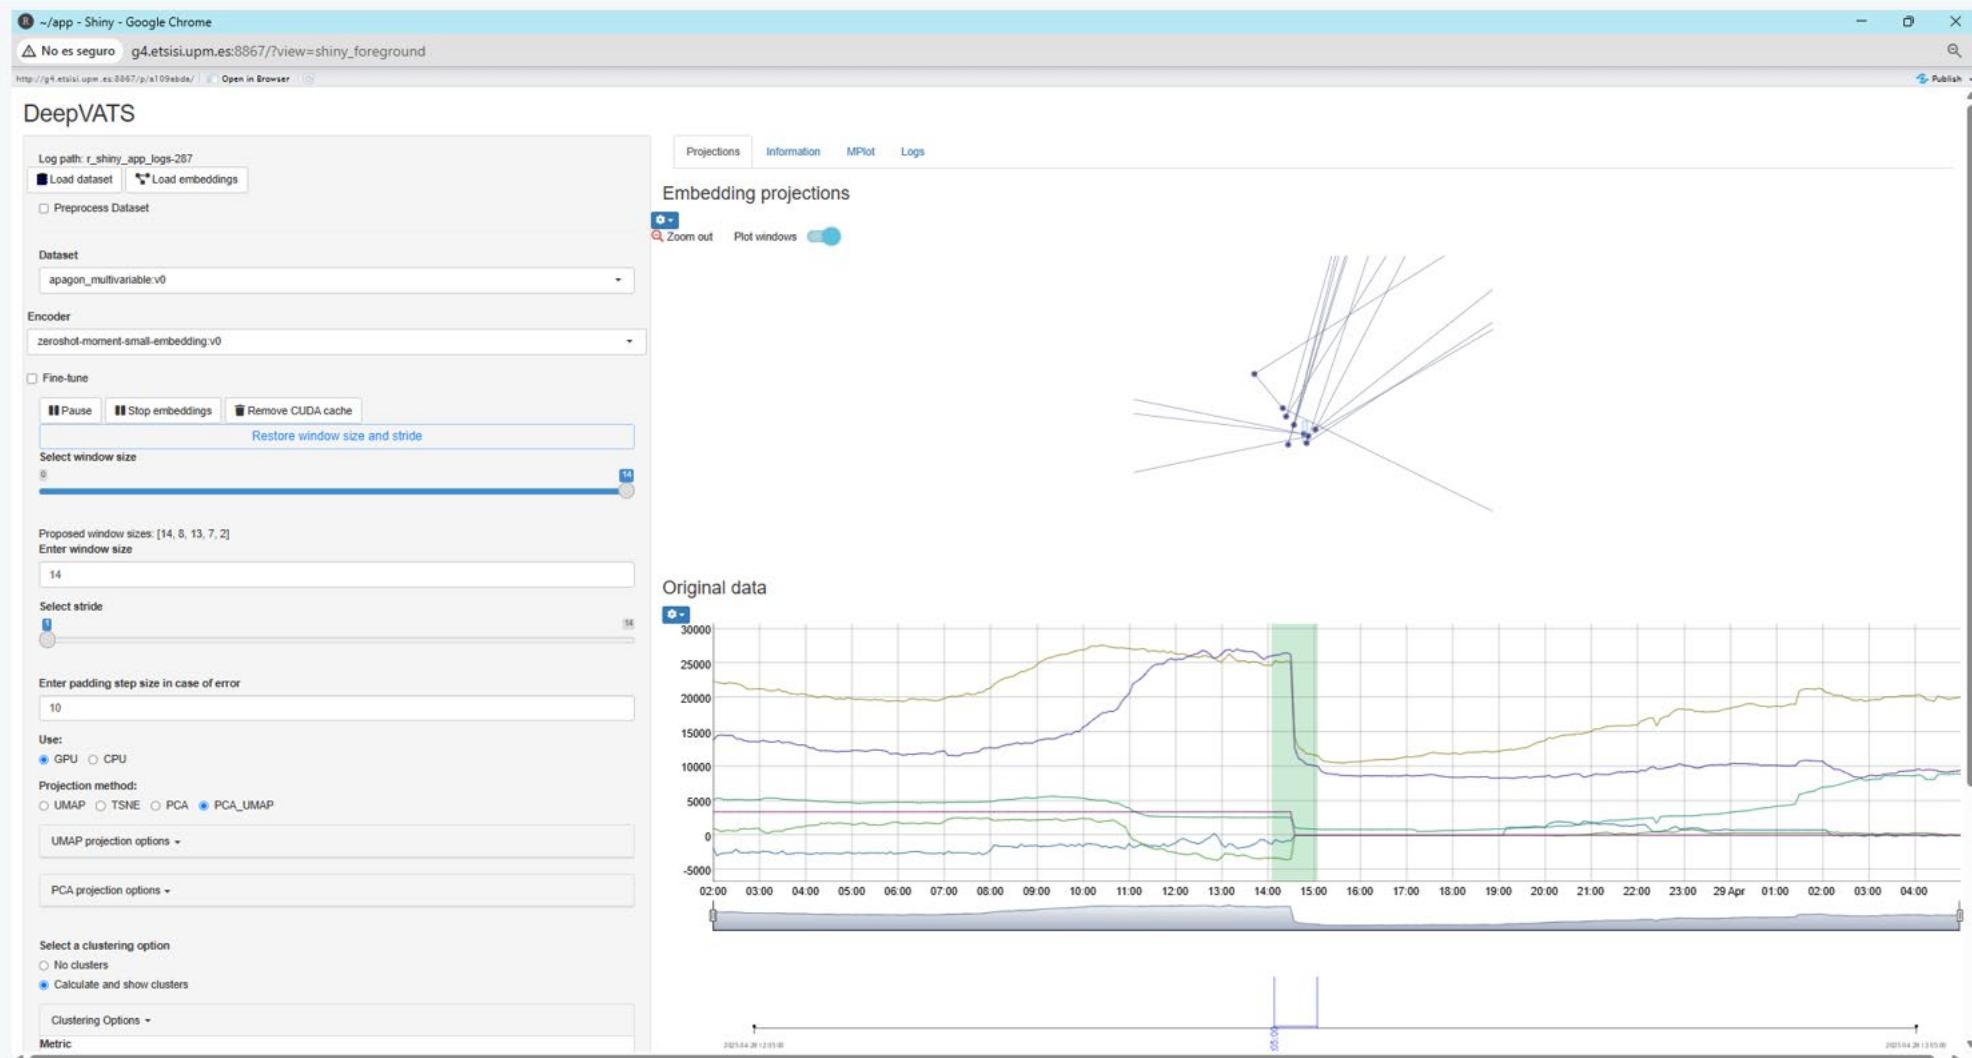


# MOMENT | Caso de uso | Multivariable (zero-shot)



Apagón

# MOMENT | Caso de uso | Multivariable (zero-shot)



Apagón

# MOMENT | Caso de uso | Multivariable (zero-shot)



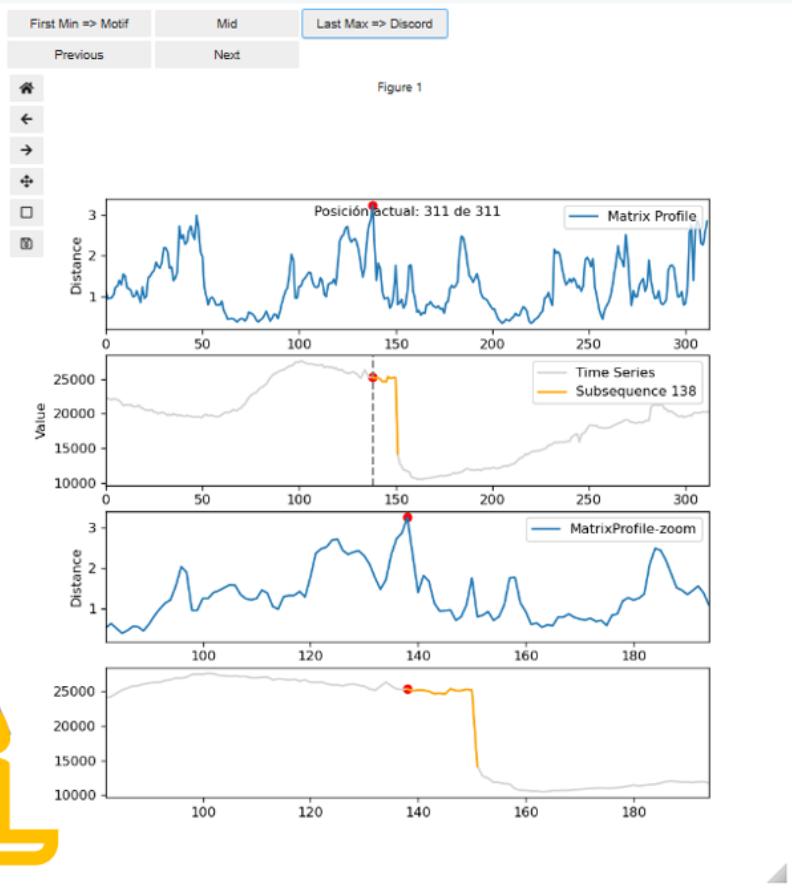
- Se detecta mejor la anomalía (aún difícil de ver)
- La segmentación se ajusta bastante a los eventos ocurridos, pero sigue sin ser clara



# Análisis visual basado en DM 1/3



## Matrix Profile



## MPlot

Vector de mínimos de distancias entre  
subsecuencias de mismo tamaño

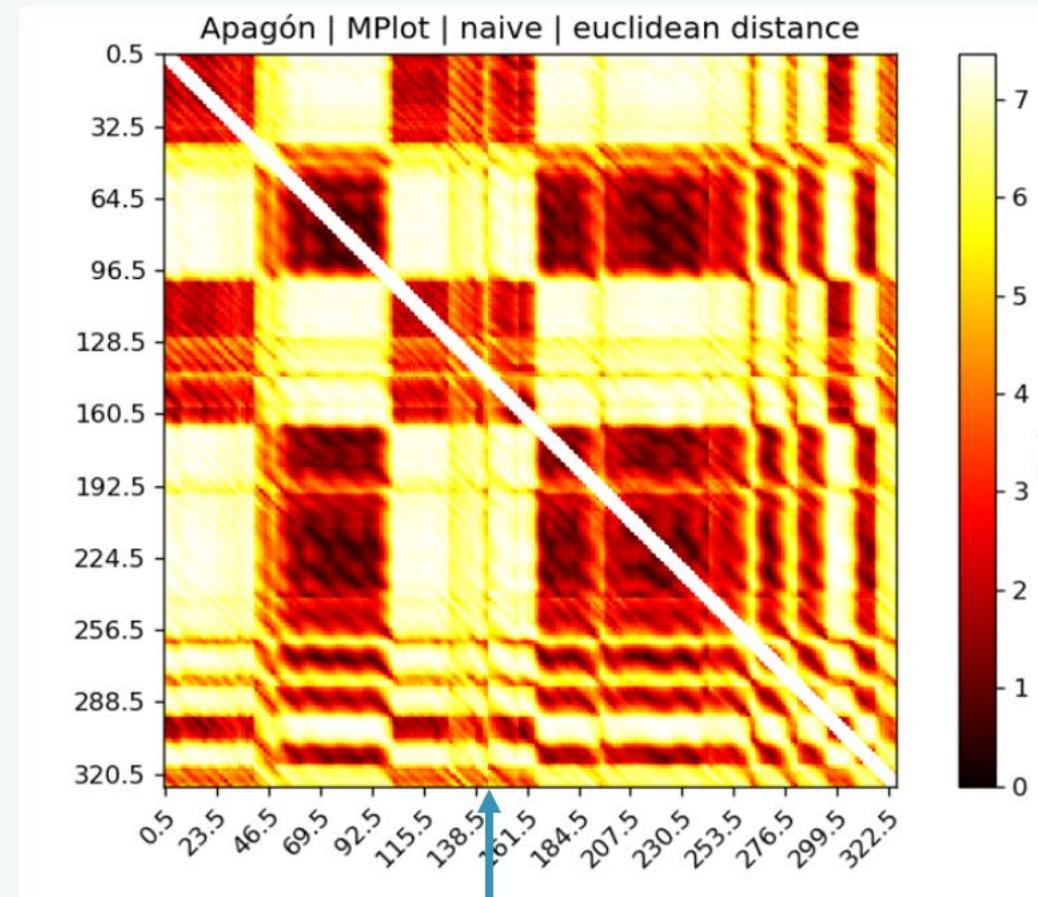
## Pseudo-MPlot

# Análisis visual basado en DM 2/3

Matrix Profile

MPlot

Pseudo-MPlot



- **Matriz de distancias** entre subsecuencias de mismo tamaño
- Difícil de detectar la anomalía, aunque está ahí

# Análisis visual basado en DM 3/3

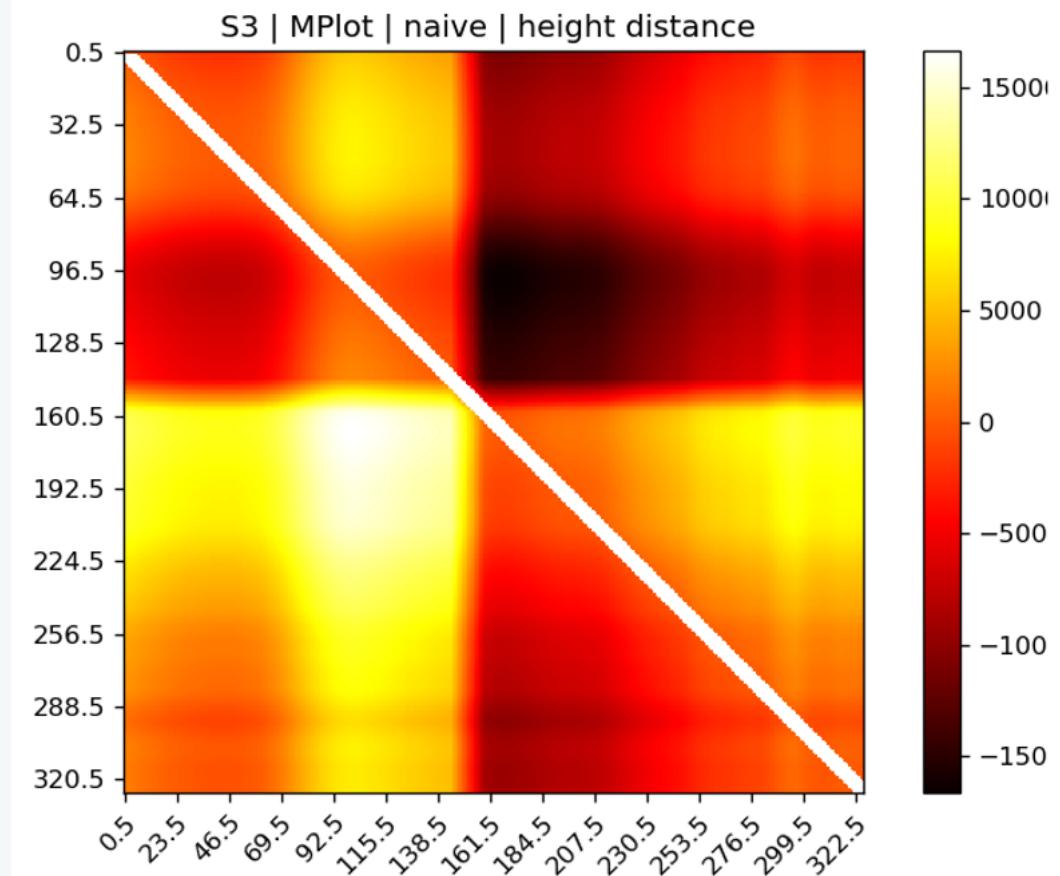


## Matrix Profile

- Matriz de **pseudo-distancias** entre subsecuencias
- Se observa claramente el cambio de tendencia (cruz)

## Mlot

## Pseudo-MPlot



# Análisis de escalabilidad



Frecuencia (s)	# Elementos	DeepVATS
600 (10m)	49,315	900.00 seg.
300 (5m)	98,630	1,885.71 seg.
60	493,149	9,600.00 seg.
20	1,479,445	29,075.00 seg.
4	7,397,222	144,850.00 seg.

Time series

Execution times



Solar 4 seconds

# Análisis de escalabilidad



Frecuencia (s)	# Elementos	DeepVATS
600 (10m)	49,315	15 min.
300 (5m)	98,630	31 min.
60	493,149	2,6 horas
20	1,479,445	8 horas
4	7,397,222	1,7 días

Time series

Execution  
times



Solar 4 seconds

# Análisis de escalabilidad



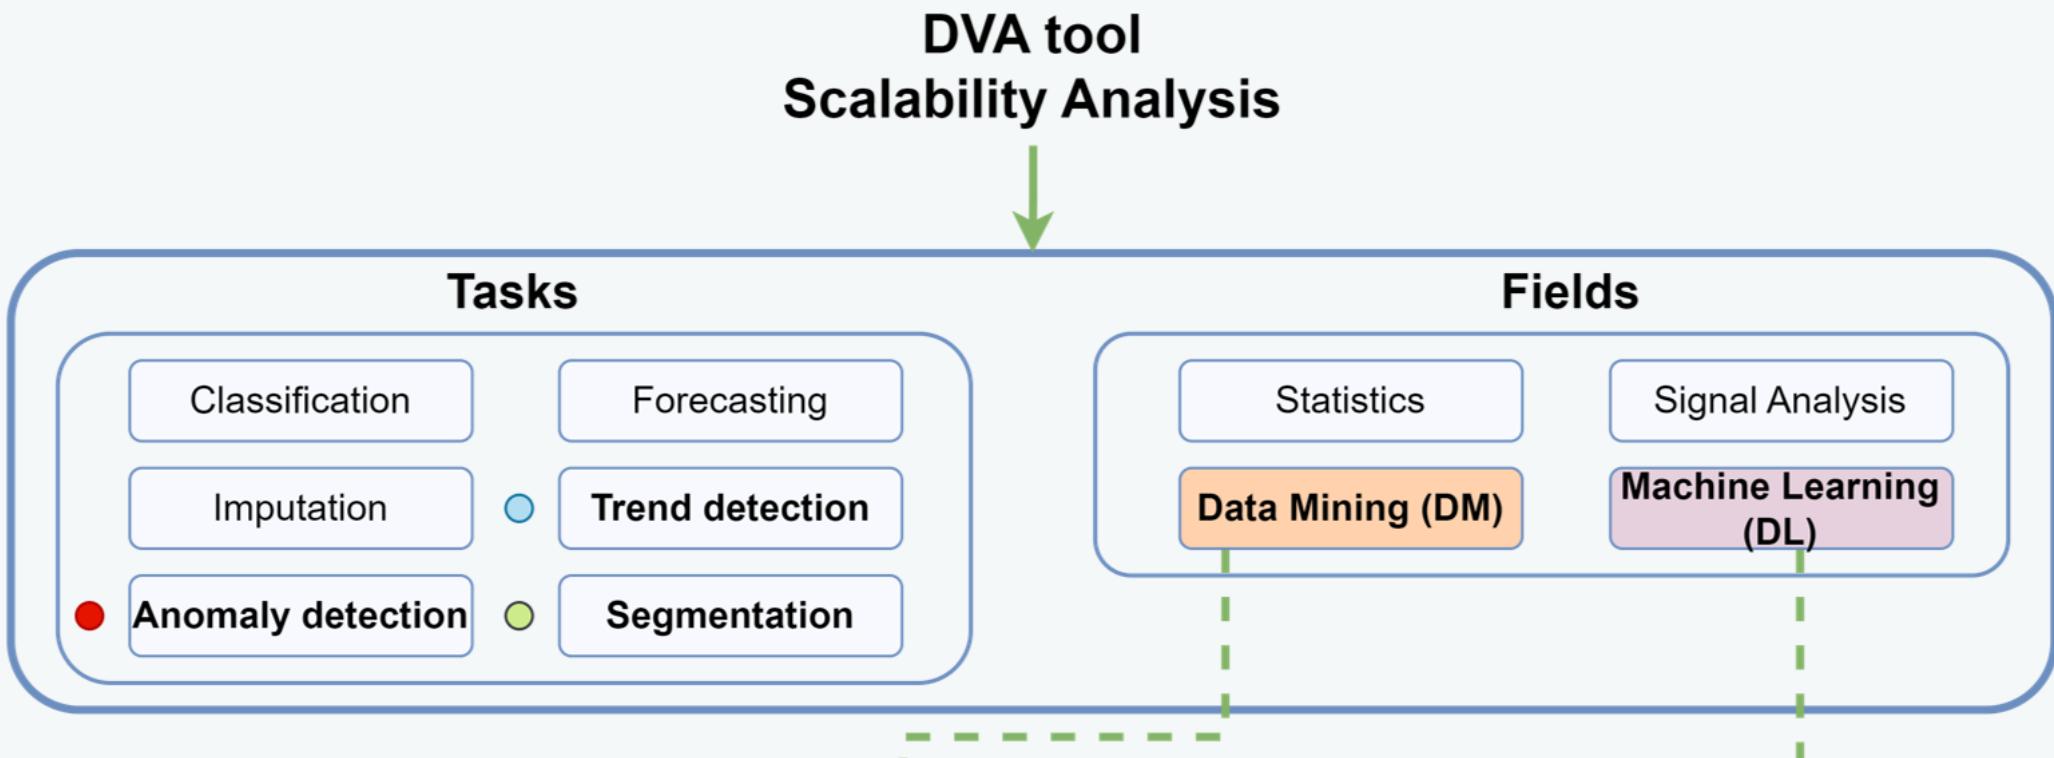
Necesito algo **más interactivo** que siga siendo **fácil de interpretar** y **mejore** las capacidades actuales



# Análisis de escalabilidad



State-of-the-art  
analysis



# Análisis de escalabilidad



Clasificación

Imputación

Predicción

Detección de anomalías

Detección de tendencias

Segmentación

Estadística

Minería de datos  
(DM)

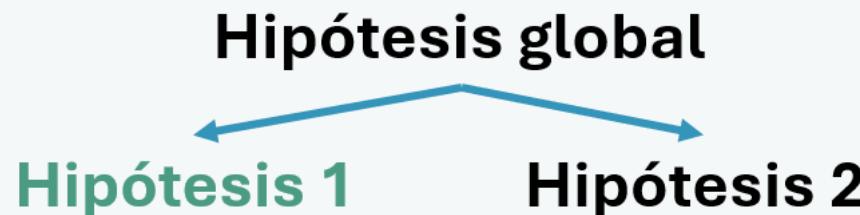
Análisis de señales

Aprendizaje  
profundo (DL)

Tareas de análisis visual

Áreas de estudio

# Preguntas de investigación 1/2



## Hipótesis 1

La **adición de DM** ayuda a obtener **gráficos más interpretables y rápidos**

### PI 1

¿ **MPlot** => DVA más eficientes e interpretables?

¿ **Mplot-10K** puntos de la serie temporal supera en **eficiencia** a MTSAE - DeepVATS?

¿ **Mplot-10K** supera la **interpretabilidad** de MTSAE - DeepVATS?

# Preguntas de investigación 2/2

## Hipótesis 2

Los **modelos fundacionales** ayudan a mejorar la interpretabilidad de los DVA

## Hipótesis global

### Hipótesis 1

### Hipótesis 2

## PI 2

¿modelos fundacionales => Mejor DVA?

### PI2.1

¿Son interpretables?

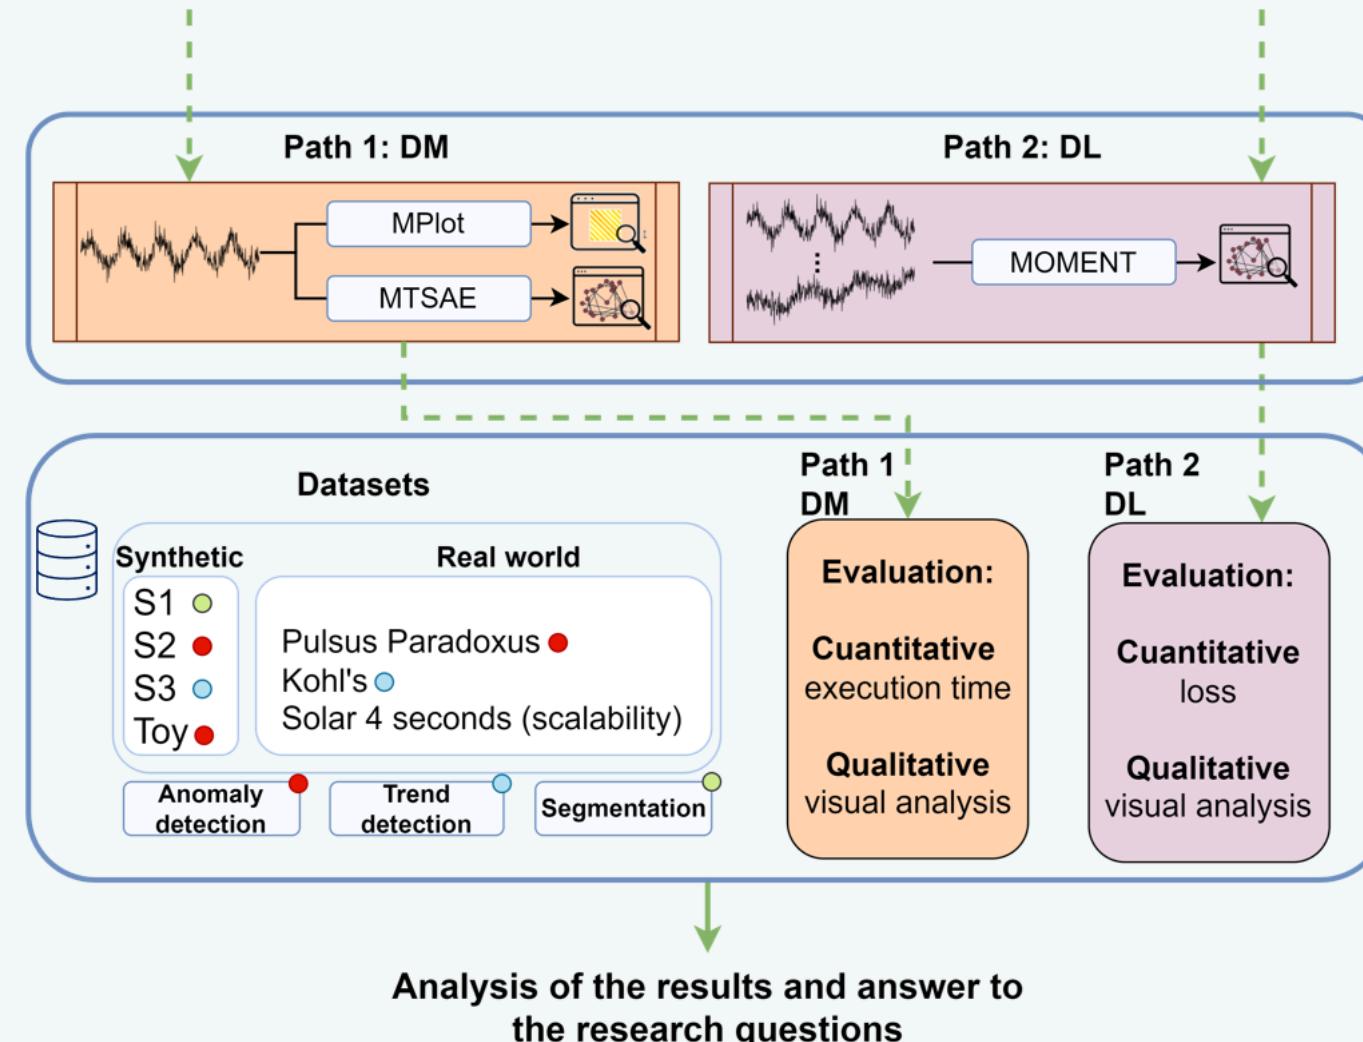
### PI2.2

¿Mejor loss => más interpretable?

### PI2.3

¿Cuánto ajuste fino es necesario para conseguir una mejorar real en la interpretabilidad?

# Metodología dual y evaluación



Camino dual

Evaluación

Respuesta Pls

# Integración



## DeepVATS

- **Módulo de Deep Learning**
- Módulo de almacenamiento
- **Módulo de análisis visual**



MOMENT (y otros)



Selección de modelos  
fundacionales independiente del  
conjunto de datos



Mplot y Matrix Profile (+ pestaña)

Selector de variable para el  
cómputo de MPlot y Matrix  
Profile

**3**/<sub>5</sub>

# Resultados experimentales

# Punto de partida



Detection of:				
Segmentation	Seasonalities	Repetitive patterns	Anomalies	Trends

# Datasets analizados



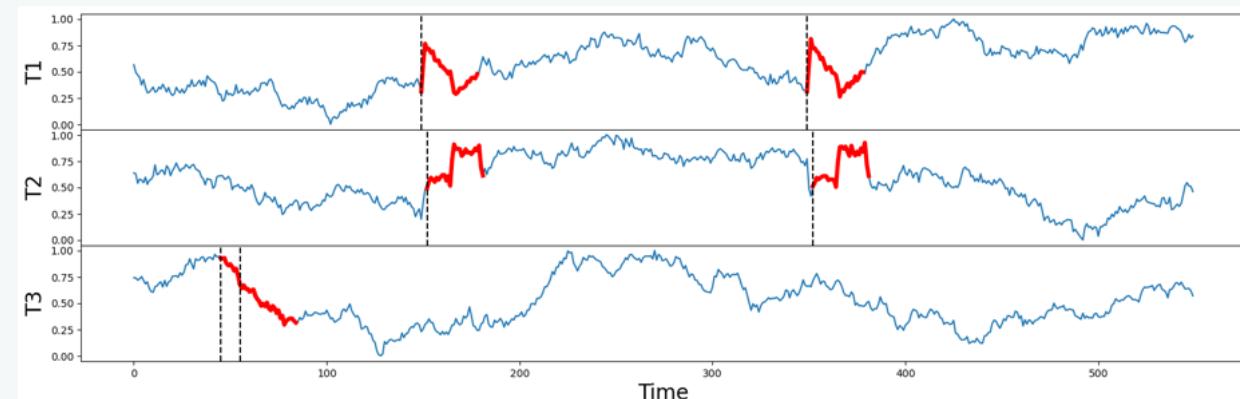
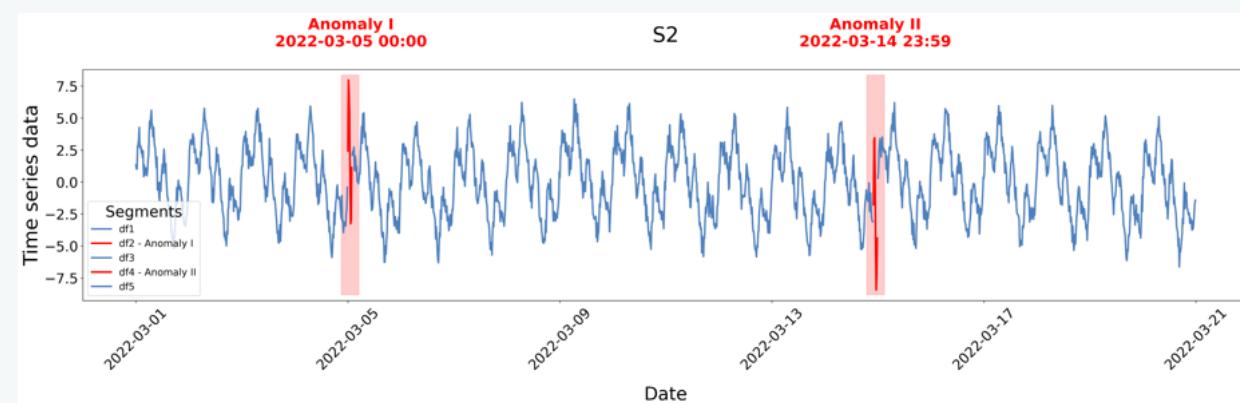
Clasificación

Detección de anomalías

Imputación

Predicción

Tareas de análisis visual



S2 y M-Toy

# Datasets analizados



Clasificación

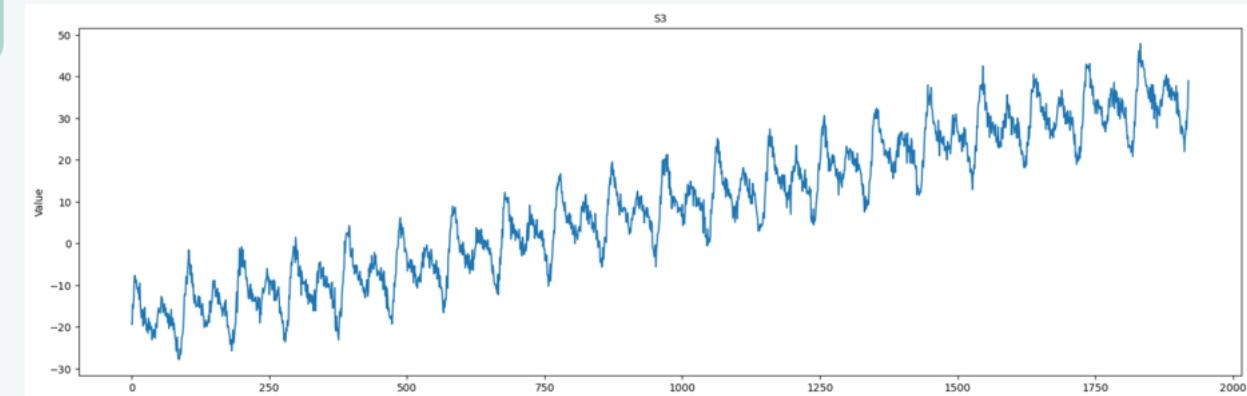
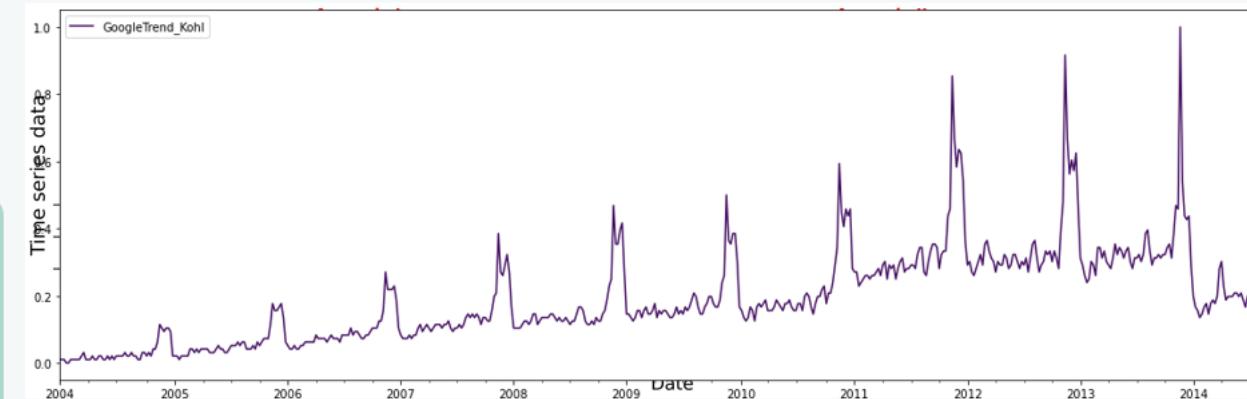
Imputación

Predicción

Detección de anomalías

Detección de tendencias

Tareas de análisis visual



Kohl's y S3

# Resultados experimentales: MPlot 1/4



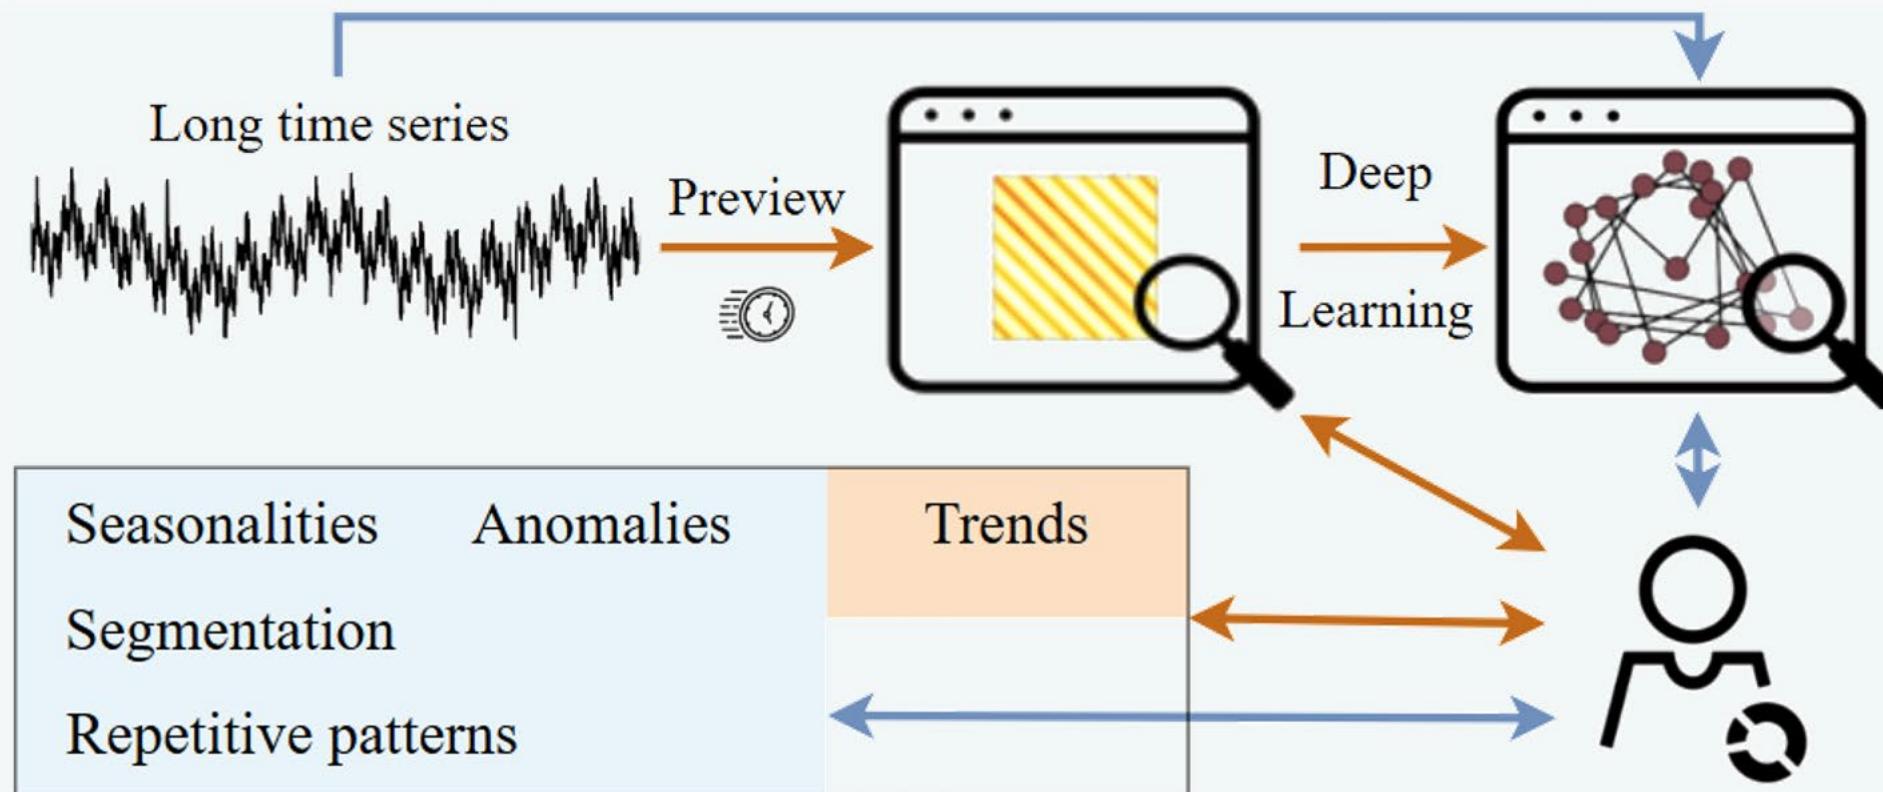
## Solar 4 seconds

Frecuencia (s)	# Elementos	DeepVATS	DeepVATS + MPlot (Completo)	DeepVATS + MPlot (10K)
600 (10m)	49,315 (50K)	15 min.	46.34 seg.	7.30 seg.
300 (5m)	98,630 (100K)	31 min.	9 min.	7.42 seg.
60	493,149 (500K)	2,6 horas	OOM	4.98 seg.
20	1,479,445 (1.5M)	8 horas	OOM	7.08 seg.
4	7,397,222 (7.4M)	1,7 días	OOM	6.93 seg.

Time series

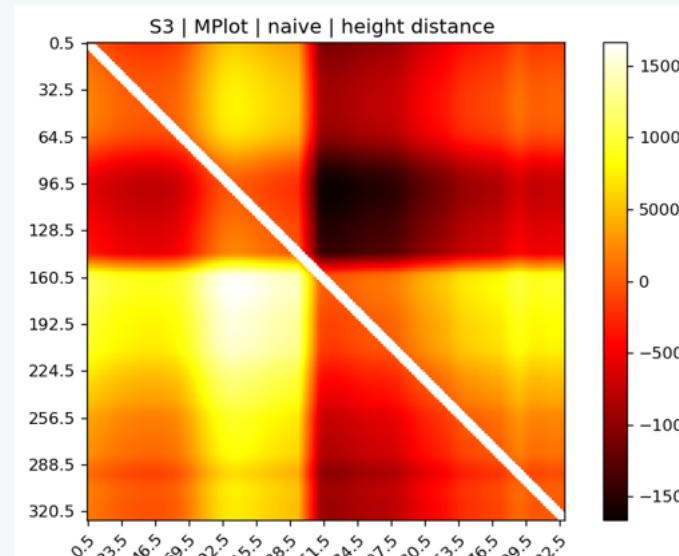
Execution times

## Resultados experimentales: MPlot 2/4



# Resultados experimentales: MPlot 3/4

- Pseudo-MPlot detecta tendencias

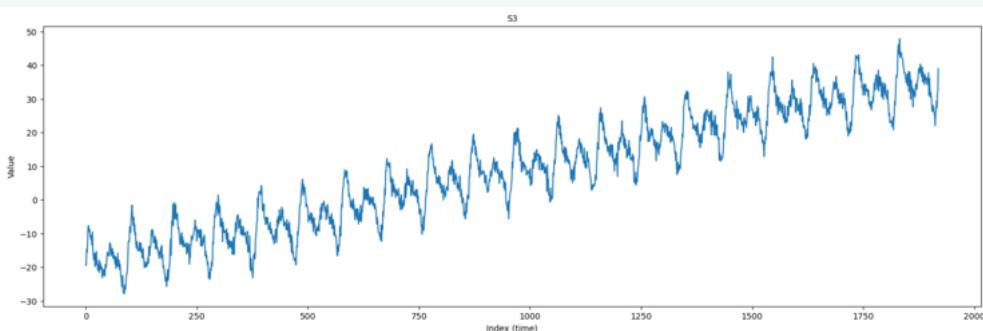


**Apagón**

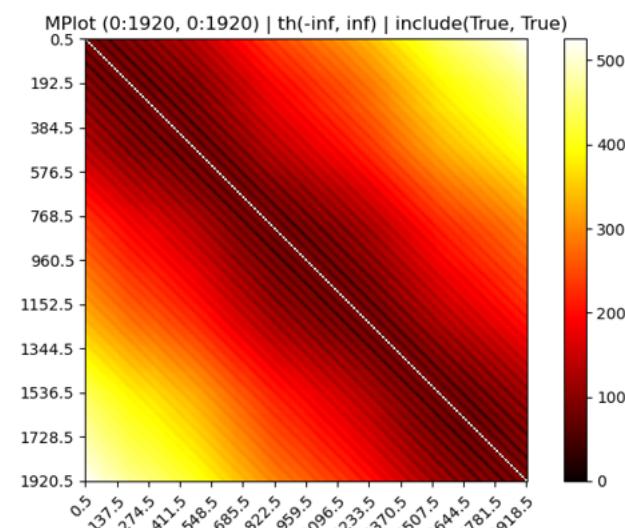
Cambio brusco alza -> baja en  
la demanda eléctrica

# Resultados experimentales: MPlot 4/4

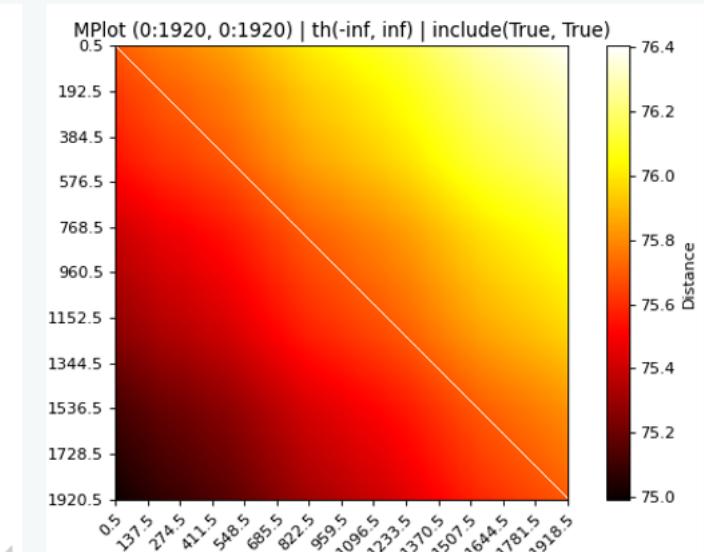
- Pseudo-MPlot detecta tendencias



S3



**S3 (Stump)**  
Se ve claramente que **hay una tendencia**  
Pero **no sabemos el sentido**



**S3 (height pseudo-distance)**  
Se realiza la **tendencia al alza**

# Respuesta primer camino (PI1)

**PI.1**

¿Ayudan los  
**MPlot**?

**PI1.2**

¿son fáciles de  
interpretar?

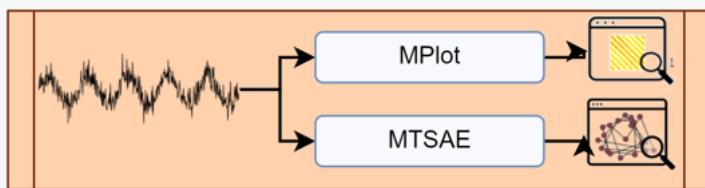
**PI1.1**

¿Son  
eficientes?

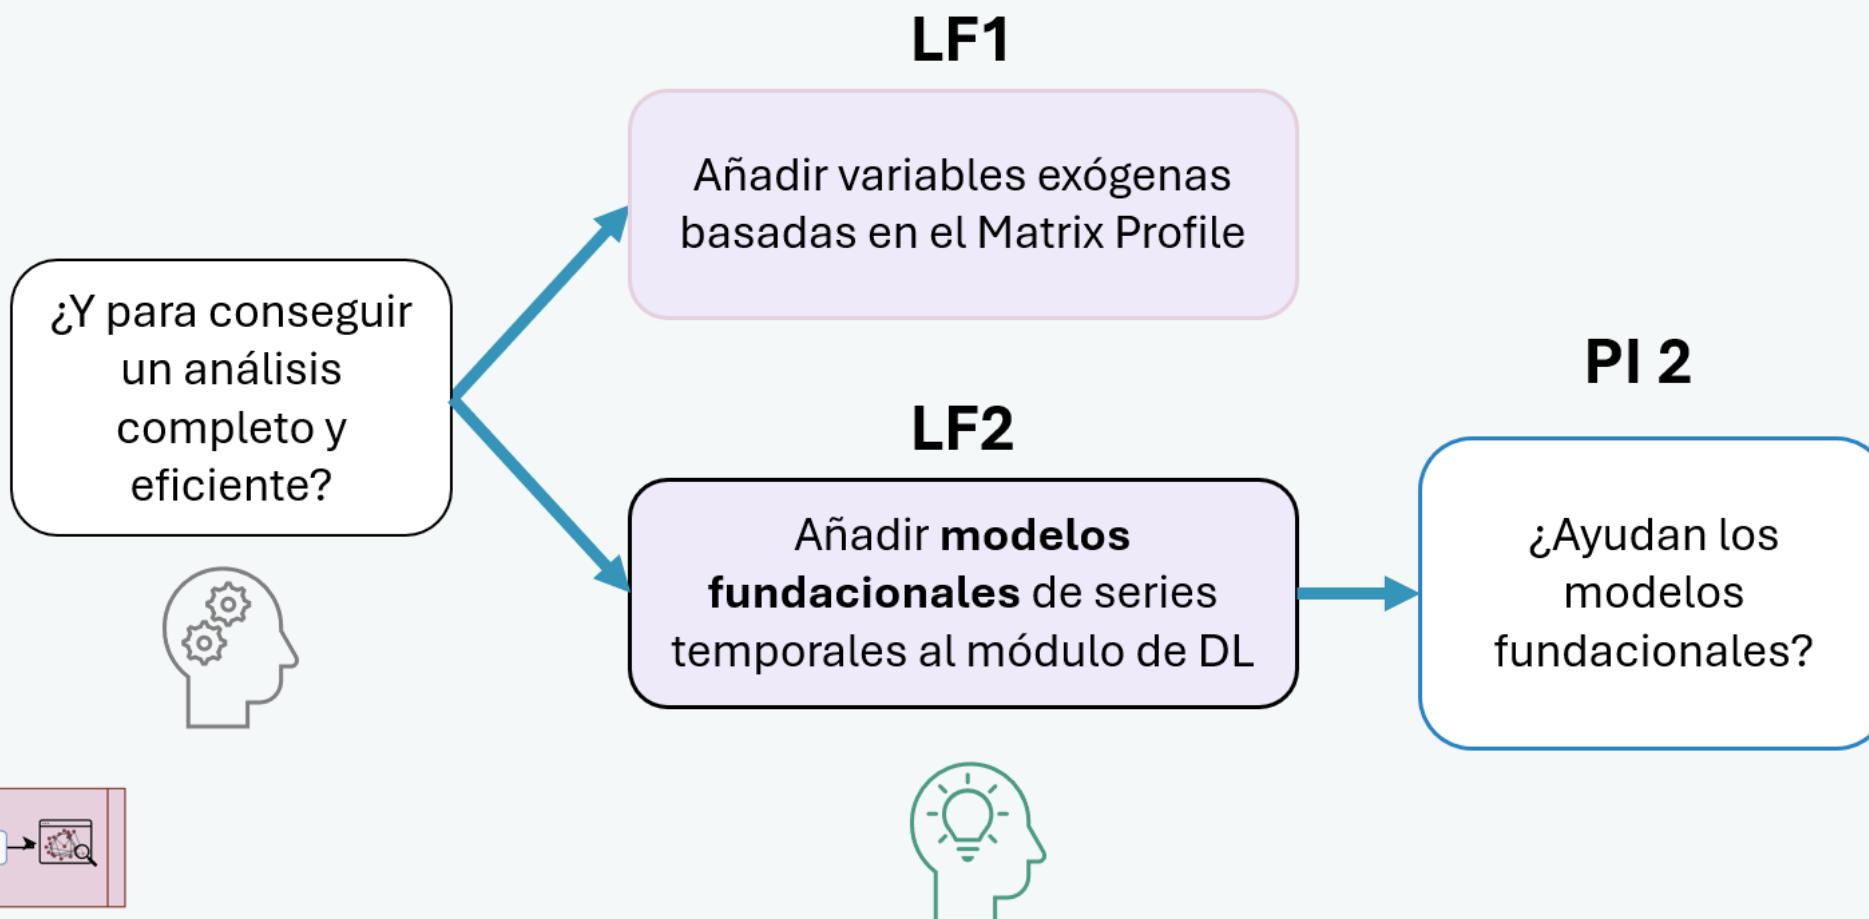
Sí, aunque se  
puede perder  
información

¿Y para  
conseguir un  
análisis  
completo y  
eficiente?

Sí, permiten  
preanálisis  
rápido

**Path 1: DM**

# Abriendo segundo camino



# MOMENT | Resultados 1/5



Se ha detectado correctamente la anomalía.



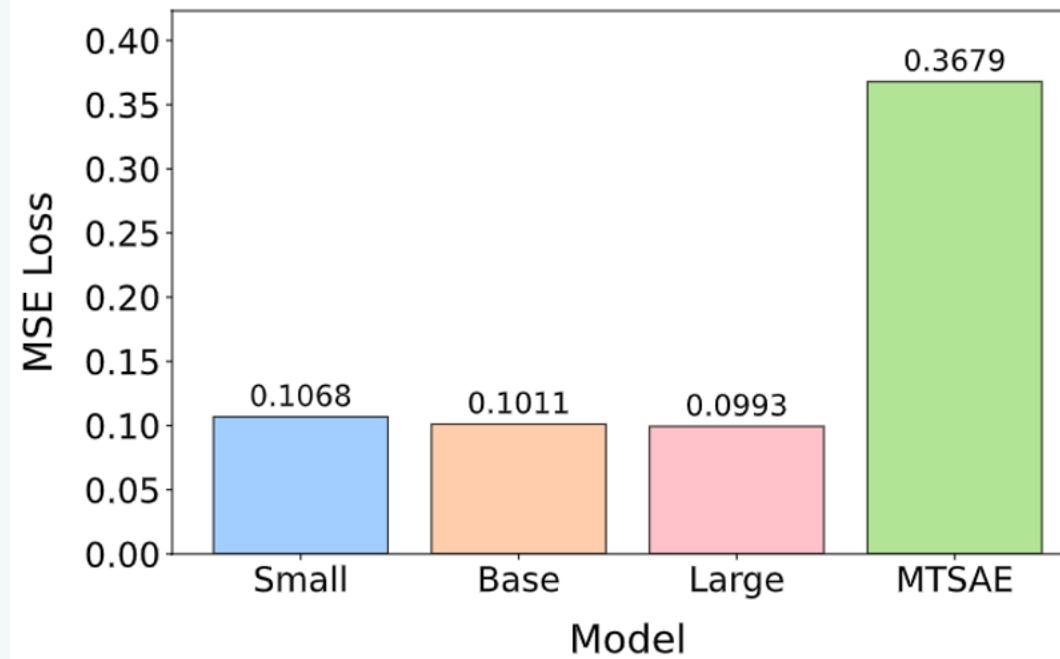
Los resultados no fueron tan buenos.

Modelo	Detección de Anomalías	Detección de Patrones	Segmentación	Detección de Tendencias
<b>MOMENT-Small</b>	✗ Se detectan anomalías pero es difícil aislarlas.	✓ Se detectan algunos patrones.	✗ Sin segmentación.	✗ No detecta tendencias visibles.
<b>MOMENT-Base</b>	✓ Mejora leve en detectar anomalías en los bordes.	✓ Los patrones son más claros que con Small.	✗ Algunas segmentaciones, pero incompletas.	✗ Sugiere tendencias, pero no son claras.
<b>MOMENT-Large</b>	✓ Las anomalías son más difíciles de detectar que con Base.	✓ Detección más estructurada de patrones.	✗ Sin segmentos claros.	✗ Aún carece de separación clara de tendencias.

## MOMENT | Resultados 2/5



MOMENT models Vs MTSAE



# MOMENT | Resultados 3/5



## MOMENT-SMALL

	Zero-shot	Fine-tuning (con segmentos y anomalías)
Anomalías	✗ Se detectan, pero son difíciles de aislar ✓ Se separan claramente los picos de la serie Kohl's	✗ Poca variación de los clúster ✓ Los clústeres están más definidos
Segmentación	✗ las llanuras no se separan visualmente	✓ Mejor captura de llanuras ✗ las llanuras no se separan completamente
Tendencias	✗ No se detectan, efecto muelle	✗ Sin cambios significativos

# MOMENT | Resultados 4/5



## MOMENT-BASE

### Zero-shot

#### Anomalías

✗ Aunque se empieza a detectar alguna, se entremezclan con el resto de la información

#### Segmentación

✓ Los picos se detectan fácilmente  
✗ Las llanuras, no

#### Tendencias

✗ Parece capturar tendencias, pero no está muy definido

### Fine-tuning (con segmentos y anomalías)

✗ Los clústeres apenas se modificaron en el caso de M-Toy

✓ Ligera mejora

✗ Ligeramente mejor, pero sigue sin estar claro

# MOMENT | Resultados 5/5



## MOMENT-LARGE

### Zero-shot

**Anomalías**

- ✓ Es donde mejor se detectan las anomalías en
- ✗ La información sigue entremezclada

**Segmentación**

- ✓ Mejor modelo para segmentación
- ✓ Se diferencian claramente picos de llanuras

**Tendencias**

- ✗ Es el mejor, pero sigue teniendo efecto muelle

### Fine-tuning (con segmentos y anomalías)

- ✗ De nuevo, los clústeres son prácticamente idénticos a los de la versión zero-shot

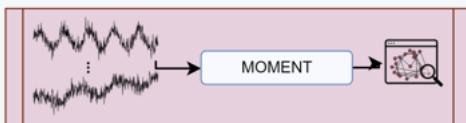
- ✗ Sin cambios significativos

- ✗ Sin cambios significativos

# Cerrando el segundo camino 1/2

**PI 2**

¿Ayudan los modelos fundacionales?

**PI2.1**

¿Son interpretables? ¿Capturan bien la información?

Difíciles de interpretar en los conjuntos de datos utilizados

**PI2.2**

¿Mejoras cuantitativas suponen mejoras en interpretabilidad?

No se detecta correlación

¿Y para tener proyecciones más interpretables?

**PI2.3**

¿Afinar el modelo ayuda en la interpretabilidad?  
¿Cuánto se necesita afinar?

Sin cambios significativos. No hay una respuesta concluyente a la cantidad



## Cerrando el segundo camino 2/2



**LF3**

Modificar la función de distancia

Probemos con DTW

**LF4**

¿Y para tener proyecciones más interpretables?

Usar otras técnicas de proyección

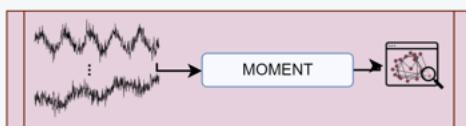
**LF5**

Aplicar el modelo de ML a datos preprocesados en lugar de a los datos brutos

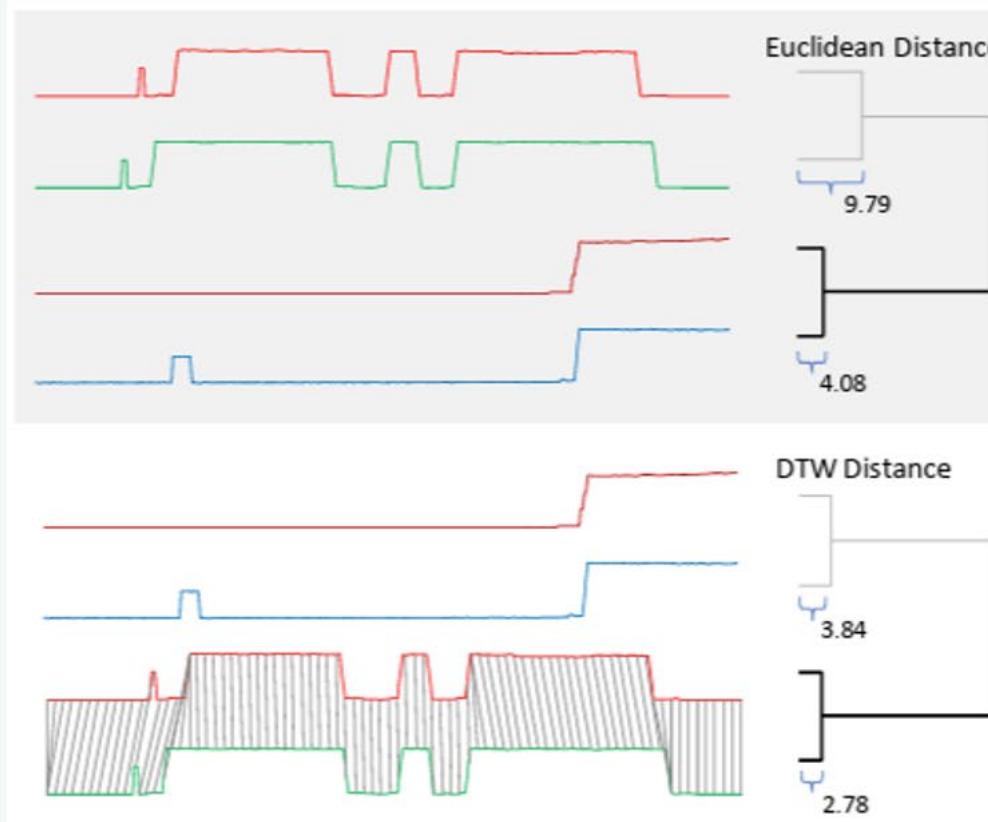
**LF6**

Congelar capas al ajustar

Path 2: DL

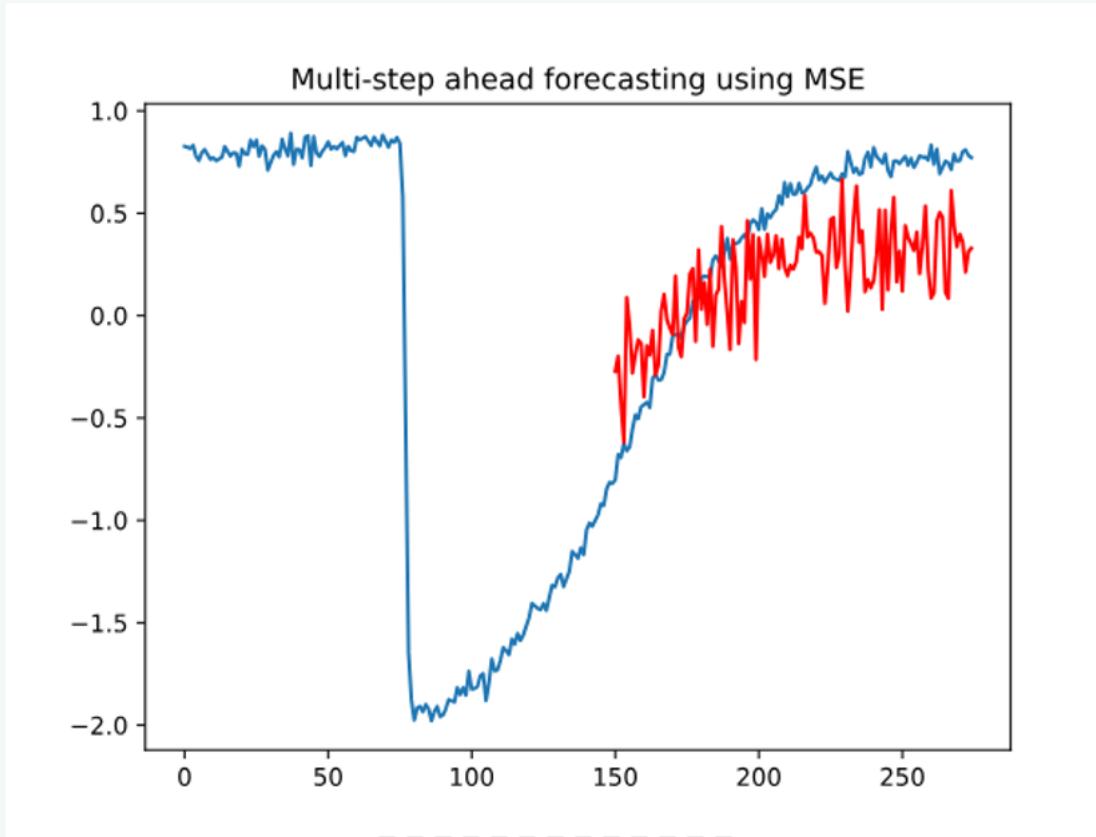


# Pruebas con MOMENT soft-DTW 1/2



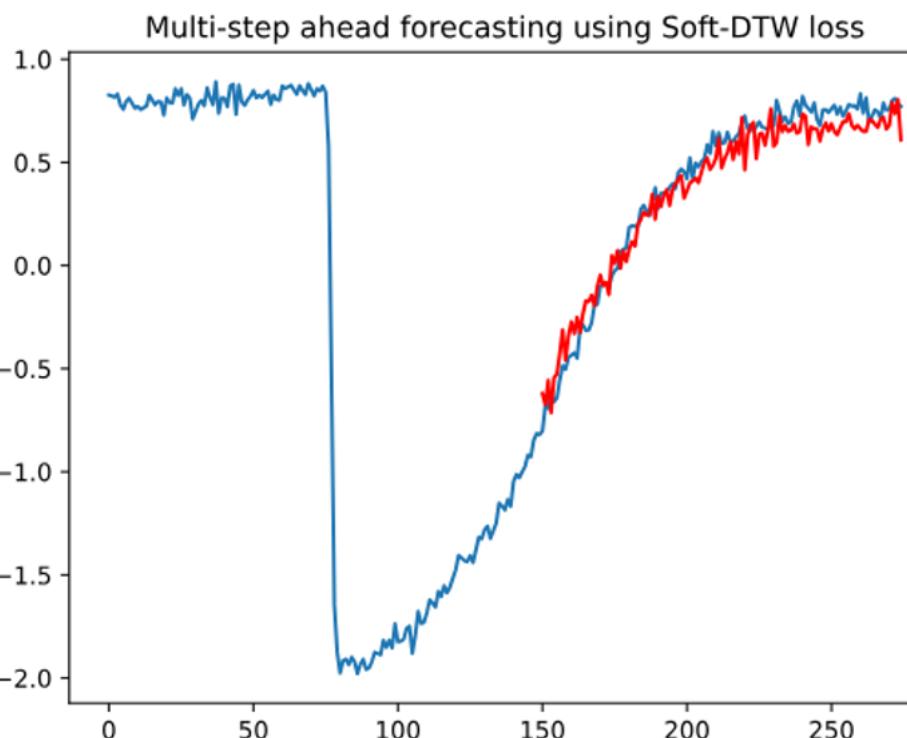
Distancia  
euclídea Vs. DTW

# Pruebas con MOMENT soft-DTW 1/2



Perceptrón  
simple con MSE

# Pruebas con MOMENT soft-DTW 1/2



Perceptrón  
simple con soft-  
DTW

## Pruebas con MOMENT soft-DTW 2/2



Al usar MOMENT-small con DTW para analizar *Kohl's* se observa



Que se **modifica** de manera clara la disposición de **los clústeres**

↳ Es **razonable** deducir que la **distancia** se puede **ajustar en función del objetivo**.



Resulta **difícil analizar patrones o tendencias**

↳ Es necesario **revisar** su uso en conjunción con otras de las **líneas futuras**

**4**/*5*

# Discusión

# Integración de MPlot



Mejora eficiencia (tiempo ejecución)



Depende del tamaño de la ventana.  
↳ MPlot multifocal  
↳ Difícil de integrar



Mejora interpretabilidad (visual)



Sólo admite series univariadas  
↳ Matrix Profile multivariable

# Integración de MOMENT



La mejora en eficiencia ha sido la esperada



La interpretabilidad no ha sido la esperada



Pocos conjuntos de datos

↳ Comparar con otras series temporales de la TS Pile, donde MOMENT ha demostrado su eficacia.

Técnicas de ajuste fino ¿sesgadas?

↳ Probar otras técnicas de ajuste fino

# Problemas a solventar



## Limitaciones de escalabilidad

- ✗ Análisis con MTSAE o MOMENT de series largas.
- ✓ Sí se ha conseguido el análisis previo con MPLOT (univariables).

## ✗ Precisión del espacio latente (no fácilmente interpretable)

- ↳ Otras distancias
- ↳ Otras técnicas de ajuste fino para ganar precisión

## ✗ Análisis previo (no admite series temporales multivariadas)

- ↳ MatrixProfile multidimensional.

**5**/*5*

# Conclusiones y trabajo futuro

# Conclusiones



## Se ha logrado

**Aplicación útil** para el análisis de series temporales **con**

- ✓ MPPlot y Matrix profile
- ✓ Distintos modelos de DL (+ fundacionales)
- ✓ Posibilidad de ajuste fino adaptado
  - ✓ En el momento de uso
  - ✓ Usando datos originales o preprocesados

↳ Versátil

## Se puede mejorar

- Escalabilidad
- Interpretabilidad
- ↳ En univariantes, los MPPlot nos apoyan

# Trabajo futuro 1/3



## Data Mining

- 1) Añadir **variables** basadas en el Matrix Profile como variables **exógenas**
- 2) Incluir **MPlot multifocal**
- 3) Incluir **Matrix Profile multivariable**



## Trabajo futuro 2/3



### Deep Learning | Mejorar el proceso de ajuste fino

- 1) Modificando la **distancia de pérdida (loss)**
- 2) Usando **datos preprocesados** en lugar de los datos brutos
- 3) **Congelando capas** durante el proceso



# Trabajo futuro 3/3



## Deep Learning | Otros

- 1) Integrar **nuevos modelos fundacionales**
- 2) Usar **otras técnicas de proyección**



- 3) Revisar la implementación de **MOMENT** para tratar de **trocear la obtención de vectores latentes** como con MTSAE
- 4) Mejorar **MTSAE** añadiendo otro tipo de **convoluciones**

# Publicaciones

## Artículos de revista

R1: Inmaculada Santamaría-Valenzuela, Víctor Rodríguez-Fernández, and David Camacho (2024). On the integration of large scale time series **distance matrices** into deep visual analytic tools. *Cognitive Computation*. ISSN: 1866-9956, eISSN: 1866-9964. Volume 17, article number 29, 2025.

- **DOI:** <https://doi.org/10.1007/s12559-024-10394-x9>
- **J. Impact Factor :** 4.3 (54/197: Computer Science, Artificial Intelligence; 76/310: Neurosciences) (year 2023)
- **Quartile:** Q1



R2: Inmaculada Santamaría-Valenzuela, Víctor Rodríguez-Fernández, Javier Huertas-Tato, John Hyuk Park, David Camacho. Decoding Latent Spaces: Assessing the Interpretability of **Time Series Foundation Models** for Visual Analytics. *International Journal of Interactive Multimedia and Artificial Intelligence (IJIMAI)*, 15th April 2025, to appear.

- **DOI:** <https://doi.org/10.48550/arXiv.2504.20099>
- **J. Impact Factor:** 3.4 (78/197: Computer Science, Artificial Intelligence; 62/170: Computer Science, interdisciplinary applications) (year 2023)
- **Quartile:** Q2

# Publicaciones

## Presentaciones en congresos

**C1:** Inmaculada Santamaria-Valenzuela, Victor Rodriguez-Fernandez, and David Camacho (2023). Exploring **Multiple Classification Systems** for Online Time Series Anomaly Detection. In Proceedings of 2023 International Conference on Network, Multimedia and Information Technology (NMITCON), Nitte Meenakshi Institute of Technology, sep. 01 - 02, 2023, Bengaluru, India, pp.1-6.

- **DOI:** <https://doi.org/10.1109/NMITCON58196.2023.10276028>
- **Indexed in:** IEEE Xplore



**C2:** Inmaculada Santamaria-Valenzuela, Victor Rodriguez-Fernandez, and David Camacho (2023). Exploring **Scalability** in Large-Scale Time Series in DeepVATS Framework. In: Nguyen, N.T., Huynh, CP., Nguyen, T.T., Le-Khac, NA., Nguyen, QV. (eds) The 13<sup>th</sup> Conference on Information Technology and Its Applications. CITA 2024. Lecture Notes in Networks and Systems, vol 882. Springer, Cham. July 19-20, 2024.

- **DOI:** [https://doi.org/10.1007/978-3-031-74127-2\\_21](https://doi.org/10.1007/978-3-031-74127-2_21)
- **CORE C (CORE2023)**
- **Indexed in:** Springer Nature, Scopus

# Publicaciones

## Congresos

**C3: Inmaculada Santamaría-Valenzuela**, Víctor Rodríguez-Fernandez, Jong Hyuk Park and David Camacho (2024). *Scalability analysis of DeepVATS: A Framework for DL Visual Analytics on Large Time Series Data*. In the 2024 World Congress on Information Technology Applications and Services (World IT Congress 2024). February 14-16, 2024, Jeju, Korea. Pp. 1-7. Web: <http://www.worlditcongress.org/2024/>.



**C4: Inmaculada Santamaría-Valenzuela**, Victor Rodriguez-Fernandez, and David Camacho (2024). *DeepVATS: A Tool for DL Visual Analytics on Large Time Series Data*. In the XX Conference of the Spanish Association for Artificial Intelligence (CAEPIA 2024). ISBN978-84-09-62724-0, pp. 235-236 (Short Paper).



# Análisis visual de series temporales combinando técnicas de minería de datos (DM) y aprendizaje profundo (DL)

María Inmaculada Santamaría Valenzuela

## Gracias

Directores

David Camacho Fernández  
Víctor Rodríguez Fernández

